

Aprendizaje automático aplicado a la selección de acciones: medición honesta del aprendizaje fuera de muestra

Adrián Núñez

2 de septiembre de 2026

Resumen

Este Trabajo Fin de Máster responde a dos preguntas que no deben confundirse. La primera es si un sistema de aprendizaje automático, formado por cinco agentes especializados, aprende a ordenar acciones de mejor a peor y mantiene esa capacidad sobre datos que no ha visto. La segunda es si ese orden puede convertirse en dinero frente al índice, y cuánto depende la respuesta de las reglas con las que se construye la cartera.

Batir al índice es un objetivo de suma cero antes de costes —lo que uno gana de más, otro lo pierde— y la mayoría de los fondos profesionales no lo consigue. El sistema trabaja sobre el S&P 500 histórico, usando cada dato contable sólo a partir del día en que se publicó. Tres estudios encadenados eligen el modelo atendiendo únicamente a la calidad del orden que produce; después, ya con esa señal congelada, un cuarto estudio compara 1.440 formas distintas de convertirla en una cartera.

Entre 2015 y 2024 el sistema ordena bien: la correlación entre el orden que predice y el que ocurre después es de 0,1067 de media sobre 117 fechas, positiva en el 76,1 % de ellas, y ninguna de 9.999 repeticiones con los datos barajados al azar llega a igualarla. En los años reservados, 2025–2026, la capacidad se mantiene positiva (0,0364) aunque con sólo 6 observaciones completas. Hay un resultado incómodo que el trabajo reporta igualmente: el agente de riesgo, por sí solo, ordena algo mejor que la combinación de los cinco, de modo que la evidencia respalda la capacidad de ordenar pero no demuestra que hagan falta cinco agentes.

La segunda respuesta depende de la cartera hasta cambiar de signo. Con la misma señal, sin reentrenar nada, pasar de la cartera de partida a la elegida eleva el resultado ajustado por riesgo de 0,312 a 0,841 y reduce las operaciones de 2,42 a 1,35 veces al año. En los años reservados, esa misma señal pasa de perder un -12,23 % frente al índice a un 0,24 %: de destruir valor a empatar. El cambio de signo es alentador, pero no demuestra que el sistema bata al mercado, porque la cartera elegida es la mejor de 1.440 alternativas y la comprobación cubre sólo 1,41 años.

De ahí la contribución principal, que es metodológica: la capacidad de predecir y la de ganar dinero con esa predicción deben medirse por separado, y ninguna conclusión práctica es interpretable sin decir con qué cartera se midió.

Palabras clave: aprendizaje automático, selección de acciones, Rank-IC, *point-in-time*, construcción de cartera, validación fuera de muestra.

Índice general

Resumen	I
Glosario de métricas y abreviaturas	VIII
1. Introducción	1
1.1. El problema y su dificultad	1
1.1.1. Dos problemas en una misma pregunta	1
1.1.2. Por qué es difícil	1
1.1.3. Por qué batir al índice es un juego de suma cero	2
1.2. Dos objetivos	2
1.3. Aportación y recorrido del documento	3
2. Estado del arte	4
2.1. De los factores al aprendizaje automático	4
2.1.1. Las regularidades que orientan el diseño	4
2.1.2. Qué añade el aprendizaje automático y qué arriesga	4
2.2. Sesgos que condicionan cualquier evidencia	6
2.3. Medir la señal: Rank-IC, amplitud y transferencia	6
2.3.1. Por qué la métrica es una correlación de rangos	6
2.3.2. De la señal a la cartera: la ley fundamental	6
3. Diseño de investigación, datos y observabilidad temporal	8
3.1. Fuentes y universo histórico	8
3.1.1. De dónde sale cada dato	8
3.1.2. Un universo que cambia con el tiempo	8
3.2. El panel que el modelo evalúa	9
3.2.1. Ventanas del experimento y cobertura del índice	9
3.2.2. Dimensión efectiva de la muestra	10
3.2.3. Integridad de la simulación: lo que no ocurrió	11
3.2.4. Identidad y trazabilidad del panel	12
3.3. Observabilidad temporal: qué se sabía y cuándo	12
3.3.1. Qué puede verse y cuándo se mira	12
3.3.2. De un cierre contable a una señal invertible	13
3.3.3. Cierre de cohortes y ausencia de fuga temporal	13
3.4. El catálogo de variables y su reparto entre agentes	14
4. Sistema de predicción: agentes y meta-agente	15
4.1. Arquitectura y aprendizaje <i>walk-forward</i>	15
4.1.1. Qué predice el modelo	16
4.1.2. Dos relojes que nunca se confunden	17
4.2. Entrenamiento y combinación de rangos	17
4.2.1. Cómo se entrena cada especialista	17

4.2.2.	Cómo se combinan los cinco rangos	17
4.3.	Qué mira cada agente y cómo cambia con el tiempo	18
5.	Protocolo experimental: de la señal a la cartera	20
5.1.	Por qué el protocolo se aplicó tres veces	20
5.2.	Cómo se elige una configuración	21
5.2.1.	Optimización secuencial por fases	21
5.2.2.	Cuándo una alternativa sustituye a la que ya estaba	21
5.2.3.	Por qué la selección predictiva es secuencial	23
5.2.4.	El coste y el rastro de la búsqueda	23
5.3.	De la ordenación a las posiciones	24
5.3.1.	De rango a alfa esperado	24
5.3.2.	Construcción de cartera y precedencia de reglas	25
5.3.3.	Ejemplo de decisión y coste	26
5.4.	El Portfolio Study: optimizar la cartera sin tocar la señal	26
5.4.1.	Qué es el Information Ratio y por qué se optimiza éste	26
5.4.2.	Por qué cartesiano y no secuencial	27
5.4.3.	Dos búsquedas y dos multiplicidades	27
6.	Resultados predictivos: qué aprendió el sistema	29
6.1.	La configuración ganadora y la cadena de estudios	29
6.1.1.	Las tres pasadas y su convergencia	29
6.1.2.	La configuración final, variable a variable	30
6.2.	Qué aprendieron los agentes y el meta	31
6.2.1.	La trayectoria del peso aprendido	31
6.2.2.	Qué significa que el meta se concentre casi por completo	32
6.2.3.	Qué mira realmente el agente dominante	32
6.3.	Capacidad predictiva fuera de muestra	34
6.3.1.	La cola superior frente a la ordenación completa	35
6.3.2.	Estabilidad por eras	36
6.3.3.	El orden mejora mientras el pago empeora	37
6.3.4.	Qué habría sabido un gestor en cada momento	38
6.4.	Robustez: aprendizaje y no suerte	38
6.4.1.	¿Es la señal una réplica de factores conocidos?	40
6.4.2.	El contraste que no supera: Deflated Sharpe	41
6.5.	Qué queda establecido y qué no	41
7.	Resultados económicos: cartera, perfiles y confirmación reservada	43
7.1.	De la señal a la cartera: qué se optimizó y cómo	43
7.1.1.	Tres ventanas y dos carteras	43
7.1.2.	La rejilla completa: qué reglas mueven el resultado	43
7.1.3.	Dónde cae la cartera adoptada entre todas las evaluadas	44
7.2.	La cartera ganadora y sus resultados	46
7.2.1.	En qué consiste y en qué se diferencia	46
7.2.2.	Selección frente a confirmación	46
7.2.3.	Resultados por ventana	47
7.3.	Por qué el sistema compró lo que compró	49
7.3.1.	Qué tuvo dentro la cartera	49
7.3.2.	Una venta prematura, y lo que costó	51
7.3.3.	Un caso concreto: por qué el sistema compró Apple	51
7.4.	Rotación, costes y capacidad	52
7.4.1.	De dónde viene la rotación	52

7.4.2.	Cuánto coste soportaría el resultado	54
7.4.3.	Hasta qué patrimonio es ejecutable	55
7.5.	Perfiles de inversor y era reservada	55
7.5.1.	Qué es un perfil y qué le pasó a cada estilo	55
7.5.2.	Años adversos y significado de la era reservada	58
7.5.3.	Qué se sigue para el diseño de cartera	59
8.	Limitaciones y amenazas a la validez	60
8.1.	Amenazas a la validez interna	61
8.1.1.	Fechas, restatements y calidad de la fuente	61
8.1.2.	El sesgo de supervivencia por cobertura del proveedor	61
8.2.	Amenazas económicas y de generalización	62
8.3.	Lo que la cartera dejó de ganar	63
8.4.	Limitaciones heredadas del desarrollo	64
8.4.1.	Tres decisiones que condicionan las cifras	64
8.4.2.	Decisiones con margen escaso	64
9.	Conclusiones y trabajo futuro	65
9.1.	Objetivo 1: capacidad de ordenación	65
9.2.	Objetivo 2: cobrar el orden frente al mercado	65
9.2.1.	Sensibilidad a la construcción de cartera	65
9.2.2.	Comportamiento en la era reservada	66
9.3.	Contribución defendible	66
9.4.	Trabajo futuro y respuesta final	66
10.	Bibliografía	68
A.	Reproducibilidad	71
A.1.	Identidad de los estudios	71
A.2.	Cómo se persiste y se audita la evidencia	71
A.2.1.	Ciclo de vida de una ejecución	71
A.2.2.	Cadena de custodia de la evidencia	72
A.3.	Regeneración de figuras y tablas	72
B.	Catálogo cerrado y protocolo experimental	74
B.1.	Regla de selección, en su forma exacta	74
B.2.	El catálogo completo	74
B.3.	Capacidad de las variables por separado	76
B.4.	Diccionario de variables predictivas	76
C.	Qué significa cada variable del catálogo	79
C.1.	Temporal: cuándo se mira y cuánto futuro se predice	79
C.2.	Representación: qué ve el modelo	80
C.3.	Modelo: cómo aprende cada agente	80
C.4.	Meta-agente: cómo se combinan los cinco	81
C.5.	Cartera: cómo se convierte el orden en posiciones	81
C.5.1.	Las seis que el Portfolio Study optimiza	81
C.5.2.	Las seis que se fijan y se estresan aparte	82
D.	Auditoría del desarrollo	83
D.1.	Cuatro defectos que producían resultados plausibles	84
D.2.	Matriz de contratos que quedó en el sistema	84

Índice de figuras

1.1. Fondos estadounidenses de gran capitalización que quedan por debajo del S&P 500 a distintos horizontes. Fuente: S&P Dow Jones Indices, <i>SPIVA U.S. Scorecard Year-End 2025</i> , Report 1a, rentabilidad absoluta; datos a 31 de diciembre de 2025.	2
3.1. Cobertura real del universo histórico y ventanas del experimento. La serie procede exclusivamente de <code>data/raw/universe_coverage.json</code> ; selección y reserva se distinguen visualmente, mientras el entrenamiento utiliza ventanas móviles de ocho años.	9
3.2. Tamaño de las cohortes evaluadas y distribución de cobertura de las variables por bloque. El panel izquierdo cuenta acciones efectivamente puntuadas en cada snapshot; el derecho resume disponibilidad dentro de ese panel, no cobertura del índice.	11
3.3. Las fechas que intervienen en una decisión. El retardo de observación separa el fin de mes del día en que se mira el mercado; sólo puede usarse lo publicado antes de ese día, y el retorno futuro se reserva como etiqueta.	13
4.1. De las variables al orden final. Cada especialista recibe únicamente las variables de su familia; el meta-agente combina los cinco rangos con pesos que aprende de las cohortes ya cerradas.	16
4.2. Izquierda: número de variables distintas que emplea cada especialista en cada reentrenamiento. Derecha: capacidad de ordenación de cada variable por sí sola frente al peso que el modelo acaba dándole.	18
5.1. La cadena de tres pasadas. El número de variables que cada una llega a cambiar se reduce de nueve a dos: el procedimiento se queda sin mejoras que hacer, que es la señal para detenerlo.	20
5.2. Las dos mitades del protocolo. Las cuatro fases superiores se deciden por Rank-IC y son las únicas que pueden modificar la configuración; lo que ocurre por debajo trabaja sobre una señal que ya no puede cambiar.	22
5.3. Orden en que la cartera decide. El tiempo mínimo en cartera se comprueba antes que la economía de la venta, y ninguna posición se vende si no hay un destino mejor después de costes.	26
6.1. Peso medio anual asignado por el meta-agente a cada especialista. 2015 corresponde íntegramente al reparto uniforme por ausencia de cohortes cerradas.	31
6.2. Variable que encabeza la atribución del agente de riesgo en cada año, como fracción de las observaciones.	33
6.3. Rank-IC por cohorte. La banda dorada identifica la era reservada, que no intervino en ninguna decisión.	34
6.4. Cada punto es una fecha de decisión: en el eje horizontal, la calidad del orden sobre todo el universo; en el vertical, el exceso que obtuvieron las diez acciones mejor puntuadas.	36

6.5.	Rank-IC medio del meta-agente y pago económico era a era, con la cartera por defecto del catálogo. Las dos escalas son distintas a propósito: lo que importa es la dirección de cada serie, no su nivel.	37
6.6.	Capacidad de ordenación calculada en cada fecha usando sólo la información ya cerrada en ese momento, con dos memorias distintas. La franja marca el tramo en que la memoria corta habría dado un veredicto negativo.	38
6.7.	Intervalos de confianza del Rank-IC por bloques y estabilidad de la media al excluir cada era completa.	39
6.8.	Dos lecturas de solapamiento factorial en selección. Izquierda: cargas y sus intervalos Newey–West; derecha: Rank-IC antes y después de neutralizar catorce controles de estilo.	41
7.1.	Cuánto separa cada variable de cartera el Information Ratio mediano. Cada línea compara el mejor y el peor valor con las otras cinco variables variando libremente.	44
7.2.	Las carteras evaluadas en el plano rotación–Information Ratio. Cada punto es una cartera completa, con las seis coordenadas fijadas a la vez; el color codifica el tope de efectivo y el círculo negro señala la ganadora.	45
7.3.	Information Ratio dentro y fuera de la ventana de selección, pasada a pasada de la cadena, con la cartera por defecto del catálogo.	47
7.4.	Patrimonio y drawdown de la cartera ganadora frente a SPY. La región dorada es confirmación reservada, no selección.	48
7.5.	Qué compró la cartera: contribución concentrada, episodios extremos y exposición sectorial. El sector es una foto actual y sólo tiene valor descriptivo.	50
7.6.	Exceso geométrico frente al coste por operación en selección. Se muestran la ruta congelada y la cartera resimulada, el coste adoptado y sus puntos de equilibrio. La reserva no se mezcla con esta curva porque parte prácticamente sin margen. .	54
7.7.	Participación sobre el volumen diario frente al patrimonio gestionado, en escala logarítmica. Los umbrales del 5 % y el 10 % marcan dónde la ejecución deja de ser cómoda.	55
7.8.	Peso que cada perfil da a cada especialista. Un peso negativo indica que el estilo apuesta deliberadamente en contra de ese agente.	57
7.9.	Resultados informativos de los perfiles: exceso geométrico agregado en selección y reserva, y exceso anual frente a SPY. La separación de 2025–2026 recuerda que los perfiles no se seleccionaron y que la reserva contiene solo seis cohortes; la figura no constituye un ranking fiable de estilos.	57
8.1.	Fracción de empresas que no llegan al panel, según cuánto hace que abandonaron el índice. La progresión es la firma de una fuente que poda su histórico, no la de un sector que quiebra.	62

Índice de tablas

2.1. Posicionamiento metodológico del estudio frente a líneas de literatura relevantes.	5
3.1. Resolución del universo histórico: por qué falta cada <i>ticker</i> ausente.	10
3.2. Dimensión efectiva de la muestra fuera de muestra.	10
5.1. Qué alternativa se rechazó en cada decisión y cuánto habría costado adoptarla. . .	22
5.2. Lo que costó recorrer el catálogo, por fase del protocolo.	24
5.3. Frecuencia de los estados de calibración por ventana.	25
6.1. Las tres pasadas de la cadena y su ganador.	29
6.2. Qué cambió cada pasada respecto de su punto de partida.	30
6.3. La configuración predictiva ganadora, variable a variable.	30
6.4. Capacidad predictiva de los agentes y combinadores en 2015–2024.	32
6.5. Variables que más contribuyen a la puntuación de cada agente.	33
6.6. Sistema frente a baselines deterministas.	35
6.7. Rank-IC medio por señal y era.	36
6.8. Resumen de contrastes de robustez.	39
7.1. La cartera adoptada frente a la distribución de las 1.440 evaluadas.	45
7.2. La cartera ganadora frente a la cartera del modelo.	46
7.3. Las tres ventanas de evaluación, con su papel declarado.	48
7.4. Resultado anual de la cartera ganadora.	49
7.5. Las diez acciones más presentes en la cartera durante la ventana de selección. . .	50
7.6. Apple el 30 de octubre de 2019: cómo la vio cada agente y cuánto pesaba cada uno. .	52
7.7. Descomposición del flujo de cartera por motivo de orden.	53
8.1. Limitaciones, evidencia que las cuantifica y severidad asignada.	60
8.2. Ventas que el mercado desmintió: exceso no cobrado en los doce meses siguientes. .	63
A.1. Niveles de persistencia y propósito de cada uno.	72
B.1. Catálogo cerrado completo: las 33 variables, su rejilla y el valor del ganador. . . .	75
B.2. Variables con mayor y menor Rank-IC univariante.	76
B.3. Diccionario completo de las 68 variables declaradas.	77
D.1. Defectos del desarrollo con impacto sobre la validez.	83
D.2. Contratos de validación derivados de los defectos materiales.	85

Glosario de métricas y abreviaturas

La memoria combina términos de aprendizaje automático, econometría y gestión de carteras. Este glosario fija su significado una sola vez; los capítulos los emplean después sin volver a definirlos.

Agente especialista

Modelo que aprende a ordenar el universo mirando sólo una familia de variables. Son cinco: calidad, valor, crecimiento, tendencia y riesgo.

Alfa

Retorno de la cartera que excede al benchmark. Puede designar el exceso realizado o, cuando se indica, el exceso esperado que gobierna una orden.

Amplitud

Número aproximado de decisiones independientes sobre las que puede expresarse una señal. Doce cohortes mensuales solapadas a horizonte anual no equivalen a doce observaciones independientes.

Atribución local

Descomposición de la puntuación de una acción en la aportación de cada variable que la produjo. Describe qué miró el modelo; no demuestra que esa variable cause el retorno.

Baseline determinista

Fórmula fija de uno o varios factores, sin entrenamiento, calculada sobre el mismo panel. Sirve de listón para saber cuánto añade el sistema aprendido.

Benchmark

Referencia contra la que se mide la cartera. SPY se usa como representación invertible del S&P 500, pero nunca puede ser una posición de la estrategia.

Bootstrap por bloques

Remuestreo que conserva tramos consecutivos de cohortes en lugar de extraerlas una a una. Con etiquetas solapadas a doce meses, romper esa dependencia produciría intervalos artificialmente estrechos.

CAGR

Tasa de crecimiento anual compuesta. Resume el crecimiento geométrico del patrimonio y no informa por sí sola de su volatilidad ni de su recorrido.

Coefficiente de transferencia

Fracción de la señal disponible que llega efectivamente a la cartera. Es el término de la ley fundamental de la gestión activa que las restricciones *long-only*, la concentración y los costes reducen.

Cohorte

Sección transversal de acciones puntuada en una misma fecha y evaluada contra el retorno que se realiza al final del horizonte declarado. Está *cerrada* cuando ese horizonte ya ha transcurrido y su retorno es observable; sólo entonces puede entrar en un entrenamiento o en un diagnóstico. Emitir una

	puntuación y disponer de su etiqueta cerrada son, por tanto, cosas distintas: en una ventana reciente hay muchas más puntuaciones que cohortes cerradas.
Dominancia	La más exigente de las dos formas en que un candidato puede desplazar al incumbente: ventaja media favorable <i>y</i> mejor en más de la mitad de las fechas comparadas.
DSR	<i>Deflated Sharpe Ratio</i> . Probabilidad de que el Sharpe observado supere lo esperable por azar después de considerar el número de configuraciones ensayadas, la asimetría y la curtosis.
Drawdown	Caída desde un máximo previo del patrimonio. El máximo drawdown es la peor de esas pérdidas durante una ventana.
Empate técnico	Situación en la que dos alternativas difieren menos de 0,002 en ventaja pareada. La regla declarada de antemano la resuelve por simplicidad, no por magnitud, de modo que su resultado no debe presentarse como un hallazgo empírico.
Episodio de tenencia	Cada tramo continuo en que una acción permanece en cartera. Una misma acción comprada, vendida y recomprada más tarde produce dos episodios.
Fecha de publicación	Día en que un estado financiero se hizo público, según el registro de SEC EDGAR. No debe confundirse con el cierre fiscal, que es la fecha económica a la que el informe se refiere y que suele ser semanas o meses anterior.
HHI	Índice de Herfindahl–Hirschman aplicado a los pesos de cartera. Aumenta cuando el patrimonio se concentra en menos posiciones.
IC-IR	Media temporal del Rank-IC dividida por su desviación estándar. Mide estabilidad de la capacidad de ordenar, no rentabilidad de cartera.
Incumbente	Configuración vigente en cada paso de la selección. Un candidato sólo la sustituye si supera la puerta declarada; ante evidencia indistinguible, el incumbente se conserva.
Information Ratio (IR)	Media del exceso de retorno dividida por su volatilidad. A diferencia del IC-IR, pertenece a la capa económica y depende de la cartera.
Lag de observación	Días que transcurren entre el fin de un mes y el día en que el sistema observa el mercado y emite puntuaciones. El ganador emplea sesenta. Fija <i>cuándo se mira</i> ; no es lo que impide usar información futura, papel que corresponde al filtro por fecha de publicación.
Meta-agente	Capa que combina los cinco rangos especializados en un único orden, aprendiendo el peso de cada agente a partir de cohortes ya cerradas.
Model Study	Ejecución que recorre el catálogo predictivo y elige una configuración por Rank-IC. El trabajo encadena tres.
Neutralización por estilo	Retirar de la señal la parte explicable por un conjunto de controles conocidos

y recalculando el Rank-IC sobre el residuo. Mide cuánta señal sobrevive a los factores clásicos.

No inferioridad Puerta alternativa a la dominancia: un candidato es admisible si el límite inferior de su intervalo *bootstrap* pareado al 90 % supera el margen declarado. Prueba que no es peor, no que sea mejor.

OOS *Out of sample*. Observaciones posteriores a las usadas para ajustar el modelo. En esta memoria también se distingue dentro de OOS entre selección y reserva.

Perfil de inversor

Reordenación de la señal ya congelada que pondera los cinco agentes con pesos fijos declarados de antemano, para representar un estilo de inversión.

Placebo de etiqueta

Ejecución completa del sistema con el retorno futuro barajado dentro de cada cohorte. Si la maquinaria fabricase señal por sí misma, el placebo la mostraría.

Portfolio Study Ejecución que, con la señal ya congelada, recorre las combinaciones de reglas de cartera y elige una por Information Ratio.

P95 Percentil 95. En capacidad es la participación sobre volumen que no supera el 95 % de las órdenes; evita que un único extremo gobierne la estimación.

PIT *Point in time*. Información asociada a la fecha en que era observable, no a la fecha económica a la que se refiere ni a una versión revisada conocida después.

Rank-IC Correlación de Spearman entre el ranking emitido y el retorno futuro excedente dentro de una cohorte. Es la métrica que selecciona el modelo. El Rank-IC *univariante* es el de una sola variable, calculado sin modelo alguno.

Reserva Periodo 2025–2026 aislado de toda selección. Sus pocas cohortes cerradas permiten una comprobación preliminar, no una estimación precisa de generalización.

Rotación Sustitución de una posición por otra porque la señal ha cambiado de opinión. Se distingue del *turnover*, que agrega todo el movimiento de pesos, incluido el simple ajuste de una posición que se conserva.

Slippage Diferencia adversa entre el precio de referencia y el de ejecución. Se suma a la comisión para calcular el coste de una operación.

Snapshot Fecha en la que el sistema reconstruye el universo observable, emite rankings y decide la cartera.

Suma cero Propiedad aritmética del problema de batir a un índice: antes de costes, el conjunto de la gestión activa obtiene exactamente el rendimiento del mercado, de modo que el exceso de un participante es el defecto de otro.

Turnover Suma anualizada de cambios absolutos de peso. Una cifra de 1,35 equivale a mover nocionalmente un 135 % del patrimonio en un año, no a cerrar la cartera 1,35 veces.

Ventaja pareada

Media de la diferencia de Rank-IC entre dos configuraciones, calculada fecha

a fecha y no como diferencia de sus promedios. Es el objeto que juzgan las puertas de decisión.

Ventila Cada uno de los veinte tramos en que se divide una cohorte ordenada por el orden final del meta-agente. Son la unidad sobre la que se estima la curva que traduce rango en alfa esperada.

Ventana de selección Cohortes de 2015–2024 sobre las que se comparan configuraciones. La era reservada queda fuera de todas esas decisiones.

Walk-forward Esquema que avanza cronológicamente: ajusta con historia disponible, predice la fecha siguiente y repite sin permitir que el futuro vuelva al entrenamiento.

Capítulo 1

Introducción

1.1. El problema y su dificultad

1.1.1. Dos problemas en una misma pregunta

¿Puede un sistema aprender a ordenar acciones fuera de muestra y convertir después ese orden en una cartera útil? La pregunta parece única, pero contiene dos problemas. Ordenar exige que las acciones con mayor puntuación obtengan, en promedio, mejores retornos futuros que las de menor puntuación. Invertir exige además elegir cuántas comprar, cuánto asignar, cuándo vender y cuánto efectivo mantener. Una señal puede resolver el primer problema y fracasar en el segundo.

Esa separación organiza todo el trabajo. El modelo se selecciona únicamente por su capacidad de ordenación transversal; las reglas de cartera se estudian después, con la señal ya congelada. Así, una mejora económica no puede reescribirse retrospectivamente como mejora predictiva.

A esa separación se añade una segunda decisión, tomada antes de calcular nada: los datos de 2025 y 2026 se apartaron desde el principio, y ninguna elección del trabajo —ni el modelo, ni sus parámetros, ni las reglas de cartera— pudo mirarlos. El motivo es que un sistema elegido con los mismos datos con los que después se juzga siempre parece mejor de lo que es, y ninguna corrección estadística devuelve del todo esa inocencia. Reservar un tramo desde el inicio es la única forma de llegar al final con una medición que la búsqueda no haya podido contaminar. Tiene un precio, y hay que declararlo desde ya: ese tramo es corto y, con un horizonte de doce meses, deja pocas observaciones completas, así que sirve para comprobar si el sistema se sostiene, no para estimar con precisión cuánto.

1.1.2. Por qué es difícil

La selección cuantitativa de acciones combina tres dificultades. Primero, la información disponible cambia con el tiempo: usar hoy la composición actual de un índice o un dato fundamental antes de su publicación produce una ventaja inexistente. Segundo, probar muchas configuraciones aumenta la probabilidad de elegir ruido. Tercero, el resultado observado depende de una cadena de decisiones posteriores al modelo. Evaluar solo la rentabilidad final no permite saber en qué eslabón apareció la mejora o el fallo.

El sistema estudiado afronta esas dificultades con un panel *point-in-time*, cohortes cerradas y una única ruta experimental. Cinco agentes especializados —calidad, valor, crecimiento, tendencia y riesgo— producen cada uno su propia ordenación, y un meta-agente aprende a combinarlas con información que ya estaba cerrada en cada fecha. La selección secuencial modifica una variable cada vez y conserva únicamente cambios respaldados por Rank-IC robusto. Después se calculan atribución, robustez, carteras y perfiles como evidencia informativa.

El segundo objetivo parte, además, de un listón competitivo muy alto. El *SPIVA U.S. Scorecard Year-End 2025* compara fondos estadounidenses de gran capitalización con el S&P 500 y

muestra que la mayoría queda por debajo del índice en todos los horizontes publicados (Figura 1.1): a veinte años, el 92,89 % no lo supera.




Figura 1.1: Fondos estadounidenses de gran capitalización que quedan por debajo del S&P 500 a distintos horizontes. Fuente: S&P Dow Jones Indices, *SPIVA U.S. Scorecard Year-End 2025*, Report 1a, rentabilidad absoluta; datos a 31 de diciembre de 2025.

Esa persistencia no es una casualidad estadística: tiene una explicación aritmética.

1.1.3. Por qué batir al índice es un juego de suma cero

El argumento lo formuló Sharpe (1991) y es aritmético, no empírico: el mercado es la suma de quienes lo componen, de modo que el conjunto de los gestores activos posee, por construcción, la cartera de mercado. Antes de costes, el rendimiento medio ponderado de la gestión activa es exactamente el del índice; para que alguien lo supere, otro debe quedarse por debajo en la misma medida. Es un juego de **suma cero antes de costes**, y como operar cuesta, pasa a ser de **suma negativa después**. No hay ninguna versión de este problema en la que todos los participantes ganen.

El argumento es exacto sobre el conjunto de los participantes, no sobre cada uno: no dice que sea imposible batir al índice, sino que hacerlo exige que otro no lo consiga. Eso no vuelve inalcanzable el objetivo económico, pero sí eleva el estándar de evidencia. No basta con encontrar una cartera que funcionó en el periodo observado: hay que separar la capacidad de ordenar de la capacidad de cobrar esa ventaja, descontar costes y comprobar qué sucede fuera de la ventana en la que se eligieron las reglas.

1.2. Dos objetivos

Objetivo 1. ¿Aprende el sistema a ordenar acciones? Determinar si aprende una ordenación transversal con capacidad predictiva fuera de muestra, y si esa capacidad resiste cambios de régimen y controles contra azar, fuga temporal y factores conocidos. Es una afirmación sobre el modelo, se mide con Rank-IC y se responde contra un listón absoluto: o existe una ordenación con Rank-IC positivo fuera de muestra, o no existe. Este objetivo no presupone que el meta-agente deba superar a todos los especialistas: esa comparación forma parte del resultado.

Objetivo 2. ¿Puede cobrarse esa ordenación frente al mercado? Comprobar si el orden aprendido se traduce en una cartera que supere al índice una vez descontados los costes.

A diferencia del primero, es una afirmación sobre un mercado competitivo y de suma cero, y por tanto se responde contra un listón relativo: superarlo significa ganarle la posición a otro participante en un juego donde la mayoría pierde. Ninguna cantidad de Rank-IC lo garantiza por sí sola.

La respuesta a ese segundo objetivo depende de algo que este trabajo no esperaba encontrar en el centro del argumento, y de ahí que se enuncie en dos mitades. **(2a)** Con la señal ya congelada, ¿generan las reglas de construcción de cartera diferencias materiales en el resultado económico? **(2b)** ¿Conserva la cartera elegida ese resultado en la era reservada? La primera mitad puede sostenerse con toda la rejilla de alternativas; la segunda queda limitada por el reducido número de cohortes reservadas. La respuesta, adelantada aquí, es que la misma señal produce resultados de signo opuesto según cómo se construya la cartera: el segundo objetivo no puede responderse sin declarar con cuál se midió.

1.3. Aportación y recorrido del documento

La aportación no consiste en presentar una cartera como recomendación de inversión. Consiste en un procedimiento auditable para separar aprendizaje predictivo e implementación económica, junto con un caso empírico completo. El trabajo muestra qué aprendió el sistema, qué especialista concentra la información, qué contrastes supera, qué reglas de cartera mueven el resultado y qué cambia cuando la misma señal se evalúa en una ventana que no intervino en ninguna decisión.

El documento sigue ese mismo orden. Los capítulos 2 a 5 preparan la respuesta —la literatura, los datos disponibles, el sistema y el protocolo que lo decide—; el 6 contesta a la primera pregunta y el 7 a la segunda; el 8 delimita hasta dónde llega la evidencia y el 9 la resume.

Capítulo 2

Estado del arte

2.1. De los factores al aprendizaje automático

2.1.1. Las regularidades que orientan el diseño

Los retornos esperados de una acción no son independientes de sus características observables. Sobre esa idea se construyó la literatura de factores: el tamaño (Banz, 1981), el valor (Fama y French, 1992, 1993), el momentum (Jegadeesh y Titman, 1993), la calidad (Asness et al., 2019), la rentabilidad bruta (Novy-Marx, 2013) o la baja beta (Frazzini y Pedersen, 2014) quedaron asociados a diferencias sistemáticas de rentabilidad. De ahí salen las cinco familias en que este trabajo reparte sus variables —calidad, valor, crecimiento, tendencia y riesgo—, y de ahí salen también sus baselines: una fórmula determinista de un factor, calculada sobre el mismo panel, es el listón mínimo que un sistema aprendido debe superar.

Esa literatura trae consigo una advertencia que importa más que el catálogo de primas. Las regularidades documentadas se debilitan al medirse fuera de la muestra en que se descubrieron, y más aún después de publicarse: McLean y Pontiff (2016) lo documentan sobre 97 predictores y Hou et al. (2020) sobre 452 anomalías reevaluadas con criterios homogéneos, muchas de las cuales dejan de superar umbrales exigentes o dependen de microcapitalizaciones. La implicación no es que toda regularidad sea falsa, sino que una señal aprendida tiene que demostrar estabilidad temporal, resistir controles conocidos y declarar cuánto de su éxito aparente procede de haber buscado entre alternativas. Es el motivo de que este trabajo reserve una era completa y mida robustez antes de afirmar nada.

Ninguna de esas primas, aplicada como fórmula fija sobre el panel de este trabajo, llega a ordenar gran cosa: el Capítulo 6 lo mide al comparar el sistema con esos mismos *baselines*. No invalida la literatura —se documentaron sobre universos, periodos y horizontes distintos—, pero sí acota qué cabe esperar aquí de una regla sin aprendizaje.

Los factores cumplen aquí un tercer papel además de orientar el reparto y servir de baseline: son controles de atribución. Si la señal desaparece al neutralizar exposiciones conocidas, la interpretación debe ser más modesta. Conviene precisar, eso sí, que ningún agente representa un factor puro: una empresa de alta calidad puede presentar a la vez baja volatilidad, crecimiento persistente y valoración elevada. La especialización organiza la entrada del modelo, no impone que el mercado recompense cada bloque por separado.

2.1.2. Qué añade el aprendizaje automático y qué arriesga

Los métodos de aprendizaje automático amplían la capacidad de modelar no linealidades e interacciones entre características. Gu et al. (2020) muestran que estos modelos pueden mejorar la predicción transversal cuando el conjunto de señales es amplio y el entrenamiento respeta la estructura temporal. LightGBM, usado aquí en cada agente, pertenece a la familia de árboles

potenciados: construye de forma secuencial árboles débiles que corrigen errores de los anteriores y puede manejar relaciones no monotónicas (Ke et al., 2017).

Ese resultado forma parte de una literatura más amplia que intenta reducir dimensionalidad sin suponer que cada característica actúa linealmente y de forma aislada. Kelly et al. (2019) vinculan características y covarianzas mediante componentes principales instrumentados; Freyberger et al. (2020) combinan selección regularizada y funciones no paramétricas; y Feng et al. (2020) estudian qué factores aportan información incremental dentro de un catálogo amplio. Sus métodos son distintos, pero convergen en dos ideas relevantes aquí: la no linealidad puede importar y añadir predictores no garantiza añadir información.

La elección de árboles potenciados no se presenta por ello como una conclusión universal. Frente a un modelo lineal, ganan capacidad para representar umbrales e interacciones, pero pierden una interpretación directa de coeficientes. Frente a una red profunda, ofrecen una complejidad más contenida y una atribución local más manejable para el tamaño del panel. El catálogo conserva una alternativa lineal regularizada y una formulación de ranking directo precisamente para que estas preferencias puedan contrastarse en vez de asumirse.

Hay además una diferencia entre predecir retornos y ordenar acciones. Un error pequeño en unidades de retorno puede convivir con un orden transversal pobre, y una transformación monótona del score puede alterar el error cuadrático sin cambiar ninguna decisión de selección. Este trabajo sigue la segunda pregunta: cada agente aprende una representación continua, pero el protocolo juzga el orden que induce. Esa elección acerca el objetivo estadístico al uso final sin hacer que la cartera entre prematuramente en la selección.

Esa flexibilidad tiene un coste epistemológico. Un modelo flexible puede encontrar patrones espurios con facilidad, especialmente si se prueban parámetros hasta maximizar una métrica final. Por ello la pregunta no es si un algoritmo complejo puede ajustar la historia, sino si conserva una ventaja al evaluarse en observaciones posteriores no utilizadas para su entrenamiento ni para su selección. El diseño *walk-forward*, las etiquetas cerradas y la era reservada son respuestas a esa exigencia. La Tabla 2.1 enfrenta las cuatro líneas de literatura que este trabajo cruza con el riesgo metodológico de cada una y con lo que aquí se hace al respecto.

Tabla 2.1: Posicionamiento metodológico del estudio frente a líneas de literatura relevantes.

Enfoque	Aportación principal	Riesgo metodológico	Respuesta de este TFM
Factores clásicos	Interpretabilidad económica y baselines simples	Confundir una prima histórica con señal universal	Comparación sobre el mismo panel y neutralización de estilo
ML transversal	Interacciones y no linealidades	Sobreajuste de parámetros y dependencia temporal	<i>Walk-forward</i> , catálogo cerrado y Rank-IC OOS
Backtest de cartera	Traducción a utilidad económica	Elegir por CAGR, ignorar costes o supervivencia	Cartera posterior al ganador y costes explícitos
Inferencia con múltiples pruebas	Penalización del <i>data snooping</i>	Publicar sólo la mejor especificación	Bootstrap, permutación, placebos y Deflated Sharpe

Elaboración propia a partir de Gu et al. (2020), Harvey et al. (2016) y López de Prado et al. (2014).

A esas cuatro líneas se añade una quinta que no es metodológica sino estructural: la aritmética de la gestión activa de Sharpe (1991), enunciada en la Sección 1.1.3. Su consecuencia para la literatura revisada es que un trabajo que reporte alfa persistente sobre un índice amplio está

afirmando, implícitamente, que ese alfa lo pagó otro participante. Es la razón de fondo por la que la replicación encuentra tanta caída fuera de muestra: una anomalía publicada deja de ser una ventaja informativa en cuanto el resto del mercado puede explotarla.

2.2. Sesgos que condicionan cualquier evidencia

El *lookahead bias* aparece cuando una variable incorpora información que no era conocida en la fecha de decisión. En fundamentales, usar la fecha de cierre fiscal en lugar de la fecha de filing es un ejemplo clásico: el trimestre puede haber terminado, pero sus resultados no se publicaron aún. El sesgo de supervivencia surge cuando se usa la composición actual de un índice para describir el pasado; se eliminan así empresas que salieron del universo y se exagera la calidad de la muestra (Brown et al., 1992).

El *data snooping* es distinto: incluso con datos perfectamente cerrados, probar muchas alternativas incrementa la probabilidad de encontrar una aparente ganadora. Harvey et al. (2016) alertan del gran número de factores propuestos y de la necesidad de elevar el estándar de evidencia, y de ahí salen las correcciones que este trabajo emplea —el Deflated Sharpe Ratio de Bailey y López de Prado (2014)— y las que formalizan la misma preocupación por otras vías: el *Reality Check* de White (2000), el test de capacidad predictiva superior de Hansen (2005) o la probabilidad de sobreajuste del backtest de Bailey et al. (2017). Ninguna reconstruye una hipótesis verdaderamente previa después de observar los datos, y por eso el catálogo cerrado, el registro de decisiones y la era reservada cumplen una función que ningún p -valor sustituye.

El sesgo de supervivencia tampoco se reduce a incluir o excluir empresas quebradas. Shumway (1997) mostró que omitir retornos de exclusión puede distorsionar la medición. En este proyecto el problema adopta otra forma: la pertenencia histórica se conoce, pero el proveedor gratuito deja de servir precios de numerosos símbolos retirados. El universo correcto y el panel observable son, por tanto, dos poblaciones diferentes. Esta distinción justifica que la cobertura se mida contra los miembros reales del índice y no contra las filas que el propio pipeline consiguió construir.

2.3. Medir la señal: Rank-IC, amplitud y transferencia

2.3.1. Por qué la métrica es una correlación de rangos

La métrica que selecciona el sistema es la correlación de rangos, no el error de una predicción puntual. El motivo es práctico: para elegir acciones importa más acertar cuál de dos empresas irá mejor que estimar con precisión cuánto rendirá cada una. Tiene además una propiedad cómoda: si un modelo cambia de escala pero conserva el orden, la cifra no se mueve.

Una sola cifra, eso sí, no basta. Junto a ella se reporta en qué fracción de fechas fue positiva, cuánto varía y su cociente entre media y desviación. Y hay una corrección obligada: como las etiquetas a doce meses se solapan entre fechas consecutivas, el número de observaciones aparenta ser mayor de lo que realmente es, lo que obliga a trabajar por bloques y con errores estándar corregidos.

2.3.2. De la señal a la cartera: la ley fundamental

La literatura de gestión activa distingue la calidad de una señal de la capacidad de aprovecharla, y lo resume en una relación clásica —la ley fundamental de Grinold (1989)— que este trabajo emplea como marco conceptual y no como identidad exacta. Dice que el resultado que un gestor puede alcanzar depende de tres cosas: cómo de buena es su señal, cuántas decisiones independientes puede tomar con ella, y qué parte de esa señal consigue llevar realmente a la cartera.

$$IR \approx IC \times \sqrt{\text{amplitud}} \times TC$$

Clarke et al. (2002) muestran por qué las restricciones reducen ese coeficiente de transferencia: una señal puede contener información que una cartera *long-only*, concentrada o sometida a límites de rotación no consigue expresar. El punto es central en este TFM. El Rank-IC evalúa toda la sección transversal, incluida la mitad inferior que una cartera sin posiciones cortas nunca puede monetizar, mientras que la cartera mantiene ocho nombres y puede retenerlos doce meses. El salto entre ambas métricas no es una conversión automática, sino un segundo problema de decisión.

Los costes añaden otra ruptura. Amihud (2002) relaciona iliquidez y retornos, y Novy-Marx y Velikov (2016) muestran que el turnover puede consumir buena parte de las anomalías más intensivas en negociación. Restar una comisión fija al final no basta cuando el coste también debe cambiar la decisión de operar. Por eso esta memoria distingue la ruta congelada —qué habría costado ejecutar las mismas órdenes— de la ruta resimulada, en la que un coste mayor eleva los umbrales y puede evitar la operación.

La utilidad de esta descomposición es que separa tres causas de un mal resultado que una cifra de rentabilidad confundiría: que la señal no ordene, que se tomen pocas decisiones independientes o que la cartera no consiga expresar lo que la señal indica. Las tres restricciones de este diseño actúan sobre el tercer término: la cartera es *long-only*, de modo que la mitad de la información que el Rank-IC mide es por construcción inaccesible; mantiene unas pocas posiciones sobre un universo de unos quinientos valores; y paga costes proporcionales a su rotación. De ahí que la métrica de selección sea el Rank-IC y no el CAGR: seleccionar por rentabilidad final confundiría los tres términos, mientras que medir la señal aislada permite atribuir después cuánto pierde la implementación.

La distinción entre calidad de señal e implementación que formula López de Prado (2018) es la que este trabajo adopta como orden de trabajo: primero la señal, después la cartera, y nunca al revés.

Capítulo 3

Diseño de investigación, datos y observabilidad temporal

Antes de presentar ningún modelo hay que responder a una pregunta más básica: qué información existía realmente en cada fecha. De su respuesta depende que la evaluación no conceda al sistema una ventaja imposible —conocer un dato antes de que existiera— y, por tanto, que todo lo que venga después signifique algo.

3.1. Fuentes y universo histórico

3.1.1. De dónde sale cada dato

Ninguna fuente aislada da todo lo necesario para una evaluación temporalmente honesta. Yahoo Finance aporta los precios ajustados con los que se valoran posiciones y se calculan retornos; Finnhub, los ratios y series fundamentales; SEC EDGAR, la fecha en que cada informe se hizo público, que es la que determina cuándo el mercado pudo conocerlo; y el historial de composición del índice, qué empresas eran invertibles en cada instante. SPY interviene sólo como referencia contra la que se mide el exceso y queda excluido de las posiciones, de modo que la cartera nunca puede comprar el índice que intenta batir.

De ahí sale una jerarquía de confianza. Los precios se usan con la última cotización anterior a la observación. Los fundamentales no valen por existir en la descarga: deben tener un periodo y una publicación elegibles. Y los perfiles de empresa, como el sector, nunca entran como señal predictiva. La ausencia de un dato tampoco se interpreta como un cero: se imputa con la mediana del conjunto de entrenamiento disponible y se conserva un indicador de que faltaba, de modo que el modelo pueda aprender que la falta de cobertura es informativa sin recibir una estimación calculada con el futuro.

3.1.2. Un universo que cambia con el tiempo

El universo no es la lista actual del S&P 500. Para cada fecha se consulta qué tickers pertenecían al índice en ese momento y se construye la sección transversal sólo con ellos. Esta decisión evita un sesgo frecuente: usar empresas que sobrevivieron y permanecen hoy en el índice para evaluar periodos en los que otras empresas ya habían sido expulsadas, adquiridas o quebrado. La literatura ha documentado que esta selección puede inflar de forma material las conclusiones de rendimiento (Brown et al., 1992).

La corrección no equivale a eliminar todo sesgo de supervivencia. Las fuentes gratuitas no ofrecen la misma profundidad para firmas retiradas, algunos fundamentales históricos se han restatado y la disponibilidad varía por año. La diferencia es metodológica: el trabajo mide esa cobertura, expone sus huecos y evita tratarlos como si no existieran. Más adelante en este

capítulo, la Figura 3.1 cuantifica qué fracción del índice llega al panel cada año, y la Tabla 3.1 desglosa por qué motivo falta cada uno de los *tickers* ausentes.

Un caso adicional es la reutilización de símbolos: un *ticker* puede corresponder a una empresa histórica y, años después, a otra distinta. CPQ dejó de pertenecer al índice en 2002, pero una serie de precios descargada hoy con ese símbolo no representa necesariamente a Compaq. Unirlas sin comprobar el intervalo de pertenencia fabricaría una historia de precios inexistente, así que el *pipeline* recorta cada serie al periodo en que la empresa estuvo realmente en el índice, con un margen de treinta días para no confundir un desfase administrativo con una empresa distinta.

Conviene separar dos fechas que es fácil confundir. Los precios se descargan desde 1990, mientras que el panel evaluado empieza en 2003. Esa historia adicional no se usa para evaluar nada: sirve para resolver la pertenencia al índice y para alimentar medias móviles, volatilidades y momentum, que necesitan pasado antes de producir su primer valor válido. Ampliar la descarga no mueve, por tanto, el periodo sobre el que se mide el modelo.

3.2. El panel que el modelo evalúa

3.2.1. Ventanas del experimento y cobertura del índice

El modelo necesita historia anterior para entrenarse. Con una ventana móvil de ocho años y primera observación evaluada en 2015, el entrenamiento procede siempre de periodos previos cuyas etiquetas ya cerraron. La ventana de selección va de 2015 a 2024 y contiene 117 cohortes mensuales; los datos de 2025–2026 quedan reservados, según la decisión explicada en el Capítulo 1.

La Figura 3.1 documenta la cobertura año a año desde 2003, incluyendo la historia que alimenta las ventanas móviles de entrenamiento y nunca actúa como cohorte de evaluación.




Figura 3.1: Cobertura real del universo histórico y ventanas del experimento. La serie procede exclusivamente de `data/raw/universe_coverage.json`; selección y reserva se distinguen visualmente, mientras el entrenamiento utiliza ventanas móviles de ocho años.

La *cobertura* es la fracción de los miembros reales del índice que llega al panel, y crece del 49,0 % en 2003 al 99,2 % en 2026. Como el índice ha tenido alrededor de quinientos componentes durante todo el periodo, esa progresión no describe un índice que crece sino una reconstrucción histórica que se degrada cuanto más atrás se mira. Es la única de las dos mediciones de cobertura que habla del sesgo de supervivencia, porque ese sesgo no se manifiesta como filas defectuosas

sino como empresas ausentes; la disponibilidad de variables *dentro* de las filas ya construidas es otra cosa, y se mide más adelante.

Esa ausencia sí es observable, y está medida. El pipeline registra una fila por cada uno de los 1.206 *tickers* que alguna vez pertenecieron al índice, con el motivo por el que entra o no en el panel; la Tabla 3.1 resume ese reparto.

Tabla 3.1: Resolución del universo histórico: por qué falta cada *ticker* ausente.

Motivo	Qué significa	Tickers	% de excluidos
symbol_withdrawn	El proveedor de precios no reconoce el símbolo: lo retiró de su API	207	36,8 %
missing_price	Sin serie de precios observable	168	29,8 %
recycled_ticker	Símbolo reutilizado después por otra empresa	153	27,2 %
no_metric_period_match	Sin fundamentales que casen con el periodo contable	31	5,5 %
missing_cik	Sin identificador CIK con el que resolver la empresa	2	0,4 %
missing_reports	Sin informes en la fuente de fundamentales	2	0,4 %
Total	Tickers del universo que no llegan al panel	563	100,0 %

Sobre los 563 *tickers* del universo histórico que no llegan al panel.

El reparto desmiente la lectura intuitiva. La causa dominante no es la mortalidad empresarial sino la retirada de símbolos por parte del proveedor de precios: el 36,8 % de los ausentes son símbolos que su API ya no reconoce. La mortalidad se mide aparte, por el sufijo Q con el que se marca a una empresa en concurso, y alcanza a 31 de los 563 excluidos, un 5,5 %; que ese porcentaje coincida con el de la última fila de la tabla es una casualidad aritmética y no la misma medición. Un dato adicional lo confirma: los 563 ausentes *sí* tienen fundamentales descargados, de modo que el cuello de botella es exclusivamente el precio y la exclusión no señala empresas sin información contable. El Capítulo 8 recoge la dirección y la magnitud del sesgo que esto introduce.

3.2.2. Dimensión efectiva de la muestra

Cuántas empresas del índice se reconstruyen no dice cuántas observaciones llegan a cada predicción. La Figura 3.2 describe el panel que consume el modelo tras aplicar observabilidad, cierre de etiqueta y requisitos mínimos de precio.

La Tabla 3.2 resume esa dimensión: 60.259 pares acción-snapshot puntuados en 135 fechas mensuales y 606 símbolos distintos. La ventana de selección reúne 51.356 observaciones en 117 snapshots: una cohorte típica contiene 439 acciones, con un intervalo observado de 377 a 489. La reserva añade 8.903 observaciones en 18 snapshots, con una mediana de 494,5 acciones. Esta última cifra no implica dieciocho evaluaciones económicas independientes: por el horizonte a doce meses, al cierre del estudio solo seis cohortes reservadas disponen de retorno realizado completo. La distinción entre *puntuación emitida* y *label cerrado* evita inflar la evidencia reservada.

Tabla 3.2: Dimensión efectiva de la muestra fuera de muestra.

Ventana	Predicciones	Snapshots	Empresas	Cohorte mín./med./máx.	Filas train mín./med./máx.
Selección 2015–2024	51.356	117	573	377 / 439,0 / 489	9.879 / 11.181 / 12.787
Reserva 2025–2026	8.903	18	523	489 / 494,5 / 503	12.863 / 13.050 / 13.236
Total OOS	60.259	135	606	377 / 449,0 / 503	9.879 / 11.412 / 13.236

El panel derecho de la Figura 3.2 mide la segunda cobertura, la de las variables dentro de las filas ya construidas: ronda el 91 % de media, aunque siete series caen por debajo del 80 %.

Muestra realmente evaluada y disponibilidad de sus predictores




Figura 3.2: Tamaño de las cohortes evaluadas y distribución de cobertura de las variables por bloque. El panel izquierdo cuenta acciones efectivamente puntuadas en cada snapshot; el derecho resume disponibilidad dentro de ese panel, no cobertura del índice.

La ausencia no se interpreta como un cero económico, sino que se conserva como indicador y se imputa únicamente con información del corte de entrenamiento.

Hay una tercera medición que conviene añadir, porque acota el problema de cobertura por el lado favorable y no aparece en ninguna de las dos figuras. Una vez construida una fila del panel, ¿es utilizable para puntuar? La respuesta es que sí prácticamente siempre: la fracción de filas usables es del **100 % en todos los años de la serie**, incluido 2003, cuando la cobertura del índice apenas llegaba al 56 %. Dicho de otro modo, el problema de este panel no es que las empresas lleguen incompletas, sino que *faltan empresas enteras*. Es una distinción que importa, porque las dos carencias tienen consecuencias distintas: filas defectuosas degradarían la calidad de cada predicción, mientras que empresas ausentes sesgan la muestra sobre la que se predice. Aquí ocurre lo segundo, y el Capítulo 8 mide en qué dirección.

Conviene además acotar qué significa aquí «más datos». Cada reentrenamiento usa sólo etiquetas ya cerradas de su ventana de ocho años, de unas 9.879 a unas 13.236 filas según la fecha. Esas decenas de miles de filas no son ensayos independientes: las acciones de una misma fecha comparten estado de mercado y las ventanas consecutivas se solapan. Por eso toda la inferencia posterior se agrega por cohorte y por era, en lugar de tratar cada acción-mes como una repetición.

3.2.3. Integridad de la simulación: lo que no ocurrió

Un panel puede estar bien fechado y aun así producir un resultado inflado si la contabilidad de la simulación trata mal los casos difíciles: una empresa que desaparece a mitad de camino, un retorno absurdo que alguien decide corregir, una posición que se liquida sin registrar el coste. Son errores que no lanzan ningún aviso y que producen curvas de patrimonio suaves y creíbles.

El sistema registra una fila por cada posición y fecha —958 en la ventana de selección, sobre 60 empresas— y marca en cada una si hubo exclusión de mercado, si el retorno se neutralizó por

anómalo y si la posición se liquidó de forma forzosa. **Las tres marcas están a cero en las 958 filas**, y el retorno aplicado coincide exactamente con el retorno bruto en todas ellas: ninguna intervención, ningún ajuste manual. El peor retorno de una posición individual, un $-38,8\%$ en octubre de 2023, se aplicó tal cual.

Conviene leer ese resultado por lo que es, porque admite una lectura demasiado favorable. Que ninguna posición de la cartera sufriera una exclusión no significa que el sesgo de supervivencia esté resuelto: significa lo contrario de lo que parece. Las empresas que desaparecieron del universo nunca llegaron a estar disponibles para comprarlas, precisamente por el problema de cobertura que documenta el Capítulo 8. Lo que estas 958 filas descartan es un error de contabilidad, no un sesgo de selección.

3.2.4. Identidad y trazabilidad del panel

El panel se materializa una vez bajo una identidad que resume fuentes, rango temporal, universo, cadencia, horizonte, retardo de observación y versiones de transformación. Si cualquiera de esos elementos cambia, se crea un panel distinto. Los resultados no guardan una copia de los datos, sino esa referencia, y la clave con la que se recupera una evaluación en caché incluye la identidad del panel: sin esa condición, dos estudios con parámetros iguales pero datos distintos podrían compartir resultado por error. No es un detalle administrativo, sino lo que impide que una métrica calculada sobre un panel se atribuya a otro. Los identificadores concretos figuran en el Anexo A, junto a las rutas de los artefactos que alimentan cada tabla y cada figura.

3.3. Observabilidad temporal: qué se sabía y cuándo

3.3.1. Qué puede verse y cuándo se mira

Dos mecanismos distintos gobiernan qué información llega a una decisión, y no conviene confundirlos porque responden a preguntas diferentes: uno decide *qué* puede verse, y el otro *cuándo* se mira.

Qué puede verse: el filtro por fecha de publicación. En cada fecha de observación t el sistema sólo puede usar el último informe cuya fecha real de publicación en SEC EDGAR, t_{filed} , sea anterior o igual a t . No es un supuesto sobre cuánto suelen tardar las empresas: es un filtro sobre la fecha que EDGAR registra para cada documento. Si un informe se hizo público el 28 de febrero, para el sistema no existe ni un día antes, por mucho que el trimestre al que se refiere hubiera terminado dos meses atrás. Este filtro no tiene ningún parámetro que ajustar, y es lo que impide el *lookahead bias*. La etiqueta obedece a la misma lógica en el otro extremo: el horizonte h sirve para construir el retorno futuro, y esa etiqueta no entra en ningún ajuste hasta que su fecha de cierre ha pasado.

Cuándo se mira: el retardo de observación. El sistema no observa el mercado el último día de cada mes, sino sesenta días después. Ese retardo sí es una variable del catálogo, que ofrecía treinta, cuarenta y cinco o sesenta días. Su papel no es proteger de la fuga temporal —de eso se encarga el filtro anterior— sino fijar el día en que se mira: observar tarde hace que la mayoría de los informes del trimestre ya se hayan publicado, de modo que la sección transversal llega más completa y una empresa que publica pronto no obtiene ventaja de calendario sobre otra que publica tarde. Al ser la opción conservadora, el protocolo prefiere el retardo mayor incluso cuando la evidencia no distingue entre los tres.

La Figura 3.3 ordena las fechas que intervienen.

La implementación aplica ese filtro antes de construir las variables, y un conjunto de pruebas automáticas verifica que se cumpla; el final de este capítulo las enumera.




Figura 3.3: Las fechas que intervienen en una decisión. El retardo de observación separa el fin de mes del día en que se mira el mercado; sólo puede usarse lo publicado antes de ese día, y el retorno futuro se reserva como etiqueta.

3.3.2. De un cierre contable a una señal invertible

Una fecha de cierre fiscal no es una fecha de disponibilidad. Una empresa puede cerrar su trimestre el 31 de diciembre y publicar su informe semanas o meses después; quien construyese una señal el 15 de enero no conocería todavía esa información, aunque hoy una base de datos la muestre asociada al trimestre terminado. Confundir la fecha económica a la que el dato se refiere con la fecha en que se hizo público es el error que el filtro por publicación evita. Un ejemplo con fechas concretas muestra cómo actúan los dos mecanismos a la vez.

Ejemplo 3.1 (Cuándo puede usarse un informe). Una empresa cierra su trimestre el 31 de diciembre de 2019 y publica su informe anual el 28 de febrero de 2020.

En la observación del 30 de enero de 2020 —sesenta días después del cierre de noviembre— ese informe todavía no se había publicado, así que el sistema no puede verlo y utiliza el del trimestre anterior. En la siguiente, el 1 de marzo de 2020 —sesenta días después del cierre de enero—, el informe ya es público y entra en la señal. Ninguna observación anterior al 28 de febrero puede usarlo, por mucho que el trimestre al que se refiere hubiera terminado dos meses antes.

Un procedimiento que fechara el dato por su cierre fiscal lo habría incorporado dos meses antes, en información que ningún inversor tenía. El diseño conserva cada dato hasta que es observable y lo mantiene disponible en observaciones posteriores mediante un relleno hacia delante, nunca hacia atrás.

3.3.3. Cierre de cohortes y ausencia de fuga temporal

El target compara el precio de una acción en el snapshot con el precio de su snapshot futuro a horizonte h , y se expresa como retorno excedente respecto al benchmark. El cálculo usa información futura por definición, pero no constituye lookahead si se limita a la evaluación posterior. Cada fila conserva `label_end_date`; antes de entrenar el meta-agente o medir un diagnóstico se comprueba que esta fecha sea menor o igual que la fecha actual de decisión.

Esta regla tiene una consecuencia práctica importante. En enero de 2015 puede emitirse una puntuación y abrirse una posición, pero su retorno a doce meses no puede enseñar nada al meta-agente hasta enero de 2016, de modo que sus primeras fechas operan sin evidencia con la que ponderar. El Capítulo 4 detalla qué hace el sistema mientras tanto.

Proposición 3.1 (Ausencia de fuga temporal). *Sea $\mathcal{I}_t$ el conjunto de entradas utilizado para generar la señal en la fecha de observación $t = t$. Si cada fundamental $x \in \mathcal{I}_t$ cumple $t_{\text{filed}}(x) \leq t$, si cada precio se obtiene en una fecha no posterior a t , y si cada etiqueta de entrenamiento ha cerrado en t o antes, entonces la señal es medible con la información disponible en t .*

Demostración. Por la primera condición, ningún fundamental de entrada se publicó después de t . Por la segunda, ningún precio usado como predictor es posterior a t . Por la tercera, todos los retornos que intervienen en el ajuste o en la combinación ya han concluido en t . Las transformaciones posteriores —rangos, winsorización y modelos— son funciones de estas entradas, por

lo que tampoco pueden incorporar un dato posterior. En consecuencia, la señal pertenece a la sigma-álgebra de información observable en t . $\square$

El retardo de observación no aparece en el enunciado, y esa ausencia es deliberada: la garantía no depende de él. Retrasar la fecha de observación sólo desplaza t hacia adelante, lo que puede ampliar el conjunto de informes admisibles pero nunca permite ver uno publicado después. La proposición no demuestra que los datos sean perfectos ni que el modelo generalice; demuestra algo anterior, que la evaluación no concede al algoritmo una ventaja imposible.

La disciplina temporal se aplica, por último, en varias capas: la pertenencia al índice se resuelve en cada observación, los precios se unen hacia atrás, los informes se ordenan por publicación y periodo, y las transformaciones que usan historia desplazan el pasado antes de calcular cualquier ventana. Cuatro contratos automáticos lo verifican —pertenencia histórica y fechas de publicación, cierre de etiquetas antes de entrenar, aislamiento de la era reservada y contabilidad coherente con órdenes y costes—, aunque su alcance es limitado: prueban que el código rechaza estados incompatibles con el método declarado, no que la fuente diga la verdad sobre sus fechas, limitación que recoge el Capítulo 8.

3.4. El catálogo de variables y su reparto entre agentes

Las variables que alimentan a los agentes no se eligen a mano ni por conveniencia: el catálogo declara bloques temáticos, cada bloque se asigna a un agente —reparto que detalla el Capítulo 4— y el conjunto que entra en el estudio es una decisión del propio protocolo. Lo que interesa medir aquí es otra cosa: cuánta señal tiene cada variable *por separado*, antes de cualquier modelo.

La respuesta es que muy poca, y ese es justamente el punto. Los Rank-IC univariantes son diminutos frente al 0,1067 del sistema completo: el mayor de todos —los huecos de apertura a un mes— llega a 0,0540, y la mayoría se queda un orden de magnitud por debajo. No es una contradicción, sino el argumento a favor de combinar: ninguna variable aislada ordena el mercado, y la capacidad predictiva aparece al agregar muchas señales débiles. La Tabla B.2, en el Anexo B, recoge los extremos de esa distribución.

Dos observaciones anticipan resultados posteriores. La variable que encabeza la lista es de liquidez de mercado y pertenece al agente de riesgo: la misma que el Capítulo 6 encontrará encabezando su atribución en casi la mitad de las observaciones. Y la que cierra por el extremo negativo es la beta a un año, el candidato obvio si la señal fuese una réplica de la prima de baja volatilidad. Esa jerarquía ya está en los datos antes de cualquier modelo.

Capítulo 4

Sistema de predicción: agentes y meta-agente

La hipótesis de partida no es que una sola familia de ratios domine de forma estable todos los regímenes, sino que distintas vistas económicas del universo aportan información con persistencia desigual. De ahí los cinco agentes especializados —calidad, valor, crecimiento, tendencia y riesgo— y un combinador que aprende a ponderarlos sin saber de antemano cuál será el más útil. El mecanismo y las alternativas que el catálogo ofrece en cada punto se describen a continuación; qué valores se eligieron finalmente depende de una regla de decisión que llega después.

4.1. Arquitectura y aprendizaje *walk-forward*

Cada agente recibe sólo los bloques de variables asignados a su especialidad. El de calidad resume rentabilidad, márgenes, eficiencia y solidez financiera; el de valor utiliza ratios de precio y flujos; el de crecimiento mide aceleración y estabilidad de fundamentales; el de tendencia recoge momentum de precio y de fundamentales; y el de riesgo representa riesgo de precio y liquidez. Esta separación tiene dos fines: conserva interpretabilidad económica y evita que el meta-agente confunda cinco copias del mismo predictor.

En cada fecha de snapshot se ajusta un LightGBM por agente sobre una ventana móvil de ocho años. El catálogo declara la rejilla de hiperparámetros — profundidad, número de estimadores, tasa de aprendizaje y mínimo de observaciones por hoja — y el protocolo del capítulo siguiente decide qué valor toma cada uno. LightGBM permite representar interacciones no lineales sin imponer una forma funcional única (Ke et al., 2017); el entrenamiento temporal evita que el modelo evalúe observaciones que habría visto durante el ajuste.

Las cinco puntuaciones se convierten en rangos transversales y pasan al meta-agente, que estima una Ridge positiva sobre cohortes trimestrales ya cerradas.

Ese «ya cerradas» tiene una consecuencia práctica que conviene ver con cifras, porque explica buena parte del comportamiento del sistema en sus primeros años. Para juzgar a un especialista hace falta saber qué pasó después de que puntuara, y con un horizonte de doce meses eso significa esperar un año. Durante ese tiempo el meta-agente no tiene con qué decidir y reparte pesos iguales de 0,20 entre los cinco. En la serie evaluada, la primera fecha en que llega a aprender un peso propio es **abril de 2016**: el primer año completo opera a ciegas, con la combinación ingenua.


A partir de ahí los pesos se mueven despacio. El cambio medio entre dos fechas consecutivas es de 0,04 sumando los cinco agentes, de modo que el reparto es estable y no salta de un especialista a otro con cada dato nuevo. Al final de la serie ha llegado a un reparto muy concentrado —0,955 para el agente de riesgo— pero el camino hasta ahí ocupa varios años, y ese trayecto no es gratuito: el Capítulo 6 muestra que buena parte de la distancia entre el meta-agente y su mejor especialista se explica precisamente por lo que costó recorrerlo.

No es un defecto de la implementación sino la manifestación correcta de una restricción de información. Un sistema que empezara ponderando desde el primer día estaría usando resultados que en esa fecha nadie conocía.

El catálogo ofrece dos variantes de esa combinación, y elegir entre ellas es una hipótesis de diseño, no un detalle de implementación. La variante **acotada** obliga a que ningún agente pese menos del 10 % ni más del 50 %: representa la idea de que una arquitectura de cinco especialistas sólo tiene sentido si ninguno puede apagar a los demás. La variante **libre** no impone tope alguno, y representa la idea contraria: si un especialista domina de forma consistente, lo correcto es dejar que el procedimiento converja hacia él.

Las dos son defendibles y miden cosas distintas. La acotada protege una propiedad cualitativa del diseño —que sigan siendo cinco agentes— que ninguna métrica del protocolo evalúa; la libre maximiza el criterio que el protocolo sí mide. Por eso la variante figura en el catálogo cerrado como una variable más, y no como una preferencia del autor.

Conviene fijarse en que el meta no ve las puntuaciones sino los *rangos*: es lo que permite combinar agentes cuyas escalas no son comparables entre sí. La Figura 4.1 recorre el camino completo.



cada agente ve sólo su familia de variables
y produce un rango, no una puntuación

Figura 4.1: De las variables al orden final. Cada especialista recibe únicamente las variables de su familia; el meta-agente combina los cinco rangos con pesos que aprende de las cohortes ya cerradas.

4.1.1. Qué predice el modelo

El sistema no aprende a predecir cuánto subirá una acción, sino en qué puesto quedará. Para cada fecha se toma el retorno a doce meses de todas las acciones cuya etiqueta ya puede cerrarse, se ordenan de peor a mejor y se convierte esa posición en un número entre 0 y 1:

$$y_{i,t} = \frac{\text{rank}_{j \in \mathcal{U}_t}(R_{j,t \rightarrow t+12}) - 1}{|\mathcal{U}_t| - 1}.$$

Un valor de 1 identifica la mejor acción de su fecha y un 0 la peor. Aprender el puesto en vez del nivel tiene dos ventajas: alinea el entrenamiento con la métrica que después decide el ganador, y hace al sistema inmune a que un año entero suba o baje. No elimina, en cambio, la dependencia entre acciones que comparten fecha, que es la razón de agregar toda la inferencia por cohorte.

Cada agente a estima una función no lineal $\hat{y}_{i,t}^{(a)} = f_a(X_{i,t}^{(a)}; \theta_{a,t})$, donde $X_{i,t}^{(a)}$ contiene únicamente las variables permitidas a ese especialista y disponibles en t . El subíndice temporal de θ importa: no existe un único árbol ajustado una vez sobre toda la historia, sino una sucesión

de modelos. Una predicción publicada en t queda ligada a la versión entrenada con la última información cerrada antes de t .

4.1.2. Dos relojes que nunca se confunden

La implementación mantiene separados el reloj con el que se emite una señal y el reloj con el que se aprende de ella. En una fecha dada puede puntuarse una empresa con información ya observable, pero esa misma fila no puede entrar en un entrenamiento hasta que transcurran los doce meses que hacen falta para conocer su resultado. Eso impide una fuga menos visible que usar un precio futuro: que una fila reciente, cuyas características se conocen pero cuyo retorno no, intervenga en la selección de variables o en el meta. El cierre de cohortes es por tanto una condición previa del entrenamiento, la poda y la calibración, no una corrección posterior.

4.2. Entrenamiento y combinación de rangos

4.2.1. Cómo se entrena cada especialista

La especialización no asigna una conclusión previa al modelo, sino un vocabulario económico con el que formular hipótesis: el agente de calidad recibe ratios como ROE, ROIC, márgenes o endeudamiento, pero no la regla «ROIC alto implica comprar», que tendría que aprender de la historia disponible. La amplitud de ese vocabulario es también una variable del catálogo, que ofrece un conjunto reducido de bloques o los once disponibles; en ambos casos una poda por estabilidad fuera de muestra limita cuántas variables conserva cada agente. Un conjunto demasiado estrecho amputa información y uno demasiado amplio añade varianza, así que la elección se mide en vez de decidirse a priori.

En cada snapshot el modelo recibe sólo la historia permitida. Si la fecha es abril de 2020 y la ventana es de ocho años, el conjunto comienza aproximadamente en abril de 2012; una fila de finales de 2019 entra sólo si su etiqueta anual ya cerró. El ajuste se repite al avanzar el tiempo. Los hiperparámetros que gobiernan la complejidad del árbol — profundidad, número de estimadores, tasa de aprendizaje y mínimo de observaciones por hoja — controlan cuán específicas pueden ser las interacciones aprendidas, y sus valores no se fijan aquí por criterio general sino con la regla del Capítulo 5.

Los scores se convierten a rangos porcentuales dentro de cada cohorte. Esta operación evita que la escala numérica de un agente domine al resto: si el de riesgo produce valores entre 0,4 y 0,6 y el de valor entre -2 y 3 , ambos pasan a expresar posición relativa en su sección transversal. El meta combina después esos rangos, no sus unidades originales.

Antes del ajuste, los extremos se tratan con reglas declaradas y los valores ausentes se imputan usando únicamente estadísticas obtenidas en el corte de entrenamiento. Una variable no se conserva porque explique retrospectivamente toda la muestra: su disponibilidad y su contribución deben sostenerse en los pliegues temporales permitidos. Con ello, la poda reduce dimensión sin convertir el conjunto reservado en un selector informal. El diccionario completo de variables, direcciones, bloques y agentes figura en el Apéndice B.

4.2.2. Cómo se combinan los cinco rangos

La pregunta que el meta-agente resuelve en cada fecha es sencilla de enunciar: qué combinación de los cinco rangos habría acertado mejor el orden real en las cohortes que ya cerraron. Formalmente, busca los pesos $\mathbf{w}$ que minimizan el error de esa combinación, con un término adicional que penaliza los pesos grandes:

$$\hat{\mathbf{w}}_t = \arg \min_{\mathbf{w}} \sum_{(i,s) \in \mathcal{C}_t} \left(y_{i,s} - w_0 - \sum_{a=1}^5 w_a z_{i,s}^{(a)} \right)^2 + \lambda \|\mathbf{w}\|_2^2,$$

donde $z_{i,t}^{(a)}$ son los cinco rangos y $\mathcal{C}_t$ contiene sólo cohortes cerradas anteriores a t . Los pesos no pueden ser negativos y se normalizan para sumar uno; la variante acotada añade además que ninguno baje de 0,10 ni pase de 0,50.

Ese término de penalización tiene una función concreta: cuando dos agentes dicen cosas parecidas, impide que sus pesos salten bruscamente de uno a otro ante cambios pequeños en los datos. Lo que no puede evitar es que, si un agente resulta consistentemente mejor, la variante libre acabe concentrándose en él. Eso es una hipótesis que el protocolo contrasta, no un defecto a corregir.

Cuando $\mathcal{C}_t$ todavía no tiene la longitud mínima exigida, no se ajusta una regresión frágil. El sistema utiliza el reparto igualitario y registra el estado de arranque. Esta conducta es parte del contrato reproducible: dos ejecuciones con el mismo catálogo y la misma instantánea no pueden decidir de manera distinta si ya existe historia suficiente.

Queda por saber si esa capa de combinación aporta algo o bastaría con quedarse con el mejor de los cinco especialistas. Es una pregunta empírica y no de diseño, así que se responde con los resultados: el Capítulo 6 la contesta comparando el meta aprendido con el reparto equiponderado, y también con cada agente por separado.

4.3. Qué mira cada agente y cómo cambia con el tiempo

Que cada especialista reciba variables distintas no garantiza que acabe usándolas de forma distinta. El sistema guarda, para cada uno de los 45 reentrenamientos, qué peso dio cada agente a cada variable, lo que permite comprobar si la especialización es real o sólo una etiqueta del diseño.




Figura 4.2: Izquierda: número de variables distintas que emplea cada especialista en cada reentrenamiento. Derecha: capacidad de ordenación de cada variable por sí sola frente al peso que el modelo acaba dándole.

El panel izquierdo de la Figura 4.2 confirma que los vocabularios son distintos, y no sólo en contenido sino en amplitud. El agente de calidad reparte su atención entre 29 variables distintas a lo largo de la serie, mientras que el de riesgo se apoya en 12 y el de tendencia en 10. Esa diferencia acompaña a los resultados de la sección anterior, aunque con cinco agentes no puede establecerse una relación causal: el que reparte la atención entre más variables débiles es también el que peor ordena.

El panel derecho responde a una pregunta distinta y más de fondo: **por qué un modelo no lineal y no una fórmula factorial**. Si el sistema estuviera recuperando factores clásicos, las variables con más peso en el modelo serían las que mejor ordenan por sí solas, y los puntos

se alinearían. No ocurre. Buena parte de las variables que más pesan tienen un Rank-IC propio próximo a cero, y alguna que el modelo usa intensamente —la beta a un año— ordena en sentido *contrario* cuando se mira aislada. El modelo no está sumando señales independientes: está aprovechando cómo interactúan.

Esa lectura admite una objeción: que una variable sin capacidad en solitario reciba mucho peso también es compatible con que el modelo esté ajustando ruido. Lo que descarta esa posibilidad no es esta figura sino los contrastes con etiquetas falsificadas del Capítulo 6, que quedan un orden de magnitud por debajo del sistema real.

Conviene delimitar, en todo caso, qué permite afirmar esta arquitectura. Los pesos hacen *atribuible* el resultado a agentes concretos, pero no permiten inferir causalidad: que un especialista reciba peso alto no demuestra que su lectura económica sea la causa del retorno, y puede reflejar interacciones entre variables o límites de los datos disponibles. Por eso el trabajo no se detiene en los pesos y añade después estabilidad por eras, neutralización por estilo y atribución local dentro de cada agente.

Un ejemplo aritmético muestra qué está en juego entre las dos variantes.

Ejemplo 4.1 (De cinco rangos a una puntuación). Una empresa queda en el percentil 0,80 de calidad, 0,55 de valor, 0,70 de crecimiento, 0,45 de tendencia y 0,90 de riesgo. En el arranque, con pesos iguales, su puntuación es $(0,80 + 0,55 + 0,70 + 0,45 + 0,90)/5 = 0,68$: algo por encima de la mediana del universo, sin que ninguna de sus cinco vistas pese más que otra.

Si la evidencia ya cerrada indicase que el agente de riesgo ordena mejor que los demás y el meta le asignara 0,70, repartiendo 0,075 entre los cuatro restantes, la puntuación pasaría a $0,70 \times 0,90 + 0,075 \times (0,80 + 0,55 + 0,70 + 0,45) = 0,82$.

Los percentiles del ejemplo son inventados, pero el cálculo es el real. Con la variante acotada ese peso de 0,70 sería imposible, porque el tope del 50 % limita cuánto puede desplazarse la puntuación hacia el especialista dominante; con la libre nada lo impide mientras la evidencia lo respalde, hasta el extremo de que la puntuación final acabe siendo, en la práctica, la de un solo agente.

Capítulo 5

Protocolo experimental: de la señal a la cartera

Una arquitectura como la del capítulo anterior no produce un sistema hasta que alguien fija el valor de cada una de sus variables. Esos valores se eligieron comparando Rank-IC y sin que la rentabilidad observada interviniera en ninguna decisión predictiva, y la ordenación resultante se convierte después en posiciones concretas. Las cifras que aparecen aquí documentan decisiones —qué alternativa se comparó con cuál y qué regla resolvió el empate—; si la señal resultante es real y si se traduce en rentabilidad son preguntas distintas, que responden los dos capítulos siguientes.


5.1. Por qué el protocolo se aplicó tres veces

El protocolo no se ejecutó una vez sino tres, encadenadas, y todas las cifras que siguen son las de la tercera pasada.

El motivo está en cómo funciona la selección secuencial. Las fases se recorren en orden y cada una parte de lo que decidió la anterior, así que el resultado depende del punto de partida: la primera variable se elige con todas las demás en su valor por defecto, y ya no se revisa aunque las decisiones posteriores cambien el contexto en que aquella elección tenía sentido.

La primera pasada lo dejó claro. Su ganador se apartaba en **nueve variables** del punto de partida del catálogo, de modo que casi todas sus decisiones se habían tomado sobre una configuración que el propio estudio acabó descartando.

La respuesta fue encadenar los estudios, según recoge la Figura 5.1: el ganador de cada pasada se convierte en el punto de partida de la siguiente, que vuelve a recorrer las fases desde ahí. Cada pasada sólo puede mejorar o confirmar, porque el valor vigente se conserva cuando no hay evidencia suficiente para desplazarlo.



cada pasada arranca del ganador de la anterior y vuelve a recorrer las cuatro fases

Figura 5.1: La cadena de tres pasadas. El número de variables que cada una llega a cambiar se reduce de nueve a dos: el procedimiento se queda sin mejoras que hacer, que es la señal para detenerlo.

Esa desaceleración —nueve cambios, luego dos, luego dos— es lo que debe ocurrir si el procedimiento converge en lugar de explorar al azar, y es la razón de detenerse en tres.

Encadenar tiene un coste. Multiplica el número de configuraciones evaluadas sobre la misma ventana, y con ello la probabilidad de que la mejor cifra observada deba parte de su tamaño a la propia búsqueda. La cadena no evita el sobreajuste: lo sistematiza y lo hace visible. Lo que protege al resultado es la era reservada, que no participó en ninguna de las tres pasadas.

5.2. Cómo se elige una configuración

5.2.1. Optimización secuencial por fases

El catálogo cerrado se recorre en cuatro fases: temporal, representación, modelo y meta. Se parte de un *baseline*; en cada fase se modifica una variable y se comparan sus candidatos con el incumbente acumulado. Así, el coste científico es una suma de alternativas, no una búsqueda cartesiana opaca. La pasada de referencia ejecutó 46 configuraciones, y cada una queda registrada junto con la elección que motivó.

5.2.2. Cuándo una alternativa sustituye a la que ya estaba

En cada paso hay una configuración *en el cargo*, el incumbente, y una alternativa que aspira a desplazarla. El procedimiento está deliberadamente sesgado hacia no cambiar: si la evidencia no distingue con holgura entre ambas, se queda la que ya estaba. Cambiar exige demostrar algo; no cambiar, no.

Lo primero que conviene entender es *qué* se compara, porque no son dos promedios. Se compara la misma fecha contra la misma fecha: en cada mes se mide cuánto ordena mejor o peor el candidato que el incumbente, y lo que se juzga es esa serie de diferencias. Así una alternativa no puede ganar por haber acertado un año excepcional que el incumbente no vivió.

Sobre esa serie, un candidato puede ganar de dos maneras.

La primera es **ganar claramente**: su diferencia media es favorable *y* además gana en más de la mitad de los meses. Hacen falta las dos condiciones, porque una media favorable construida sobre menos de la mitad de las fechas no demuestra superioridad: significa que unos pocos meses muy buenos compensaron a muchos malos.

La segunda es **ganar por no ser peor**. Cuando la alternativa es más simple o más conservadora, basta con demostrar que su desventaja plausible es despreciable, es decir, que ni en el peor escenario razonable pierde apenas nada. Prueba que no empeora, no que mejore.

Hay además dos filtros previos que un candidato debe pasar antes de llegar a esa comparación: tener observaciones suficientes y no hundirse en ninguna era disponible, de modo que una configuración que fracasa por completo en un régimen queda excluida aunque su promedio sea favorable.

Y cuando la diferencia es minúscula —por debajo de 0,002— se declara empate técnico y decide una preferencia fijada de antemano hacia la opción más simple o más prudente. Eso no es una medición, y por eso los valores que salen de un empate no se presentan en este trabajo como hallazgos empíricos.

Un caso real del propio estudio muestra por qué la regla mira la serie y no el promedio. La regla de ponderación de variables tenía una alternativa que medía *mejor* —0,1065 frente a 0,1063— y cuya ventaja pareada era incluso positiva. Aun así no ganó: era superior en el 49,6 % de las cohortes, es decir, en menos de la mitad. No superó la puerta de dominancia y el valor vigente se conservó.

Esa disciplina es la garantía que sostiene todo lo demás, y la Figura 5.2 la resume: sólo las cuatro fases predictivas pueden mover al ganador, y todo lo económico ocurre después de congelar la señal.

La Tabla 5.1 hace auditable esa traza. Lo que tabula no es el Rank-IC acumulado tras cada paso —que apenas se mueve, por lo que se explica más abajo— sino **la alternativa que se descartó**: cuánto Rank-IC habría costado adoptarla, ordenado de mayor a menor coste.




Figura 5.2: Las dos mitades del protocolo. Las cuatro fases superiores se deciden por Rank-IC y son las únicas que pueden modificar la configuración; lo que ocurre por debajo trabaja sobre una señal que ya no puede cambiar.

Tabla 5.1: Qué alternativa se rechazó en cada decisión y cuánto habría costado adoptarla.

Variable	Ganador	Mejor alternativa	Su Rank-IC	Coste	Regla
objective	rank regression	ranking	0,0290	-0,0768	Rank-IC robusto
neutralize_by_sector	False	True	0,0549	-0,0514	Rank-IC robusto
feature_preset	all	core	0,0616	-0,0443	Rank-IC robusto
target_horizon_months	12	6	0,0680	-0,0379	Rank-IC robusto
recency_weighting	off	linear	0,0727	-0,0332	Rank-IC robusto
snapshot_step_months	1	3	0,0883	-0,0176	Rank-IC robusto
train_lookback_years	8	12	0,0939	-0,0120	Rank-IC robusto
meta_method	stacked rolling free	stacked rolling bounded	0,0996	-0,0071	Rank-IC robusto
lgbm_max_depth	3	4	0,1013	-0,0050	Rank-IC robusto
lgbm_n_estimators	100	200	0,1013	-0,0050	Rank-IC robusto
fundamental_momentum	True	False	0,1026	-0,0032	Rank-IC robusto
execution_lag_days	60	30	0,1043	-0,0015	Empate: simplicidad
max_features_per_agent	12	20	0,1055	-0,0008	Rank-IC robusto
lgbm_learning_rate	0.03	0.05	0,1063	-0,0004	Empate: simplicidad
market_regime_feature	False	True	0,1059	-0,0004	Empate: simplicidad
lgbm_min_child_samples	20	50	0,1066	-0,0002	Rank-IC robusto
feature_weighting_mode	oos stability prune	model native	0,1065	0,0002	Rank-IC robusto
winsorization	0.0	0.025	0,1068	0,0005	Empate: simplicidad

El coste es el Rank-IC de la mejor alternativa menos el del ganador; un coste *positivo* indica que la alternativa medía mejor y que el ganador se decidió por otra vía, lo que ocurre en dos filas y se comenta más abajo. No debe confundirse con la *ventaja pareada*, que promedia la diferencia cohorte a cohorte: en el método de combinación del meta-agente el coste es $-0,0071$ y la ventaja pareada $+0,00699$.

Leída así, la tabla separa con claridad tres grupos. Cinco decisiones eran caras de equivocarse: cambiar el objetivo de regresión de rango a *ranking* habría costado $-0,0768$ de Rank-IC, neutralizar por sector $-0,0514$, reducir el conjunto de variables a *core* $-0,0443$, acortar el horizonte a seis meses $-0,0379$ y aplicar pesos de recencia $-0,0332$. Son las decisiones estructurales, y las cinco se resolvieron con holgura.

Un segundo grupo, el más numeroso —diez de las dieciocho filas—, tiene costes de 0,005 o menos: los cuatro hiperparámetros del modelo, el retardo de observación, la winsorización, el máximo de variables por agente y la regla que las pondera. Ahí la evidencia apenas distingue entre alternativas, y el resultado merece decirse sin rodeos: **el sistema no debe su capacidad predictiva al ajuste fino del modelo**.

Entre ambos extremos quedan tres decisiones intermedias —la cadencia de observación, la ventana de entrenamiento y la variante del meta-agente—, que también confirmaron el valor que ya traían.

El tercer grupo son las **cuatro** decisiones que la última columna marca como empate técnico:

el retardo de observación, la winsorización, la variable de régimen de mercado y la tasa de aprendizaje. Ninguna de las cuatro puede presentarse como hallazgo empírico, y por eso figuran con su regla al lado.

El dato que resume la pasada es que **dieciséis de las dieciocho decisiones confirmaron su valor de partida**, y las dos que lo cambiaron lo hicieron por márgenes mínimos: la variable de régimen de mercado por no inferioridad, sin demostrar ser mejor, y la tasa de aprendizaje con una ventaja media de tres diezmilésimas. Esa planitud es lo esperable de una cadena que ha convergido —la pasada parte del ganador de la anterior, así que casi todas las variables llegan ya en su mejor valor conocido— y es también una defensa parcial frente a la objeción de sobreajuste: un protocolo que aceptase cualquier mejora aparente habría movido al incumbente muchas más veces, persiguiendo ruido.

Dos filas merecen lectura aparte porque en ellas **el ganador no es el valor que mejor midió**. En la winsorización, la alternativa medía cinco diezmilésimas por encima, la diferencia cayó dentro del empate técnico y se impuso la preferencia por la opción más simple, que aquí es no winsorizar. La otra es la regla de ponderación de variables, ya comentada al presentar la regla de decisión: la alternativa medía mejor en promedio pero ganaba en menos de la mitad de las cohortes.

El catálogo cerrado es lo que hace verificable todo esto. El Anexo B reproduce las treinta y tres variables con su rejilla completa y el valor que tomó el ganador, de modo que puede comprobarse que cada valor final pertenecía a su rejilla declarada y que ninguna variable ajena aparece en la configuración. Doce de esas treinta y tres son de cartera: se ejecutan después de congelar el ganador y no pueden modificarlo.

5.2.3. Por qué la selección predictiva es secuencial

Una búsqueda cartesiana de todos los valores posibles permitiría encontrar combinaciones muy ajustadas a la historia, dificultaría explicar de dónde surge el ganador y multiplicaría las pruebas. El protocolo fija un orden: temporalidad, representación, modelo y meta. Cada fase hereda el incumbent anterior, de modo que una decisión posterior no puede reabrir silenciosamente una elección temporal. Si dos alternativas difieren menos de 0,002 en ventaja pareada, se prefiere la más simple; si tampoco hay evidencia suficiente, se conserva el incumbent.

Ese argumento vale para el plano **predictivo** por dos motivos. El primero es estadístico: la selección predictiva se decide sobre el Rank-IC, la misma magnitud que después se reporta como resultado principal, de modo que cada comparación adicional infla precisamente la cifra que sostiene el trabajo. El segundo es expositivo: una rejilla de miles de puntos devuelve un ganador que nadie puede explicar.

Ninguno de los dos se aplica al plano de la **cartera**, y de ahí que allí el trabajo haga lo contrario. Las reglas de cartera operan sobre una señal ya congelada, así que optimizarlas no puede inflar la métrica predictiva; y su elección no es una escalera de decisiones, sino un problema con interacciones fuertes que el apartado del Portfolio Study desarrolla.

Un ejemplo de cada puerta cierra el mecanismo. La cadencia mensual desplazó a la trimestral por *dominancia*: ventaja media de +0,0136 sobre 40 fechas emparejadas y mejor en el 60 % de ellas, aunque el límite inferior de su intervalo rozaba cero. Un procedimiento que hubiera exigido además un intervalo estrictamente positivo habría conservado la cadencia trimestral, y con ella habría perdido las 117 cohortes mensuales sobre las que descansa el resto del trabajo. En sentido contrario, el horizonte de seis meses fue rechazado con holgura: ventaja pareada de -0,0375 y un intervalo íntegramente negativo.

5.2.4. El coste y el rastro de la búsqueda

Decir que la pasada evaluó cuarenta y seis configuraciones no permite comprobar nada. El sistema guarda por eso un registro con una fila por evaluación, que anota la fase a la que

pertenecía, el valor probado, la métrica que obtuvo, el motivo por el que se adoptó o se rechazó y el tiempo que costó calcularla.

Tabla 5.2: Lo que costó recorrer el catálogo, por fase del protocolo.

Fase	Evaluaciones	Adoptadas	Rank-IC mín.	Rank-IC máx.	Horas
Temporal	17	7	0,0290	0,1059	2,8
Representación	16	7	0,0549	0,1068	3,3
Modelo	12	4	0,0934	0,1067	3,4
Meta-agente	3	1	0,0690	0,1067	0,4
Total	48	19			9,9

Las evaluaciones incluyen al valor vigente de cada comparación, que se mide de nuevo en cada fase; de ahí que sean 48 y no 46.

El reparto de la Tabla 5.2 dice algo sobre dónde se concentró el esfuerzo. Las fases temporal y de representación —las que deciden qué información entra y cómo— suman 33 de las 48 evaluaciones, mientras que la del meta-agente se resuelve con tres. Y el rango de Rank-IC que recorre cada fase es revelador: en la temporal las alternativas van de 0,0290 a 0,1059, un factor de casi cuatro, mientras que en la de modelo apenas se mueven entre 0,0934 y 0,1067. Elegir bien cuándo se mira y qué se mira importa mucho más que afinar los hiperparámetros, que es la misma conclusión a la que llega la traza de decisiones desde otro ángulo.

El registro sirve además para una comprobación que el protocolo necesita. Guarda, para cada candidato rechazado, no sólo su métrica global sino su desglose por era, lo que permite verificar algo incómodo: hubo alternativas que se descartaron por su promedio y que sin embargo habrían ganado en alguna era concreta. Observar el universo cada trimestre en lugar de cada mes, por ejemplo, medía peor en conjunto pero mejor en el primer tramo de la serie. Una regla que hubiera elegido mirando subperiodos habría encontrado siempre algún argumento para casi cualquier valor.

Queda por decir lo que este registro no hace. Documenta la búsqueda; no la exculpa. Las 46 configuraciones distintas que recorrió —las 48 evaluaciones incluyen la remediación del valor vigente, que no añade una alternativa nueva— son exactamente lo que penaliza el Deflated Sharpe del Capítulo 6, y hacer visible el rastro no reduce la multiplicidad: sólo la vuelve contable.

5.3. De la ordenación a las posiciones

5.3.1. De rango a alfa esperado

A partir de aquí el problema cambia de naturaleza: ya no se trata de ordenar mejor, sino de convertir una ordenación en posiciones sin destruir por el camino la ventaja que contiene. El primer paso es que una cartera necesita una magnitud económica, no sólo un puesto en una lista: saber que una acción es la tercera mejor no dice si merece la pena pagar por comprarla. Sobre cohortes ya cerradas se estima por eso una relación entre el tramo del ranking y el retorno excedente anual, usando veinte grupos para que cada tramo conserve suficientes acciones.

Calibración causal y estados de respaldo

En cada fecha de inversión el calibrador sólo mira cohortes cuyo retorno a doce meses ya terminó. Para cada tramo del ranking calcula el exceso medio que se observó, y con esos veinte puntos ajusta una función creciente que traduce posición en alfa esperado:

$$\hat{\alpha}_{i,t} = g_t(\text{rank}_{i,t}).$$

Que la función sea creciente no obliga al mercado a pagar ninguna cantidad concreta. Impone sólo una coherencia mínima: que una acción mejor ordenada no reciba menos alfa esperado que otra peor ordenada. La magnitud sale de la historia cerrada y se expresa en puntos básicos anuales, de modo que los umbrales operativos significan lo mismo aunque cambie el horizonte.

La estimación más local usa cohortes recientes del mismo horizonte; si no hay historia suficiente se amplía a dieciséis trimestres y, si tampoco basta, a todo el histórico cerrado. Sólo cuando ninguna de las tres es viable se activa una salvaguarda fija. Cada observación registra cuál de los cuatro estados empleó, lo que evita mezclar silenciosamente un supuesto con una estimación.

Tabla 5.3: Frecuencia de los estados de calibración por ventana.

Ventana	Fuente de la curva	Snapshots	Peso en la ventana
Selección 2015–2024	Sin calibración	15	12,8 %
Selección 2015–2024	Salvaguarda	6	5,1 %
Selección 2015–2024	Era	24	20,5 %
Selección 2015–2024	Horizonte	72	61,5 %
Reserva 2025–2026	Sin calibración	0	0,0 %
Reserva 2025–2026	Salvaguarda	0	0,0 %
Reserva 2025–2026	Era	0	0,0 %
Reserva 2025–2026	Horizonte	18	100,0 %

El reparto figura en la Tabla 5.3. En selección, 72 de las 117 observaciones usan la estimación del mismo horizonte, 24 amplían a la era, 15 quedan sin calibración empírica suficiente y seis activan la salvaguarda de arranque; en la reserva, las 18 aplican la estimación de horizonte obtenida con historia anterior. El recuento hace visible cuándo el sistema aprendió una escala económica y cuándo operaba con una regla de seguridad.

La calibración no crea información predictiva: dos acciones conservan el orden que les dio el meta-agente, y la curva sólo cuantifica la distancia económica necesaria para compararlas con costes, efectivo y una posición existente. Por eso sus parámetros no participan en la selección por Rank-IC.

5.3.2. Construcción de cartera y precedencia de reglas

Seis variables gobiernan cómo se traduce el ranking en posiciones: cuántas acciones se mantienen a la vez, cómo se reparte el peso entre ellas, cuánto efectivo se tolera, cuánto tiempo debe retenerse una posición antes de poder venderla, por debajo de qué percentil se vende una que ha decaído y cuánta deriva se consiente en los pesos antes de corregirla. El catálogo declara la rejilla de cada una; qué valores toman se decide con el procedimiento de la Sección 5.4.

Las restantes condiciones de simulación sí son constantes del entorno y no se optimizan: comisión de 10 pb, *slippage* de 20 pb y SPY como benchmark, nunca como posición. Los umbrales se expresan en puntos básicos anuales de alfa esperado para poder compararlos entre horizontes. Una rotación requiere que la diferencia esperada cubra el coste de ida y vuelta y un margen de 50 pb; una compra nueva usa histéresis. Estas reglas pretenden preservar señal y controlar rotación, no volver a optimizar el modelo por rentabilidad.

La era 2025–2026 fue aislada antes de aplicar la selección. Sus observaciones no participan ni en los pesos del meta ni en la elección de parámetros; su papel es exclusivamente de confirmación posterior.

Precedencia de las reglas operativas

Las seis variables no se aplican como filtros independientes: en cada rebalanceo hay una precedencia explícita que impide contradicciones, y la Figura 5.3 la recoge.




Figura 5.3: Orden en que la cartera decide. El tiempo mínimo en cartera se comprueba antes que la economía de la venta, y ninguna posición se vende si no hay un destino mejor después de costes.

Esa jerarquía aclara una diferencia importante: la permanencia mínima puede impedir cualquier venta, mientras que el suelo de cobertura o un alfa negativo sólo convierten una posición en candidata a venderse. Incluso entonces debe existir un destino mejor después de costes. El índice no puede ser ese destino, porque sólo actúa como referencia; el efectivo sí, pero dentro de su tope.

5.3.3. Ejemplo de decisión y coste

Ejemplo 5.1 (Cuándo se rota y cuándo no). Con horizonte de doce meses, comisión de 10 pb y *slippage* de 20 pb, una rotación completa — vender una posición y comprar otra — cuesta 60 pb. Si la peor posición tuviese alfa esperado 60 pb, una candidata externa 250 pb y el margen de rotación fuese 50 pb, la mejora de 190 pb superaría los 110 pb exigidos entre coste y margen, y se rotaría. Si la candidata ofreciese 150 pb, la mejora de 90 pb no cubriría esos 110 pb y se conservaría la posición.

El ranking ordena preferencias; operar exige además una ventaja neta. Las cifras del ejemplo son inventadas —los costes sí son los de la simulación, pero los alfas no proceden de ninguna medición— y la regla que ilustran es la que gobierna toda la rotación de la cartera. El efectivo, por su parte, no se remunera, y una plaza sólo puede quedarse en caja dentro del tope declarado: si ese tope es cero, debe reinvertirse necesariamente.

5.4. El Portfolio Study: optimizar la cartera sin tocar la señal

Elegir esas seis variables por su rentabilidad conocida parecería contradecir la regla que gobierna el protocolo, pero no lo hace. Lo que la regla protege es la *métrica predictiva*: si se elige una configuración porque su Rank-IC es alto y luego se reporta ese mismo Rank-IC, la cifra está inflada por la búsqueda. Las reglas de cartera no participan de ese circuito, porque operan sobre una señal congelada y no pueden modificar el Rank-IC. Lo que sí hay que proteger es la era reservada, y eso se consigue por construcción.

De ahí el *Portfolio Study*. Toma el ganador del último Model Study, no reentrena nada y recorre el producto cartesiano de las seis variables midiendo cada combinación sobre una serie **recortada en 2024**. La distinción es fina y decisiva: no se trata de calcular el resultado de cada cartera en la era reservada y luego ignorarlo —si existiera, bastaría con mirarlo— sino de que ese resultado *no llega a calcularse*. Sólo la ganadora, ya elegida, se reevalúa después sobre la serie completa, como comprobación y nunca como criterio.

5.4.1. Qué es el Information Ratio y por qué se optimiza éste

El criterio de selección deja de ser el exceso geométrico y pasa a ser el *Information Ratio*: el exceso medio sobre el índice dividido por la volatilidad de ese exceso. Premia la **consistencia**,

no el alfa bruto. Una cartera que bate al índice un 2 % todos los años tiene un IR altísimo; otra que alterna +15 % y -11 % puede tener el mismo exceso medio y un IR pésimo. Para un trabajo cuya pregunta es si una señal se sostiene fuera de muestra, la segunda cartera no es equivalente a la primera aunque el promedio coincida, y optimizar por exceso bruto no sabría distinguirlas.

Cada una de las seis mueve ese cociente por una vía distinta, y eso explica la forma de los resultados:

- El **número de posiciones** gobierna el compromiso central. Pocas concentran la señal pero hacen el exceso volátil; muchas lo estabilizan a costa de parecerse al índice, y una cartera que se parece al índice tiene poco exceso que mostrar.
- El **tope de efectivo** amortigua numerador y denominador a la vez: la caja no se remunera, así que sostenerla resta rentabilidad esperada, pero también resta varianza.
- El **reparto de pesos** decide si el peso sigue al alfa esperado o se distribuye por igual. Concentrar en las convicciones altas sube el exceso y la varianza a la vez.
- La **permanencia mínima** reduce fricciones, pero no de forma monótona: retener de más impide corregir cuando la señal cambia de opinión, y ese coste de oportunidad acaba superando al ahorro.
- El **suelo de cobertura** corta la cola inferior del ranking, forzando la venta de lo que cae por debajo del percentil declarado.
- La **tolerancia a la deriva** es pura fricción: no cambia qué se tiene, sino cada cuánto se corrige el peso de lo que ya se tiene.

5.4.2. Por qué cartesiano y no secuencial

Aquí se hace lo contrario que en el plano predictivo, y no por comodidad: las seis variables **interactúan**, de modo que recorrerlas de una en una daría una respuesta que depende del orden en que se pregunte.

El suelo de cobertura lo ilustra bien, porque hace cosas *opuestas* según cuánto efectivo se tolere. Con tope cero, la plaza que deja una posición vendida se recompra necesariamente, así que el suelo funciona como un mecanismo de sustitución. Con tope positivo, esa misma plaza puede quedarse en caja, y entonces el mismo valor pasa a reducir la exposición.

Un ascenso por coordenadas sobre variables así converge a un óptimo local que depende de por dónde se empiece; el cartesiano no. Tiene otro problema, la multiplicidad, que declara el Capítulo 8.

5.4.3. Dos búsquedas y dos multiplicidades

El proyecto contiene dos recuentos que no deben sumarse ni intercambiarse. La pasada predictiva de referencia evaluó 46 configuraciones del Model Study. Esas comparaciones podían afectar qué señal se congelaba y, por tanto, forman el universo de intentos que penaliza la inferencia predictiva y el Deflated Sharpe asociado al resultado económico de esa señal.

El Portfolio Study evaluó 1.440 combinaciones de seis reglas sobre la selección hasta 2024. Es una multiplicidad distinta: la señal, sus pesos y su Rank-IC permanecían idénticos en las 1.440 celdas. Este recuento obliga a tratar el Information Ratio ganador como seleccionado y a reservar 2025–2026 para una única reevaluación, pero no aumenta retrospectivamente el número de modelos predictivos. Mezclar ambos números produciría dos errores: atribuir a la cartera capacidad de elegir el modelo y presentar el máximo de la rejilla como una estimación no condicionada por búsqueda.

La regla de lectura queda así fijada una sola vez. El Capítulo 6 juzga la señal con la multiplicidad de Model Study; el Capítulo 7 interpreta la cartera seleccionada frente a su distribución de 1.440 alternativas y luego mira una sola reserva.

Capítulo 6

Resultados predictivos: qué aprendió el sistema

¿Existe realmente la ordenación que el sistema dice haber aprendido, y resiste los contrastes que tratan de explicarla por azar? Ésa es la primera de las dos preguntas empíricas del trabajo, y la evidencia que sigue es exclusivamente predictiva. Alguna cifra económica aparecerá —ciertos contrastes de robustez se construyen sobre carteras—, pero tiene carácter diagnóstico y se calcula con una cartera distinta de la que el trabajo acaba adoptando.

6.1. La configuración ganadora y la cadena de estudios

6.1.1. Las tres pasadas y su convergencia

Toda la evidencia de este capítulo procede de la última de las tres pasadas encadenadas. Las tres comparten ventana de selección, era reservada y métrica, y se diferencian sólo en su punto de partida; la Tabla 6.1 recoge qué obtuvo cada una.

Tabla 6.1: Las tres pasadas de la cadena y su ganador.

Pasada	Run ganador	Rank-IC	IC-IR	t NW	Transf.	IR sel.	Exceso sel.	IR reserv.
Study 1	run-803c214fd2ac	0,1051	0,844	—	0,130	0,156	1,03 %	-2,348
Study 2	run-95dcffb1640f	0,1059	0,858	—	0,099	0,138	0,74 %	-1,010
Study 3	run-1bb331e23a18	0,1067	0,833	3,33	0,264	0,312	2,12 %	-1,795

Rank-IC, IC-IR y t de Newey–West son de la ventana de selección. «Transf.» es el coeficiente de transferencia introducido en el Capítulo 2: la fracción de la señal disponible que llega a expresarse en posiciones. IR y exceso corresponden a la cartera *por defecto* de cada estudio, no a la optimizada del Capítulo 7.

Dos lecturas condicionan el capítulo. La primera es que la cadena mejoró de forma monótona dentro de la ventana de selección, pero por márgenes cada vez más estrechos —de 0,1051 a 0,1059 y a 0,1067—: son milésimas, y esa pequeñez es en sí misma el resultado, porque la búsqueda se agota y ésa es la señal para detenerla. La segunda es que la era reservada no acompaña, con Information Ratio negativo en las tres pasadas. Conviene no sobreinterpretarlo: esa columna corresponde a la cartera *por defecto* de cada estudio, no a la optimizada, y descansa sobre poco más de un año de datos. Lo que sí deja claro es que ninguna pasada compró su mejora a costa de la era reservada, porque esa era nunca intervino en ninguna decisión.

La Tabla 6.2 muestra en qué sentido convergió: la primera pasada se apartó en nueve variables del punto de partida del catálogo, la segunda cambió dos y la tercera otras dos. Esa desaceleración es lo que justifica detenerse en tres.

Tabla 6.2: Qué cambió cada pasada respecto de su punto de partida.

Pasada	Cambios	Variables modificadas respecto del punto de partida
Study 1	9	commission_bps, coverage_percentile_floor, feature_preset, max_features_per_agent, meta_method, minimum_holding_period, slippage_bps, snapshot_step_months, target_size
Study 2	2	lgbm_min_child_samples, max_features_per_agent
Study 3	2	lgbm_learning_rate, market_regime_feature

Cada pasada se compara con su configuración de partida. El Anexo B reproduce el catálogo completo con el valor final de las treinta y tres variables.

6.1.2. La configuración final, variable a variable

La configuración ganadora observa el mercado cada mes, aprende a ordenar el retorno de los doce meses siguientes, usa el conjunto amplio de variables con un máximo de doce por agente, no neutraliza por sector ni pondera por recencia, y combina a los cinco especialistas con la variante **libre** del meta-agente, sin tope por agente. Esa última elección procede de la primera pasada y gobierna buena parte de lo que sigue; la tercera volvió a compararla con la acotada y la confirmó. La Tabla 6.3 la recoge entera.

Tabla 6.3: La configuración predictiva ganadora, variable a variable.

Etapas del protocolo	Variable	Valor del ganador
Temporal	snapshot_step_months	1
	target_horizon_months	12
	train_lookback_years	8
	execution_lag_days	60
	recency_weighting	off
	objective	rank regression
Representación	feature_preset	all
	fundamental_momentum	True
	market_regime_feature	False
	neutralize_by_sector	False
	winsorization	0.0
	max_features_per_agent	12
	feature_weighting_mode	oos stability prune
	model_family	lightgbm
Modelo	lgbm_max_depth	3
	lgbm_n_estimators	100
	lgbm_learning_rate	0.03
	lgbm_min_child_samples	20
	meta_method	stacked rolling free
Meta-agente	meta_history_quarters	16
	meta_recency_weighting	off

Las veintiuna variables predictivas del catálogo y el valor con el que quedó congelado el sistema. Las doce variables de cartera se omiten aquí porque en esta fase conservaban el valor por defecto: las que el trabajo adopta se deciden después y se presentan en el Capítulo 7. El Anexo B añade, para cada una, la rejilla completa de valores que estaban disponibles y no se eligieron.

6.2. Qué aprendieron los agentes y el meta

El aprendizaje es observable, no una inferencia a partir de la rentabilidad final. Durante los primeros meses el meta reparte 0,20 a cada agente, porque aún no existe ninguna cohorte cerrada con la que juzgar a nadie. En cuanto las hay empieza a ponderar, y el peso se desplaza hacia el agente de riesgo a medida que se cierran más. Al final de la serie el reparto es prácticamente degenerado —0,955 para riesgo y 0,045 para valor, con los otros tres en cero—, de modo que el meta-agente no aprendió a combinar cinco especialistas sino a descartar cuatro.

6.2.1. La trayectoria del peso aprendido




Figura 6.1: Peso medio anual asignado por el meta-agente a cada especialista. 2015 corresponde íntegramente al reparto uniforme por ausencia de cohortes cerradas.

El primer tramo de la Figura 6.1 es el más informativo. En 2015 el reparto es uniforme por construcción. En 2016 el meta concentra en tendencia, que acabará siendo el peor especialista del periodo: es un error, y es exactamente lo que cabe esperar de un sistema que decide con dos años de datos. En 2017 corrige hacia riesgo (0,43 de media anual), en 2018 lo eleva a 0,63 y desde 2020 nunca baja de 0,79, con un máximo de 0,97 en 2023. Que se equivoque primero y se corrija después, sin que nadie intervenga, es la evidencia más directa de que el aprendizaje es real.

Que el reparto acabe así es el resultado esperable del método, no una anomalía: con la variante libre, un especialista que domina de forma consistente acaba absorbiendo el peso. La cadena arrancó de la variante acotada que recomienda el catálogo; fue la primera pasada la que adoptó la libre, y la tercera volvió a medir ambas y la ratificó. Se ganó Rank-IC, por tanto, a costa de que la arquitectura multi-agente quede en la práctica reducida a uno.

El contraste relevante conserva exactamente los mismos cinco agentes y cambia sólo la regla de combinación. En la ventana de selección, el meta aprendido alcanza Rank-IC 0,1067 frente a 0,0690 del promedio equiponderado: una mejora de 0,0377, equivalente al 55 %. La capa de combinación añade, por tanto, información útil y no sólo reescala los scores.

La Tabla 6.4 reúne las siete señales y contiene un resultado que incomoda a la propia arquitectura del trabajo: **el agente de riesgo por separado ordena mejor que el meta-agente**. Su Rank-IC es 0,1201 con IC-IR 0,966 y 81,20 % de cohortes positivas, frente a 0,1067, 0,833 y 76,07 % del meta. La diferencia es pequeña, pero va en la dirección contraria a la que justificaría la complejidad añadida, y no puede achacarse al tope de los pesos: con la variante libre el meta puede concentrarse cuanto quiera y aun así ordena algo peor.

Tabla 6.4: Capacidad predictiva de los agentes y combinadores en 2015–2024.

Señal	Rank-IC	Desv.	Positivas	IC-IR
risk	0,1201	0,1243	81,20 %	0,966
meta_final	0,1067	0,1282	76,07 %	0,833
meta_equal_weight	0,0690	0,1278	62,39 %	0,540
growth	0,0291	0,0867	62,39 %	0,336
value	0,0287	0,0796	63,25 %	0,361
quality	0,0096	0,1062	47,86 %	0,091
momentum	-0,0005	0,0911	49,57 %	-0,006

Desviación e IC-IR se calculan sobre cohortes cerradas de la ventana de selección.

La explicación está en el trayecto. El meta converge hacia riesgo, pero tarda años, y mientras tanto arrastra el peso de agentes que ordenan mucho peor —calidad 0,0096 y tendencia $-0,0005$, ambos indistinguibles de cero—. Ese coste es irre recuperable porque forma parte de lo que significa aprender sin mirar al futuro: la superioridad del agente de riesgo se conoce *a posteriori*, mirando la ventana entera, y elegirlo de antemano no era una opción disponible en 2015.

La lectura honesta, entonces, tiene dos mitades que deben ir juntas. El meta-agente demuestra saber *aprender* de la evidencia —supera con holgura a la combinación ingenua y reproduce casi toda la señal del especialista dominante sin conocerlo de antemano—, pero estos datos no demuestran que combinar aporte más que seleccionar bien. El documento no presenta, por tanto, la arquitectura multi-agente como demostrada.

6.2.2. Qué significa que el meta se concentre casi por completo

Que el peso del agente de riesgo termine rozando la unidad es un resultado ambivalente. Leído a favor, el aprendizaje funciona: el sistema identifica a su mejor especialista en unos dos años, partiendo de la ignorancia, y mantiene esa identificación de forma estable en lugar de oscilar entre candidatos. Leído en contra, la arquitectura multi-agente se vacía de contenido en su propio ganador. Un meta que asigna el 95 % del peso a un único agente ha dejado de ser un combinador para ser un selector.

La variante acotada existía precisamente para evitar este desenlace, y adoptar la libre es un caso claro de decisión que mejora la métrica de selección a costa de una propiedad cualitativa del diseño que ninguna métrica del protocolo estaba midiendo. El riesgo que la restricción cubría sigue existiendo y queda asumido: la señal del sistema es, en la práctica, la del agente de riesgo, de modo que su comportamiento futuro depende de que ese especialista siga funcionando. La era reservada permite una primera comprobación —su Rank-IC se mantiene positivo en $+0,0669$ y el del meta en $+0,0364$ —, pero seis cohortes no bastan para descartar que la concentración sea frágil.

Todas las cifras de este capítulo se miden sobre la ventana de selección —117 cohortes hasta 2024— salvo indicación expresa. Los artefactos guardan además la ventana completa, que añade las cohortes cerradas de la era reservada y produce valores ligeramente menores; ninguna es más correcta que la otra, pero mezclarlas genera discrepancias aparentes.

6.2.3. Qué mira realmente el agente dominante

Saber qué vocabulario recibe cada agente no dice qué hace con él, y eso también es comprobable: el estudio guarda, para cada acción, fecha, agente y variable, cuánto aportó esa variable a la puntuación resultante —1.306.960 contribuciones en total—. La Tabla 6.5 resume las tres de mayor peso en cada agente.

Tabla 6.5: Variables que más contribuyen a la puntuación de cada agente.

Agente	Variable	Contrib. media	Encabeza	Variables distintas
risk	gap_21d	0,0216	47,8 %	12
	range_63d	0,0143	33,7 %	
	max_drawdown_252d	0,0101	2,4 %	
value	pb	0,0151	10,7 %	11
	pfcf	0,0105	27,5 %	
	ev_revenue	0,0086	6,1 %	
growth	cash_conversion	0,0147	65,4 %	11
	roe_trend	0,0089	4,9 %	
	sales_per_share_growth_yoy	0,0079	7,0 %	
quality	asset_turnover	0,0162	30,2 %	28
	fcf_margin	0,0123	28,2 %	
	receivables_turnover	0,0122	2,5 %	
momentum	mom_acceleration	0,0133	33,3 %	10
	mom_volatility	0,0128	18,5 %	
	ma_distance_to_high12	0,0080	12,7 %	

«Contrib. media» es la magnitud media de la contribución local; «Encabeza», la fracción de observaciones en las que esa variable fue la primera por importancia. No se reporta el signo medio porque se cancela entre acciones y no admite lectura direccional.

El resultado más relevante afecta al agente de riesgo, que es el que domina el sistema. La lectura natural sería que reproduce la conocida prima de baja volatilidad, y **los datos no la respaldan**. Las dos variables que mandan son los huecos de apertura a un mes y la amplitud del rango de negociación a tres meses —microestructura del precio a corto plazo—, que juntas encabezan el 81,5 % de las observaciones. Las medidas propias de una estrategia defensiva aparecen después y con mucho menos peso: la máxima caída anual encabeza el 2,4 % y la beta, el candidato más obvio, ni siquiera está entre las tres primeras. El agente no compra acciones defensivas en el sentido factorial clásico: lee la estructura reciente de negociación.

Eso explica por qué la neutralización por catorce controles de estilo, que se presenta más adelante, retiene el 87,21 % de la señal: si el agente dominante replicase el factor de volatilidad, debería destruir mucho más.




Figura 6.2: Variable que encabeza la atribución del agente de riesgo en cada año, como fracción de las observaciones.

La Figura 6.2 añade un matiz sobre esa concentración. Aunque el agente de riesgo acabe recibiendo más del 95 % del peso, no es una apuesta fija: la variable que lo gobierna cambia con el régimen. La amplitud del rango encabeza hasta 2020 —el tramo más turbulento, con un máximo del 66 % en 2019— y luego se desvanece hasta el 1 % en 2024, mientras los huecos de apertura crecen del 25 % al 79 % en ese mismo periodo. El sistema reasigna atención dentro del agente aunque el reparto entre agentes esté congelado, lo que suaviza —sin eliminarla— la objeción de que depender de un único especialista equivalga a depender de un único factor.

La atribución local es descriptiva: dice qué variables movieron la puntuación, no que causen el retorno, y ningún contraste de este capítulo se apoya en ella. Un último dato en la misma dirección: el agente de calidad reparte su atención entre 28 variables distintas —más del doble que tendencia o riesgo— y es a la vez uno de los peores por Rank-IC. Con cinco agentes no hay evidencia causal, pero la asociación sugiere que repartir la atención entre muchas variables débiles ordena peor que concentrarla en unas pocas con contenido.

6.3. Capacidad predictiva fuera de muestra

En la ventana de selección, el sistema alcanza Rank-IC medio 0,1067, IC-IR 0,833, un 76,07 % de cohortes positivas y un estadístico de Newey–West de 3,33.

Esas 117 cohortes mensuales no son, sin embargo, 117 pruebas independientes. Como cada etiqueta tarda doce meses en cerrarse, dos fechas consecutivas comparten once de esos doce meses: miden en gran parte el mismo periodo. El estudio calcula por ello cuántas observaciones verdaderamente independientes contiene la ventana, y el resultado es **nueve**. En la era reservada, donde hay seis cohortes solapadas, esa cuenta baja a **una**. Es la cifra que conviene tener presente cada vez que aparezca un intervalo de confianza en este capítulo: la muestra efectiva es mucho menor de lo que el número de fechas sugiere, y es la razón de que toda la inferencia se agregue por bloques y no por cohorte. La Figura 6.3 muestra la serie cohorte a cohorte, con la era reservada marcada en dorado.



Figura 6.3: Rank-IC por cohorte. La banda dorada identifica la era reservada, que no intervino en ninguna decisión.

¿Es mucho o poco? La referencia justa son fórmulas fijas —las que un inversor podría aplicar sin entrenar ningún modelo—, calculadas sobre el mismo panel y con las mismas restricciones de fecha. La Tabla 6.6 las compara: la mejor, una combinación de crecimiento a precio razonable, obtiene 0,0119, que el sistema aprendido multiplica aproximadamente por nueve. No se sigue de

ahí que los factores clásicos sean inútiles, sino que en este universo una combinación no lineal ordena mejor los retornos futuros que una fórmula fija.

Tabla 6.6: Sistema frente a baselines deterministas.

Señal	Rank-IC	Cohortes positivas
Sistema (meta final)	0,1067	76,07 %
garp_score	0,0119	62,21 %
growth_score	0,0022	51,91 %
momentum_score	-0,0002	52,67 %
quality_score	0,0024	52,29 %
value_score	0,0026	48,85 %

Los baselines no requieren entrenamiento, de modo que se evalúan sobre las 262 cohortes que el panel admite desde 2003; el sistema, que necesita ventana móvil, aporta las 117 de la ventana de selección. La comparación es de nivel de Rank-IC, no sobre la misma ventana.

Esa media de diez años esconde, eso sí, bastante variación: la señal se debilita a la mitad en el régimen intermedio, aunque sin cambiar de signo. Es la razón de reportar series y no una única cifra agregada.

6.3.1. La cola superior frente a la ordenación completa

El Rank-IC resume toda la ordenación, pero la cartera sólo compra el extremo superior, así que hay que comprobar si la ventaja se concentra donde se utiliza. El decil superior bate al universo en las tres eras de selección, de modo que la ventaja no procede sólo de acertar la cola inferior, que una cartera *long-only* no puede explotar.

La era reservada obliga a un matiz. En ella el decil superior obtiene $-11,52\%$ frente al $-2,14\%$ del universo: **pierde contra el panel**, al revés que antes. Y sin embargo la distancia entre el decil superior y el inferior se mantiene en $+6,27$ puntos. Las dos cosas juntas dicen algo preciso: la ordenación siguió separando lo bueno de lo malo, pero el nivel de toda la cola alta cayó por debajo del panel. Que la cartera adoptada batiese al índice en esa era se explica entonces por elegir *dentro* del decil, no porque el decil entero fuese ganador.

Todo lo anterior mira el decil, que son unas cuarenta y cinco acciones. La cartera compra ocho, y ahí aparece el resultado más importante de esta sección: ordenar bien las cuatrocientas y pico acciones de una fecha y acertar en las pocas que efectivamente se compran son cosas mucho menos relacionadas de lo que el Rank-IC sugiere.

La correlación entre ambas magnitudes es de **0,22** sobre las 117 cohortes de selección. Es positiva —ordenar mejor ayuda a comprar mejor— pero está muy lejos de la equivalencia que el Rank-IC podría sugerir. La zona sombreada de la Figura 6.4 contiene el caso incómodo: de las 62 fechas en que el sistema ordenó bien el universo, con un Rank-IC por encima de 0,10, **en dieciséis las diez acciones que compró perdieron dinero** frente al mercado. Una de cada cuatro.

Esa desconexión entre ordenar y cobrar es el puente entre este capítulo y el siguiente, y explica un contraste que de otro modo parecería contradictorio: que la capacidad de ordenar mejore entre eras mientras el resultado económico se deteriora. No son dos mediciones del mismo fenómeno. El Rank-IC premia acertar el orden completo, incluida la mitad inferior que una cartera sin posiciones cortas nunca podrá aprovechar; la cartera sólo cobra por lo que ocurre en las primeras.

La cifra debe leerse con la misma prudencia que el resto del capítulo. Con aproximadamente nueve observaciones independientes efectivas, una correlación de 0,22 no es una estimación precisa: lo que sostiene es la dirección del argumento, no su magnitud exacta.




Figura 6.4: Cada punto es una fecha de decisión: en el eje horizontal, la calidad del orden sobre todo el universo; en el vertical, el exceso que obtuvieron las diez acciones mejor puntuadas.

6.3.2. Estabilidad por eras

Una media agregada puede ocultar que una señal funcionó en un régimen y no en otro. La Tabla 6.7 descompone el Rank-IC de cada señal por era, incluyendo la reservada a título informativo.

Tabla 6.7: Rank-IC medio por señal y era.

Señal	2015-2018	2019-2021	2022-2024	2025-2026
risk	0,1238	0,0577	0,1778	0,0669
meta final	0,0949	0,0543	0,1739	0,0364
meta equal weight	0,0811	0,0184	0,1045	-0,0868
value	0,0205	0,0330	0,0347	-0,1284
growth	0,0493	0,0193	0,0137	-0,1476
quality	0,0018	-0,0110	0,0399	-0,0533
momentum	0,0331	-0,0450	0,0019	-0,0009

Las tres primeras columnas son ventana de selección; la cuarta es la era reservada y no intervino en ninguna decisión.

La tabla contiene tres lecturas que el promedio agregado no permite. La primera es que el agente de riesgo es la única señal positiva en las cuatro eras. La segunda es que el meta aprendido supera al equiponderado en las tres eras de selección, no sólo en promedio, lo que descarta que la mejora del 55 % proceda de un único subperiodo afortunado. La tercera es la más incómoda: en la era reservada los otros cuatro agentes se vuelven negativos a la vez —el de crecimiento llega a $-0,1476$ — y sólo el de riesgo aguanta en positivo, con $0,0669$. El meta conserva un Rank-IC de $+0,0364$ justamente porque para entonces ya había concentrado su peso ahí, mientras que la ponderación uniforme cae a $-0,0868$. Es la única era en la que aprender los pesos, en vez de fijarlos de antemano, cambia el signo del resultado.

Que los cuatro se inviertan simultáneamente es informativo: apunta a una rotación de fac-

tores en el mercado y no a un error de signo en un modelo concreto, que afectaría a uno solo. Este mismo patrón fue el que motivó introducir la ponderación por recencia como variable del catálogo, según se documenta en el Anexo D. Debe leerse junto a su advertencia estadística: son seis cohortes cerradas y aproximadamente una observación independiente efectiva, cantidad insuficiente para concluir que la capacidad predictiva se haya degradado.

6.3.3. El orden mejora mientras el pago empeora

Las dos series se mueven en direcciones opuestas a lo largo de la ventana de selección, y separarlas en capítulos distintos sería justamente lo que las haría engañosas. La Figura 6.5 las enfrenta.




Figura 6.5: Rank-IC medio del meta-agente y pago económico era a era, con la cartera por defecto del catálogo. Las dos escalas son distintas a propósito: lo que importa es la dirección de cada serie, no su nivel.

Antes de leer las cifras hay que declarar con qué cartera se miden, porque es determinante: son las de la **cartera por defecto del catálogo**, la que estuvo vigente durante todo el trabajo predictivo, no la que el trabajo acaba adoptando. Con ella, el alfa medio anual acompaña al Information Ratio y no al Rank-IC: +5,78 % en 2015–2018, +2,25 % en 2019–2021 y –2,37 % en 2022–2024.

No es una contradicción, porque cada métrica mide una cosa distinta: el Rank-IC evalúa la calidad del orden transversal y el Information Ratio el pago ajustado por riesgo de operarlo con una cartera concreta, que además penaliza que la señal sea errática de un mes a otro aunque su media suba. El modelo sigue ordenando, e incluso ordena mejor, pero de forma menos constante y sobre una dispersión de retornos que recompensa peor el acierto.

Conviene adelantar, eso sí, que ese deterioro **no es una propiedad de la señal sino de aquella cartera**. Con la que el Capítulo 7 acaba adoptando, la misma señal obtiene un alfa medio de +2,73 % en esa última era y ningún año negativo en toda la ventana. Que dos carteras den signos opuestos sobre la misma ordenación es precisamente el hallazgo de ese capítulo, y la razón de que exista.

Esto tiene una consecuencia directa sobre el sesgo de cobertura. Ese sesgo es máximo en 2015–2018 y mínimo en 2022–2024, así que si estuviera fabricando la capacidad predictiva el Rank-IC debería ser mayor en la primera era y desvanecerse en la última. Ocurre lo contrario, lo que **contradice una explicación simple basada en la cobertura del panel**. No permite afirmar, en cambio, que el resultado *económico* esté libre de ese sesgo: con la cartera por defecto el patrón es el inverso —su alfa decae hacia la era menos sesgada— y sugiere que la rentabilidad

medida se apoyó en los años de peor cobertura. El trabajo se queda con la primera lectura, que sostiene su tesis predictiva, y no la extiende a la segunda.

6.3.4. Qué habría sabido un gestor en cada momento

Todo lo anterior se mide mirando la serie completa, con el resultado ya conocido. Un gestor que hubiera operado este sistema no disponía de esa perspectiva: en cada fecha sólo podía juzgarlo con las cohortes que ya habían cerrado. Preguntar qué habría visto entonces es distinto de preguntar si el sistema funcionó, y la respuesta resulta menos tranquilizadora.




Figura 6.6: Capacidad de ordenación calculada en cada fecha usando sólo la información ya cerrada en ese momento, con dos memorias distintas. La franja marca el tramo en que la memoria corta habría dado un veredicto negativo.

La Figura 6.6 recoge esa lectura con dos memorias. Un gestor que hubiera juzgado el sistema con toda la historia disponible nunca habría visto una cifra negativa: la serie se mueve entre 0,028 y 0,103 durante los ocho años. Pero uno que sólo hubiera mirado los dos últimos años —que es un horizonte de evaluación perfectamente razonable, y el que emplea la mayoría de los comités de inversión— habría visto la señal cruzar a terreno negativo y quedarse ahí **durante doce meses seguidos, entre julio de 2022 y junio de 2023**.

Eso no contradice ningún resultado de este capítulo: la capacidad de ordenación existe y las pruebas adversariales la respaldan. Y tampoco significa que la señal se rompiera, porque no lo hizo; la memoria corta cruza cero en parte por construcción, ya que con menos cohortes la estimación es más ruidosa.

Lo que la figura documenta es otra cosa, y es una advertencia sobre la distancia entre demostrar que un sistema funciona y poder sostenerlo mientras funciona. Un comité que hubiera revisado el sistema a dos años vista habría encontrado doce meses seguidos de lectura negativa —parte ruido del estimador corto, parte una era realmente peor— justo antes del tramo en que mejor ordenó. El juicio que puede hacerse de una señal en tiempo real es bastante más frágil que la señal misma.

6.4. Robustez: aprendizaje y no suerte

La Tabla 6.8 resume ocho contrastes predefinidos. Siete respaldan la capacidad predictiva; el Deflated Sharpe no alcanza su umbral de 0,95. Reportar este último resultado evita convertir

la robustez en una lista selectiva de éxitos: la evidencia de señal y la evidencia de rentabilidad ajustada por multiplicidad no tienen la misma fuerza.

Tabla 6.8: Resumen de contrastes de robustez.

Contraste	Resultado	Veredicto
Permutación	$p = 0,0001$; 9.999 réplicas	Supera
Placebos	Rank-IC entre $-0,0099$ y $0,0042$	Supera
Bootstrap	IC 95 % $[0,0397; 0,1715]$	Supera
Exclusión de eras	Rank-IC entre $0,0769$ y $0,1300$	Supera
Semillas	Rango de Rank-IC $0,0023$	Supera
Aleatorias con riesgo	Percentil 97,3	Supera
Neutralización	Retiene 87,21 % de la señal	Supera
Deflated Sharpe	$0,573 < 0,95$	No supera

Los contrastes de señal no dependen de la cartera; el Deflated Sharpe y las carteras aleatorias, que sí, están calculados sobre la cartera del Model Study.

El test de permutación baraja el retorno futuro dentro de cada cohorte, conservando el calendario y el número de empresas, para responder a una pregunta concreta: ¿puede surgir un Rank-IC como el observado sin ninguna asociación predictiva? Con 9.999 réplicas, ninguna lo alcanza ($p = 0,0001$).

Los cinco placebos de etiqueta atacan otra objeción: conservan la maquinaria completa — variables, agentes, meta y cartera— pero con la etiqueta barajada, de modo que si alguna parte del sistema fabricase señal por sí misma, deberían mostrarlo. Quedan entre $-0,0099$ y $+0,0042$, indistinguibles de cero y un orden de magnitud por debajo del sistema.




Figura 6.7: Intervalos de confianza del Rank-IC por bloques y estabilidad de la media al excluir cada era completa.

El *bootstrap* por bloques y la exclusión de eras, que reúne la Figura 6.7, responden a una tercera objeción: que la media positiva esté dominada por meses correlacionados o por un subperiodo excepcional. Con bloques de doce cohortes —la longitud del horizonte, para no romper la dependencia que el solapamiento induce—, el intervalo al 95 % es $[0,0397; 0,1715]$ y excluye cero; eliminando cualquiera de las tres eras, la media permanece entre $0,0769$ y $0,1300$. El valor más bajo corresponde a excluir 2022–2024, que es la era de mayor señal: el resultado no depende

de ninguna era, pero tampoco es homogéneo entre ellas.

Las tres semillas ensayadas descartan que todo dependa de una inicialización afortunada: el rango de Rank-IC es 0,0023 y ninguna cruza cero. El exceso geométrico tampoco, aunque su rango es amplio en términos relativos —de +0,63 % a +2,12 %—, así que la ordenación es estable pero su traducción a rentabilidad conserva el signo, no la magnitud.

El último contraste enfrenta la cartera a 1.000 carteras aleatorias del mismo tamaño y con los mismos costes. Con riesgo emparejado, el modelo ocupa el percentil 97,3 (CAGR 15,02 % frente a una mediana aleatoria del 8,54 %). En el escenario general baja al percentil 75,0, pero ese nulo no se usa como prueba: su percentil 95 llega al 75,68 %, dominado por carteras que por azar concentraron alguna superviviente extraordinaria, y una distribución con esa cola no es una referencia informativa.

6.4.1. ¿Es la señal una réplica de factores conocidos?

Dos contrastes independientes preguntan lo mismo desde ángulos distintos: ¿es la señal una réplica de estilos ya conocidos?

El primero neutraliza. Los catorce controles cubren las cinco familias que la literatura considera establecidas: cuatro múltiplos de valoración —precio sobre beneficios, sobre valor contable, sobre ventas y valor de empresa sobre EBITDA—, dos medidas de tendencia a doce meses, tres de riesgo —volatilidad a tres y seis meses y beta a un año—, tres de rentabilidad —retorno sobre recursos propios, sobre capital invertido y margen operativo— y dos de crecimiento de beneficios y ventas. Regresando la señal contra ellos y recalculando después el Rank-IC, éste baja de 0,1135 a 0,0990. Conviene declarar de dónde sale ese 0,1135, porque no coincide con el 0,1067 del resto del capítulo: el contraste se calcula sobre las mismas 117 cohortes de selección, pero sólo sobre las filas en que los catorce controles están disponibles, y sobre ese subconjunto el Rank-IC bruto es algo mayor. Lo que importa es que las dos cifras se miden sobre la misma muestra, de modo que su cociente sí es interpretable. La pérdida del 12,79 % indica que parte de la señal comparte información con esos controles, como sería esperable en un sistema que usa ratios económicos; la retención del **87,21 %** muestra que no se agota en ellos.

El segundo, que resume la Figura 6.8 junto al anterior, pregunta lo contrario: si los retornos de la estrategia pueden explicarse como una mezcla de cinco estilos conocidos. La respuesta es que no de forma estable. Esos cinco estilos dan cuenta de apenas el 1,5 % de la variación, ninguna de las exposiciones es distinguible de cero —la mayor es la de calidad— y el exceso que queda sin explicar tampoco alcanza significación por sí solo. Dos factores más, tamaño e inversión, no pueden construirse con las fuentes disponibles y se declaran no replicables en vez de sustituirse por un sucedáneo que nadie podría auditar.

La visualización evita una inferencia que una lista de coeficientes favorece: escoger la carga de mayor valor absoluto y tratarla como exposición demostrada. Todas las barras de incertidumbre cruzan cero. En cambio, la neutralización sí muestra una reducción medible, pero pequeña frente a la señal retenida. La evidencia apunta por tanto a solapamiento parcial, no a identidad factorial ni a independencia completa.

Las dos mitades deben leerse juntas, porque acotan la afirmación por ambos lados: no hay evidencia suficiente para atribuir la señal a un factor clásico, ni tampoco para afirmar que genere alfa por sí misma. La conclusión prudente es que la evidencia es compatible con una señal parcialmente distinta de los factores implementados, no que se haya descubierto una prima nueva y causal.

Conviene precisar el alcance del segundo contraste, porque se calcula sobre la serie de retornos de la cartera de referencia del Model Study, que no es la que el trabajo adopta. Eso lo hace válido para la pregunta que aquí se formula — si la señal se explica por estilos conocidos, algo que no depende de cuántas posiciones se compren — pero no para describir la cartera final, cuyas cifras se presentan íntegramente en el Capítulo 7 desde su propia evidencia.




Figura 6.8: Dos lecturas de solapamiento factorial en selección. Izquierda: cargas y sus intervalos Newey–West; derecha: Rank-IC antes y después de neutralizar catorce controles de estilo.

6.4.2. El contraste que no supera: Deflated Sharpe

El Deflated Sharpe de 0,573, inferior al umbral de 0,95, es la limitación empírica más importante del trabajo. El estadístico corrige el Sharpe observado por el número de configuraciones ensayadas: con 46 evaluaciones detrás y 135 observaciones de retorno, la probabilidad de que el Sharpe medido supere al máximo esperable por azar no llega a seis de cada diez. Dicho sin tecnicismos, la rentabilidad histórica de este trabajo no es distinguible de la que produciría buscar lo bastante entre alternativas razonables.

El recuento de 46 corresponde a la búsqueda predictiva. La Sección 5.4.3 estableció por qué las 1.440 carteras constituyen otra multiplicidad y no se suman a este estadístico; aquí basta aplicar aquella regla al interpretar el resultado.

Este resultado no contradice el test de permutación del Rank-IC: examinan cosas diferentes. El primero limita una afirmación de *rentabilidad ajustada por riesgo*; el segundo apoya que el *ranking* no se comporta como ruido puro. Que uno se debilite mientras el otro se mantiene es exactamente el patrón esperable cuando se busca más, y coincide con lo que muestra la lectura por eras: la evidencia de que el sistema ordena resiste, y la de que ese orden se cobra se encarece.

6.5. Qué queda establecido y qué no

Queda establecido que la ordenación existe. El Rank-IC de 0,1067 con t de Newey–West 3,33 no es un artefacto de la agregación: ninguna de 9.999 permutaciones lo alcanza, los cinco placebos quedan un orden de magnitud por debajo, el intervalo bootstrap excluye cero, la conclusión sobrevive a eliminar cualquier era y las tres semillas coinciden dentro de 0,0023. Y no se agota en controles conocidos: la neutralización por catorce variables de estilo retiene el 87,21 % de la señal, y la atribución local explica por qué.

No queda establecido que la arquitectura multi-agente esté justificada por estos datos: el agente de riesgo aislado ordena mejor que el meta que lo contiene, y el meta acaba asignándole más del 95 % del peso. Tampoco queda establecida ninguna afirmación de rentabilidad ajustada por multiplicidad: el Deflated Sharpe de 0,573 no alcanza su umbral, y encadenar tres estudios ha encarecido esa exigencia en lugar de aliviarla. Y no queda establecido que la señal se mantenga fuera de la ventana de decisión con la fuerza que muestra dentro: en la era reservada el Rank-IC sigue siendo positivo, +0,0364, pero descansa sobre seis cohortes.

Con esto queda contestada la primera pregunta del trabajo. La segunda es independiente y no se deduce de la anterior: si una cartera real puede expresar esa ordenación sin destruirla por el camino. Nada de lo visto hasta aquí la anticipa — el Rank-IC no depende de cuántas posiciones se compren ni de cuánto cueste rotarlas —, y la respuesta resultará depender de esa construcción mucho más de lo que cabría esperar. A ella responde el Capítulo 7.

Capítulo 7

Resultados económicos: cartera, perfiles y confirmación reservada

El capítulo anterior cerró el Objetivo 1: la ordenación aprendida existe y resiste los contrastes que intentan explicarla por azar. Eso no basta para afirmar que sirva de algo. Una señal puede ordenar bien el universo y perder su ventaja al convertirse en posiciones, porque una cartera real no puede comprar la ordenación entera: compra unas pocas acciones, paga costes y rota.

Este capítulo aborda el **Objetivo 2**: si el orden aprendido puede cobrarse frente al índice, y cuánto de esa respuesta depende de las reglas con las que se construye la cartera.

7.1. De la señal a la cartera: qué se optimizó y cómo

Un buen Rank-IC no compra un buen resultado económico. Que el sistema *aprenda* es una afirmación sobre el modelo; que ese aprendizaje *se cobre* lo es sobre un mercado competitivo y de suma cero, donde superar al índice significa ganarle la posición a otro participante. Este capítulo mide qué separa una cosa de la otra, y encuentra que buena parte de esa distancia está en la construcción de cartera.

7.1.1. Tres ventanas y dos carteras

Antes de las cifras hay que fijar dos distinciones que el capítulo respeta sin excepción.

Tres ventanas, tres estatus. En la de *selección* (2015–2024) se tomaron todas las decisiones, así que sus cifras describen el sistema pero están contaminadas por esa selección. La de *confirmación* (2025–2026) no intervino en ninguna, de modo que es honestamente fuera de muestra, pero contiene pocos datos. La *curva completa* mezcla ambos regímenes y sólo sirve para describir la serie.

Dos carteras, no una. Conviven la que el catálogo recomienda —vigente y sin optimizar durante todo el trabajo predictivo, empleada como punto de partida— y la que la rejilla eligió, que es la que el documento adopta. Producen resultados de *signo opuesto* en la era reservada, y ese contraste es la respuesta al Objetivo 2. Toda tabla declara con cuál se calculó.

7.1.2. La rejilla completa: qué reglas mueven el resultado

Que la cartera fuera el punto donde intervenir no era una intuición. La cadena de Model Studies medía qué fracción de la señal llegaba a expresarse en posiciones, y esa fracción se movió de forma irregular —0,130, 0,099 y 0,264—: incluso en el mejor caso, apenas una cuarta parte de lo que el sistema ordenaba llegaba a la cartera. Ahí estaba el margen disponible.

Las 1.440 carteras que siguen son las del Portfolio Study: el producto cartesiano de las seis variables de gestión, medido sobre una serie recortada en 2024 para que ninguna combinación pudiera ver la era reservada. Como todas parten del mismo modelo, la misma señal y el mismo panel, sus diferencias sólo pueden atribuirse a la regla de construcción de cartera. Es un experimento controlado en sentido estricto.




Figura 7.1: Cuánto separa cada variable de cartera el Information Ratio mediano. Cada línea compara el mejor y el peor valor con las otras cinco variables variando libremente.

La Figura 7.1 ordena las seis variables por cuánto importan, y el resultado es desigual. Las dos que gobiernan la exposición separan el Information Ratio de forma decisiva — 0,208 el número de posiciones y 0,139 el tope de efectivo —, la tenencia mínima aporta 0,164 y el suelo de cobertura 0,076. Las dos restantes se mueven por debajo de 0,02: el reparto de pesos (0,005) y la tolerancia de deriva (0,017) son, a efectos del IR, prácticamente indiferentes.

Cada extremo de esas barras resume un *conjunto* de carteras, no una: al fijar una coordenada, las otras cinco siguen variando. Un extremo alto significa que ese valor tiende a funcionar bien acompañado de casi cualquier cosa, no que baste con adoptarlo.

Esa diferencia tiene una consecuencia concreta. Si se eligiera cada variable por su mejor valor marginal se adoptarían un suelo de cobertura de 60 y un reparto equiponderado, y la cartera ganadora usa suelo 0 y reparto proporcional al alfa: acompañado del resto de sus coordenadas, prescindir del filtro funciona mejor, aunque promediando sobre todos los contextos ocurra lo contrario. *Optimizar variable a variable no habría encontrado la cartera ganadora*, y ésta es exactamente la razón por la que esta búsqueda es cartesiana.

La nube de la Figura 7.2 deja ver de entrada que el Information Ratio no es una función de la rotación: para casi cualquier nivel de turnover existen carteras buenas y carteras mediocres, de modo que rotar poco no es en sí mismo una virtud ni rotar mucho un defecto. Lo que sí separa la nube con claridad es el tope de efectivo, cuya banda superior se agrupa en los topes bajos. Las dos figuras son por tanto complementarias: la anterior dice qué regla importa, y ésta dónde cae la ganadora dentro de todo lo que era alcanzable.

7.1.3. Dónde cae la cartera adoptada entre todas las evaluadas

Antes de mirar la ganadora conviene responder a la objeción más natural que suscita elegir la mejor de mil cuatrocientas cuarenta: ¿cuánto de este resultado depende de haber dado con la combinación afortunada? La rejilla guarda trece métricas de cada cartera, y compararlas permite




Figura 7.2: Las carteras evaluadas en el plano rotación–Information Ratio. Cada punto es una cartera completa, con las seis coordenadas fijadas a la vez; el color codifica el tope de efectivo y el círculo negro señala la ganadora.

contestar.

Tabla 7.1: La cartera adoptada frente a la distribución de las 1.440 evaluadas.

Métrica	Mínimo	Mediana	Máximo	Cartera adoptada
Information Ratio	-0,165	0,202	0,841	0,841
Exceso geométrico	-1,36 %	0,98 %	5,91 %	5,91 %
Máxima caída	18,92 %	24,55 %	29,51 %	22,83 %
Rotación anual	1,20	2,64	6,36	1,35
Coste acumulado	3,52 %	7,71 %	18,60 %	3,94 %
Años que batan	30 %	60 %	100 %	100 %

Todas las cifras se miden sobre la ventana de selección, que es donde se comparó la rejilla.

El dato más tranquilizador no está en la tabla sino en el recuento: **el 88,3 % de las carteras evaluadas obtiene un Information Ratio positivo**. La señal produce un resultado mejor que el índice con casi cualquier regla de gestión razonable, y no sólo con la que se eligió: lo que la elección aporta es magnitud, no signo.

Conviene ver también esa magnitud, porque «positivo» no significa «apreciable». La cartera mediana de la rejilla se queda en un exceso del 0,98 % anual con un Information Ratio de 0,202, que es poco más que ruido. Que la señal casi nunca destruya valor es una cosa; que llegue a ser rentable depende de las reglas.

La Tabla 7.1 muestra además que la cartera adoptada no es extrema en todo. Es el máximo en Information Ratio, exceso y años batidos —como corresponde a la ganadora del criterio que la seleccionó— pero en caída máxima queda por debajo de la mediana sin ser la mejor, y su rotación es de las más bajas. El coste acumulado es donde la diferencia se vuelve dramática: entre carteras varía más de cinco veces, del 3,5 al 18,6 %, y la adoptada paga un 3,9 %. Buena parte de lo que separa a una cartera buena de una mediocre no es acertar más, sino gastar menos en intentarlo.

Nada de esto corrige el sesgo de haber elegido el máximo. Que el 88,3 % tenga signo positivo es una afirmación sobre la ventana donde todas se midieron, y el nivel concreto de la ganadora sigue siendo una cota superior optimista. Lo que la dispersión acota es el papel del azar en el *signo* del resultado, no en su tamaño.

7.2. La cartera ganadora y sus resultados

7.2.1. En qué consiste y en qué se diferencia

La cartera elegida concentra en ocho posiciones, reparte el peso en proporción al alfa esperado, tolera hasta un 10 % de efectivo, retiene cada posición un horizonte completo, no aplica suelo de cobertura y deja correr la deriva hasta el 40 % antes de reequilibrar.

Frente a la cartera de partida comparte el número de posiciones y el reparto de pesos, y difiere en tres cosas: reduce el efectivo máximo del 25 % al 10 %, amplía la permanencia mínima de medio horizonte a uno completo y *relaja* la corrección de deriva de 0,25 a 0,40. Que sólo cambien tres reglas es lo que convierte la comparación en un experimento legible.

La Tabla 7.2 enfrenta las dos. Las tres diferencias apuntan en la misma dirección, y ése es el hallazgo de la sección: la cartera ganadora **opera menos**. Mantiene lo que compra durante todo el horizonte de la señal y no persigue la deriva de los pesos, de modo que su rotación cae del 242 % al 135 % anualizado.

Que eso mejore el resultado dice algo concreto: la señal es a doce meses, y la maquinaria que la traducía en posiciones la estaba deshaciendo antes de que madurase.

Tabla 7.2: La cartera ganadora frente a la cartera del modelo.

Métrica	Cartera del modelo	Cartera ganadora	Diferencia	Era reservada
Information Ratio	0,312	0,841	0,528	0,109
Exceso geométrico	2,12 %	5,91 %	3,79 %	0,24 %
Rotación anualizada	2,42	1,35	-1,07	0,35
Máxima caída	25,21 %	22,83 %	-2,38 %	16,08 %
Años que baten	70 %	100 %	30 %	50 %

Las dos primeras columnas se miden sobre 2015–2024; la última, sobre la era reservada, que no intervino en la elección.

La mejora en la ventana de selección es grande y era esperable, porque es justo la ventana sobre la que se optimizó: el Information Ratio pasa de 0,312 a 0,841 y el exceso geométrico de 2,12 % a 5,91 %. La cartera ganadora bate al índice en los diez años de la ventana, frente a siete de diez de la cartera del modelo, y lo hace con menos rotación y menos caída máxima. Lo que no era esperable aparece en la última columna.

7.2.2. Selección frente a confirmación

La Figura 7.3 documenta el problema que la optimización de cartera vino a resolver. Con la cartera *por defecto*, las tres pasadas de la cadena mejoran dentro de la ventana de selección pero fracasan fuera: su Information Ratio en la era reservada es negativo en las tres, y la mejor de ellas no bate al índice ni un solo año. Leído así, el trabajo parecería el retrato de un sobreajuste.

El hallazgo del capítulo es que la cartera era el **cuello de botella**. Con la optimizada, la misma señal —sin reentrenar nada ni tocar una sola variable predictiva— deja de perder en la era reservada: exceso de +0,24 % e Information Ratio de +0,109, batiendo al índice en uno de los dos años. La ordenación se mantuvo positiva fuera de muestra; la política original no conseguía convertirla en resultado y rotaba demasiado deprisa para una señal a doce meses.




Figura 7.3: Information Ratio dentro y fuera de la ventana de selección, pasada a pasada de la cadena, con la cartera por defecto del catálogo.

Conviene medir la afirmación por lo que es: se pasa de destruir valor a igualar al índice, no a superarlo con holgura, y un exceso del 0,24 % en 1,41 años no demuestra rentabilidad. Lo demostrado es más modesto y más útil: la conclusión sobre utilidad económica cambia con la cartera aun manteniendo fija la señal. Dos cautelas lo acotan: la era reservada son seis cohortes, de modo que «bate la mitad de los años» significa uno de dos; y la ganadora es la mejor de 1.440, así que su generalización no queda demostrada por un único periodo de confirmación.

7.2.3. Resultados por ventana

Con la cartera ya elegida, la evaluación sobre la serie completa produce las cifras que este apartado desarrolla, separadas por ventana en la Tabla 7.3. Entre 2015 y 2024 la cartera obtiene CAGR 19,86 % frente a 13,17 % de SPY; el exceso geométrico es 5,91 %, el IR 0,841, el máximo *drawdown* 22,83 % y el índice se bate los diez años. El coste acumulado es 3,94 % y el turnover anualizado 134,53 %. Esa última cifra es la que más cambia respecto de la cartera de partida y la que explica buena parte de la mejora: menos rotación es menos fricción pagada por una señal que necesita doce meses para expresarse.

Dos observaciones condicionan la lectura de la tabla. El efectivo medio es **cero en las tres ventanas**: la cartera renuncia por completo a la liquidez, así que su resultado no puede atribuirse a haber estado fuera del mercado en los momentos oportunos, y su exceso procede íntegramente de qué acciones eligió. Y el turnover *cae* en la era reservada, del 135 % al 35 %, no por un cambio de comportamiento sino por la permanencia mínima: con doce meses obligatorios y sólo 1,41 años de serie, buena parte de las posiciones aún no ha podido venderse. Esa cifra describe una ventana demasiado corta para que la regla llegue a expresarse.

La Figura 7.4 muestra que la ventaja no se construye en un salto sino de forma acumulativa, y que el tramo reservado no rompe la trayectoria. El *drawdown* máximo, 22,83 %, es 2,38 puntos *menor* que el de la cartera del modelo pese a que ésta mantenía un colchón de efectivo mayor: la mejora no se compró aceptando más riesgo de caída, y la explicación está en la permanencia mínima, que evita cristalizar caídas transitorias que la versión más activa sí realizaba. Aun así, que la caída de una cartera de ocho nombres sea comparable a la de un índice de quinientos no debe leerse como control de riesgo: es consecuencia de la señal, no de una política de exposición, que el sistema no tiene.

El detalle anual desmiente que el exceso agregado proceda de un año excepcional. La cartera bate al índice en **los diez años** de la ventana de selección, con un alfa medio de 5,77 % y un

Tabla 7.3: Las tres ventanas de evaluación, con su papel declarado.

Métrica	Selección 2015–2024	Confirmación 2025–2026	Curva completa
CAGR de cartera	19,86 %	19,46 %	19,65 %
CAGR de SPY	13,17 %	19,18 %	13,81 %
Exceso geométrico	5,91 %	0,24 %	5,13 %
Information ratio	0,841	0,109	0,691
Máximo drawdown	22,83 %	16,08 %	22,83 %
Años por encima de SPY	100,00 %	50,00 %	91,67 %
Alfa anual media	5,77 %	0,26 %	4,85 %
Peor alfa anual	0,14 %	-4,01 %	-4,01 %
Turnover anualizado	134,53 %	35,01 %	121,26 %
Efectivo medio	0,00 %	0,00 %	0,00 %
Coste acumulado	3,94 %	0,16 %	4,09 %
Periodos	117	18	135

Cifras de la cartera adoptada, no de la que el catálogo recomienda. Selección: se tomaron decisiones sobre ella. Confirmación: reservada, ninguna decisión la utilizó. Curva completa: descriptiva, no probatoria.




Figura 7.4: Patrimonio y drawdown de la cartera ganadora frente a SPY. La región dorada es confirmación reservada, no selección.

Tabla 7.4: Resultado anual de la cartera ganadora.

Año	Cartera	SPY	Alfa	MDD	IR	Efectivo	Turnover
2015	2,56 %	-0,63 %	3,21 %	8,35 %	0,759	0,00 %	100,00 %
2016	11,04 %	10,88 %	0,14 %	5,10 %	0,072	0,00 %	213,87 %
2017	31,89 %	21,71 %	8,37 %	2,03 %	1,935	0,00 %	185,05 %
2018	4,79 %	-5,40 %	10,77 %	14,80 %	1,547	0,00 %	113,91 %
2019	42,97 %	32,05 %	8,26 %	2,62 %	1,099	0,00 %	188,05 %
2020	30,23 %	18,02 %	10,35 %	22,83 %	1,356	0,00 %	185,93 %
2021	40,63 %	29,71 %	8,42 %	2,89 %	0,876	0,00 %	73,63 %
2022	-15,11 %	-18,38 %	4,01 %	14,16 %	0,591	0,00 %	14,61 %
2023	30,23 %	26,18 %	3,21 %	16,88 %	0,390	0,00 %	236,48 %
2024	26,57 %	25,34 %	0,98 %	4,41 %	0,225	0,00 %	0,18 %
2025	23,52 %	18,17 %	4,53 %	16,08 %	0,481	0,00 %	12,84 %
2026	4,08 %	8,43 %	-4,01 %	10,93 %	-0,732	0,00 %	39,68 %

Turnover anualizado; efectivo medio.

peor año de +0,14 %: la distribución está desplazada por completo, no arrastrada por una cola. Batir todos los años es, eso sí, precisamente el tipo de regularidad que una búsqueda amplia tiende a encontrar por construcción, y esta cartera salió de una. El único año adverso de la serie es 2026, ya en la era reservada.

7.3. Por qué el sistema compró lo que compró

Hasta aquí la cartera se ha descrito por sus métricas agregadas. Queda la pregunta que sigue a la curva de patrimonio: qué tuvo dentro y por qué. Todo lo que sigue es **descriptivo** —explica de dónde salió un resultado ya medido, no lo sostiene— y ningún contraste del trabajo se apoya en ello.

7.3.1. Qué tuvo dentro la cartera

La cartera mantuvo exactamente ocho posiciones en los 117 *snapshots* de la ventana de selección, sin una sola desviación y sin efectivo en ninguno de ellos, con un índice de Herfindahl medio de 0,131 — el de una cartera de ocho nombres repartidos de forma razonablemente equilibrada —. Por ella pasaron **42 acciones distintas** en 49 episodios de tenencia.

Ese recuento es en sí mismo un resultado sobre la doctrina de cartera. Con 117 oportunidades de cambiar de opinión y ocho huecos que llenar, una regla que reaccionase a cada *snapshot* habría desfilado por cientos de nombres; ésta se quedó en 42. La permanencia mediana de un episodio es de **15 meses**, la media de 18,1 y la más larga de 45, y *ningún* episodio duró un solo *snapshot*. La tenencia mínima de un horizonte completo, que la rejilla eligió, no es por tanto una etiqueta de la configuración: se lee directamente en la vida de las posiciones.

De dónde salió el resultado

El primer panel de la Figura 7.5 descompone la rentabilidad por nombre. La contribución de una acción suma, periodo a periodo, su peso por su retorno, descontando el coste de las órdenes que la movieron: descompone la rentabilidad *de la cartera*, no su exceso sobre el índice, así que sus cifras no son comparables con el 5,91 % de exceso geométrico.

El reparto es muy desigual. **AAPL aporta 27,8 puntos porcentuales**, un 66 % más que la segunda, y con ORLY, AXP, BA y ROP forma un grupo de cinco nombres que suma algo más de la mitad de lo que aportan las quince mayores. En el otro extremo, la peor posición de diez años pierde 4,2 puntos: la cola izquierda es corta, coherente con una cartera que nunca sufrió una pérdida catastrófica en un nombre.

Qué compró la cartera y dónde se concentró el resultado




Figura 7.5: Qué compró la cartera: contribución concentrada, episodios extremos y exposición sectorial. El sector es una foto actual y sólo tiene valor descriptivo.

Esa concentración es una **limitación, no un mérito**: que una sola acción pese tanto significa que la evidencia económica descansa sobre menos apuestas independientes de lo que sugieren los diez años de serie.

Tabla 7.5: Las diez acciones más presentes en la cartera durante la ventana de selección.

Acción	Meses	Episodios	Peso medio	Peso máx.	Contrib. neta
AAPL	61	2	14,9 %	24,2 %	27,78 %
AZO	48	2	9,8 %	15,3 %	6,08 %
VRSK	46	1	12,8 %	15,1 %	5,87 %
MSFT	41	2	14,5 %	21,5 %	10,09 %
ORLY	40	1	13,7 %	18,0 %	16,76 %
SPGI	39	1	11,5 %	14,7 %	-0,04 %
HLT	35	2	12,6 %	17,7 %	5,44 %
APH	34	1	12,2 %	17,3 %	7,49 %
ORCL	34	1	12,4 %	14,0 %	5,96 %
LH	33	2	12,3 %	15,3 %	2,13 %

«Episodios» cuenta las veces que la acción entró en cartera: dos episodios significan que se vendió y se recompró más tarde. La contribución neta es a la rentabilidad de la cartera, no a su exceso sobre el índice.

Esa descomposición permite además separar lo que una posición ganó de lo que costó mantenerla, y el reparto es revelador. En las posiciones de larga duración el peaje es casi irrelevante: Apple pagó en comisiones y deslizamiento un 1,0 % de lo que aportó en bruto, y Applied Materials un 0,3 %. El coste de operar sólo se vuelve significativo cuando se rota, no cuando se mantiene, que es la contrapartida natural del hallazgo de la sección anterior: sumando todas las posiciones, la fricción se lleva 4,1 puntos frente a los 221 que aporta la cartera en bruto.

La Tabla 7.5 añade un matiz que la figura no da: presencia y contribución no coinciden. VRSK es la tercera por permanencia y aporta 5,9 puntos; SPGI es la sexta y aporta esencialmente cero, mientras que AXP contribuye 12,4 en apenas quince meses. Estar mucho tiempo en cartera no es lo mismo que haber sido una buena posición.

Dónde estuvo invertida

El tercer panel de la Figura 7.5 responde a una pregunta que el sistema nunca se plantea: ninguna variable del catálogo codifica el sector, de modo que el reparto sectorial es una *con-*

secuencia de la señal y no una decisión. En la ventana de selección la cartera se apoya sobre todo en Technology (21,6 % de peso medio), Retail (13,4 %) y Financial Services (11,2 %), un reparto amplio para una cartera de ocho nombres.

En la era reservada el cuadro cambia por completo, y es el dato más incómodo de esta sección. Sólo nueve acciones distintas pasan por la cartera en los 18 *snapshots*, siete de ellas presentes en todos, y el peso se concentra en **dos sectores que suman dos tercios** —Media el 33,9 % y Financial Services el 33,0 %— mientras Technology cae del 21,6 al 2,9 %. La concentración no es una decisión de exposición: es lo que ocurre cuando una serie de año y medio se combina con una permanencia mínima de doce meses, de modo que casi nada llega a rotar.

Ese mismo mecanismo acota lo que la era reservada puede demostrar. Se cerró en ella **una sola operación** —MTCH, con un -28,9 % tras 31 meses, que además subió un 25,2 % en el año siguiente a su venta—, y una única posición, AMAT, aporta 21,3 de los puntos de rentabilidad de la ventana. El exceso del 0,24 % de esa era, que el resto del capítulo trata como su lectura más honesta, descansa por tanto sobre un puñado de nombres y prácticamente ninguna decisión de rotación. Confirma que la señal no se hunde fuera de muestra; no es una muestra del comportamiento de la cartera.

7.3.2. Una venta prematura, y lo que costó

El segundo panel de la Figura 7.5 sitúa en el calendario las operaciones extremas, y una de ellas ilustra mejor que cualquier métrica qué *no* hace la regla de rotación. El sistema compró AZO en agosto de 2016 y la vendió trece meses después con un -21,9 %, desplazada por un candidato mejor. En los doce meses siguientes AZO subió un 26,7 % frente al 6,2 % del índice: la venta costó **19,3 puntos de exceso** que la cartera no llegó a cobrar. Tres años más tarde el sistema volvió a comprar la misma acción y la mantuvo 33 meses para un +113,3 %, de modo que la misma empresa fue la peor y la tercera mejor operación del periodo sin que ninguna regla especial interviniera: sólo la señal cambiando de opinión dos veces.

La lección es que los umbrales de rotación tienen un coste medible en ventas prematuras, y que la permanencia mínima de un horizonte completo —que en 2016 aún no estaba en la configuración— es la mitigación que la rejilla acabó eligiendo. Lo que no puede hacerse es convertir el caso en una regla nueva: se lee con el resultado ya conocido, y añadir un filtro que lo hubiera evitado sería ajustar sobre el resultado.

Dos salvedades acompañan a toda esta sección. El **sector no es *point-in-time***: procede de una foto actual del proveedor de perfiles, así que una empresa que cambió de clasificación aparece con la de hoy en todo el histórico, y sirve para describir pero nunca para atribuir. Y la **cartera es la mejor de 1.440**, de modo que todo lo descrito dentro de la ventana de selección hereda ese sesgo optimista.

7.3.3. Un caso concreto: por qué el sistema compró Apple

Las métricas agregadas dicen que la cartera funcionó; no dicen por qué compró lo que compró. Esta sección reconstruye una decisión completa, la de la acción que más tiempo estuvo en cartera, con los datos que el sistema tenía delante ese día y ninguno posterior.

La decisión. El 30 de octubre de 2019 la cartera vendió Centene y compró Apple. No fue una compra en un hueco vacío: fue una **sustitución**. La regla exige que la ventaja esperada del entrante supere a la del peor de los ocho que ya estaban, y por un margen que cubra el coste de la operación. Apple esperaba un exceso anual de **632 puntos básicos** y Centene, de -150: una diferencia de casi ocho puntos porcentuales, muy por encima del umbral exigido.

Por qué Apple encabezaba el orden. Los cinco especialistas la vieron de forma muy distinta, y el meta-agente había aprendido, con quince cohortes ya cerradas, a quién hacer caso.

La Tabla 7.6 reúne ambas cosas.

Tabla 7.6: Apple el 30 de octubre de 2019: cómo la vio cada agente y cuánto pesaba cada uno.

Agente	Percentil de Apple	Peso del agente
Riesgo	0,998	0,723
Crecimiento	0,950	0,193
Tendencia	0,666	0,084
Valor	0,765	0,000
Calidad	0,456	0,000

Percentiles dentro de su cohorte, de 434 acciones. Los pesos son los que el meta-agente había aprendido en esa fecha con cohortes cerradas anteriores.

La combinación deja a Apple en el percentil 1,000: la primera de las 434 acciones de esa fecha, y también la de mayor alfa esperado del universo. Lo interpretable no es tanto que quedase primera como *por qué*: su nota mediocre en calidad no le costó nada, porque el sistema había aprendido que ese agente no ordenaba bien —su Rank-IC acumulado era de 0,004— y le había retirado todo el peso. Y esos pesos no los eligió nadie: salieron de la evidencia disponible en 2019.

Qué miró el agente decisivo. Dentro del agente de riesgo, que aportaba casi tres cuartas partes de la decisión, la puntuación de Apple se apoya en la amplitud de su rango de negociación a tres meses (+0,038), en los huecos de apertura del último mes (+0,026) y en su iliquidez medida a la Amihud (+0,013). Su volatilidad realizada aporta un orden de magnitud menos. Es la misma lectura que el Capítulo 6 hace de forma agregada, aquí sobre un caso único: el sistema no compró Apple por ser una empresa defensiva, sino por la estructura reciente de su negociación. En calidad, de hecho, casi todas las contribuciones fueron negativas salvo el margen de flujo de caja libre.

Por qué la mantuvo, y por qué la vendió. El sistema no tiene ninguna regla de toma de beneficios. Apple se mantuvo 45 meses seguidos —el episodio más largo de toda la serie, y la razón de que la Tabla 7.5 le sume 65 meses entre sus tres estancias— porque siguió encabezando el orden —volvió al percentil 1,000 en once observaciones posteriores— y porque la permanencia mínima de un horizonte completo impide deshacer una posición antes de que su tesis haya tenido tiempo de cumplirse; su peso llegó a 0,242 en agosto de 2020. Se vendió el 30 de julio de 2023 exactamente por el mismo motivo por el que se compró: su alfa esperado había caído a 283 puntos básicos y otras candidatas la desplazaron. El resultado realizado fue de +228,7 %.

Dos salvedades acompañan al caso, y son las mismas que gobiernan el capítulo. Es la mejor operación de toda la serie y se cuenta con el resultado ya conocido, de modo que ilustra el mecanismo pero no lo valida. Y el reparto de pesos de esa fecha —casi tres cuartas partes en un solo especialista— es la concentración que el capítulo anterior reporta como límite del trabajo, no como virtud: esta decisión salió bien, pero descansaba casi por completo en que un único agente siguiera funcionando.

7.4. Rotación, costes y capacidad

7.4.1. De dónde viene la rotación

Un turnover del 135 % anualizado, aun siendo la mitad del de la cartera de partida, sigue exigiendo explicación: significa que la cartera se renueva entera cada nueve meses para expresar una señal de doce. La Tabla 7.7 lo descompone por motivo declarado de cada orden.

Tabla 7.7: Descomposición del flujo de cartera por motivo de orden.

Motivo de la orden	Órdenes	% del flujo	Coste
net_edge_over_worst	40	36,5 %	3,43
displaced_by_net_edge	40	35,0 %	3,31
rebalance	61	17,6 %	2,18
initial_fill	8	7,3 %	0,30
cash_floor_fill	2	1,8 %	0,25
missing_current_score	2	1,8 %	0,24
Total	153	100,0 %	9,70

Cubre la serie completa: 143 órdenes de la ventana de selección y 10 de la era reservada. El flujo es la suma de $|\Delta w|$ de cada orden y el coste agrega comisión y *slippage* efectivamente cargados.

El desglose revela una fuente dominante y clara: el cambio de opinión de la señal —una acción que sustituye a otra, contabilizada por sus dos caras— concentra el 71,5 % del flujo. El simple ajuste del peso de lo que ya se tiene se queda en el 17,6 %, y el resto son compras iniciales y motivos residuales.

Ese reparto es en sí mismo un resultado. La rejilla eligió la tolerancia a la deriva más laxa disponible, y con ella el reajuste de pesos deja de ser una partida comparable a la rotación para convertirse en una sexta parte de ella: la cartera dejó de gastar dinero en corregir pesos y lo reservó para cambiar de opinión cuando la señal se lo pedía.

Queda entonces una sola fuente relevante, y es estructural: el sistema *re-decide cada mes* sobre una señal cuyo horizonte es de *doce*, así que en cada observación vuelve a comparar sus posiciones con todo el universo y basta una diferencia neta suficiente para ejecutar un intercambio que la señal, a doce meses vista, quizá no habría pedido. La palanca sería observar con menos frecuencia, pero eso es una variable *predictiva*: cambiarla obligaría a rehacer la selección entera. Hay aquí un conflicto real entre dos objetivos legítimos —más cohortes para decidir mejor frente a menos rotación para implementar mejor— que este trabajo documenta sin resolver. La permanencia mínima de un horizonte completo es la mitigación disponible desde el lado de la cartera: no impide que la señal cambie de opinión, sino actuar sobre ese cambio antes de que la tesis original haya tenido tiempo de cumplirse.

Rotación, coste y exceso año a año

La Tabla 7.4 permite comprobar que el turnover no compra rentabilidad. La actividad de la cartera es muy desigual de un año a otro: en 2018 y en 2023 emitió veintidós órdenes, mientras que en 2022 y en 2024 le bastaron dos. Y esos años quietos no son los malos. En 2022, el único año bajista de toda la serie, la cartera batió al índice en cuatro puntos habiendo operado dos veces; en 2023 emitió once veces más órdenes para obtener un exceso menor.

No hay, por tanto, relación monótona entre rotar más y ganar más. Lo que explica esa quietud es la permanencia mínima: cuando la cartera se llena de posiciones recientes, no puede deshacerlas aunque la señal cambie de opinión, y el año transcurre casi sin operaciones. Lo notable es que ese silencio forzado no perjudicó al resultado. El coste acumulado de 3,94 puntos porcentuales frente a un exceso geométrico de 5,91 % no es despreciable — antes de costes la ventaja sería apreciablemente mayor —, pero es un peaje que la cartera paga para expresar la señal, no la fuente de su resultado.

Conviene subrayar el dato de la optimización que apunta en la misma dirección: la cartera ganadora rota *mucho menos* que la del modelo (1,35 frente a 2,42 veces al año) y aun así obtiene 2,7 veces su Information Ratio. La mejora no se compró rotando más, sino justamente lo contrario. Es coherente con lo que muestra la Figura 7.2: en la nube de las 1.440 carteras, las mejores combinaciones no son las más activas.

7.4.2. Cuánto coste soportaría el resultado

Declarar unos costes concretos invita a una objeción legítima: ¿se eligieron benévolos? La respuesta no puede ser una afirmación sino una medición, y consiste en subir el coste hasta que el exceso desaparezca. Con el coste adoptado — 30 puntos básicos por operación entre comisión y *slippage* —, el exceso de la cartera sobre el índice no se agota hasta unos **295 puntos básicos por operación**, es decir, 9,8 veces lo que paga.

Ese cálculo resimula la cartera a cada nivel de coste, de modo que el gestor simulado opera menos a medida que operar se encarece. Es la cifra que el texto cita porque es la *menor* de las dos: si en cambio se congela la ruta de decisiones tomada con el coste real y sólo se recalcula la factura, el equilibrio sube a 447 puntos básicos, 14,9 veces el coste adoptado. La Figura 7.6 muestra las dos familias.

Que la ruta congelada aguante *más* parece contraintuitivo, pero tiene una explicación simple: cada peldaño de la curva resimulada es una cartera distinta, porque al cambiar el coste cambian los umbrales y con ellos las órdenes, y sólo una de esas carteras —la del coste adoptado— fue la que la rejilla eligió. De ahí que la resimulada quede por debajo incluso con coste cero (3,10 % frente a 6,34 %). El texto adopta por eso la lectura conservadora: el margen es de *al menos* 295 puntos básicos por operación.




Figura 7.6: Exceso geométrico frente al coste por operación en selección. Se muestran la ruta congelada y la cartera resimulada, el coste adoptado y sus puntos de equilibrio. La reserva no se mezcla con esta curva porque parte prácticamente sin margen.

Dos salvedades acotan la afirmación. La primera es que ese margen se mide sobre la ventana de selección, donde la cartera es la mejor de 1.440, de modo que el equilibrio hereda ese sesgo optimista. La segunda es más contundente y se reporta por serlo: **en la era reservada prácticamente no hay margen**. Con la ruta congelada, el exceso reservado a coste cero es de apenas 0,35 % y se agota en 94 puntos básicos por operación —3,1 veces el coste adoptado, frente a las 14,9 de la ventana de selección—; y en la variante resimulada ni siquiera puede calcularse un equilibrio, porque a coste cero el exceso ya es negativo. Dicho de otro modo: el resultado reservado empata con el índice y no tiene holgura que gastar en fricción.

7.4.3. Hasta qué patrimonio es ejecutable

Una cartera de ocho posiciones que rota el 135 % anual sólo es realizable si sus órdenes caben en el volumen que negocian esas acciones, y la Figura 7.7 sitúa ese límite. Comparando el notional de cada una de las 143 órdenes de selección con el volumen diario mediano del título, y tomando como referencia el percentil 95 de participación —no la mediana, que escondería las órdenes problemáticas—, la estrategia alcanza un 5 % de participación con **20,3 millones de dólares** de patrimonio y un 10 % con **40,6 millones**.




Figura 7.7: Participación sobre el volumen diario frente al patrimonio gestionado, en escala logarítmica. Los umbrales del 5 % y el 10 % marcan dónde la ejecución deja de ser cómoda.

Ese límite no lo impone la cartera en su conjunto, sino unos pocos nombres poco líquidos. Con un patrimonio de mil millones, la peor orden de News Corporation habría supuesto un **29,6 % del volumen diario** de la acción, porque su volumen mediano ronda los 5,4 millones de dólares; Keurig Dr Pepper llega al 9,8 %. El resto de valores implicados se queda por debajo del 3,2 %. El sistema no elige por liquidez —ninguna variable del catálogo la penaliza al puntuar—, de modo que basta con que dos o tres nombres estrechos entren en la cartera para fijar el techo de todo el conjunto.

Es una limitación de escala, no de validez: acota el resultado al tamaño de un inversor individual o un fondo pequeño, no al de una gestora institucional. Y se lee con dos cautelas: el notional diario es aproximado, y lo que se mide es participación sobre el volumen habitual, no impacto de mercado.

En la era reservada esa cifra sube a 106,5 millones, pero por el mismo artefacto ya descrito para el turnover: con diez órdenes en año y medio, la capacidad aparente crece porque casi no se opera. La que acota este trabajo es la de la ventana de selección.

7.5. Perfiles de inversor y era reservada

7.5.1. Qué es un perfil y qué le pasó a cada estilo

Hasta aquí la cartera ha comprado siempre las mejores acciones según el meta-agente. Un inversor real rara vez opera así: tiene un estilo, y ese estilo le hace preferir unas empresas sobre otras *dentro* de las que su sistema considera buenas. Los ocho perfiles formalizan esa idea y

responden a una pregunta concreta: ¿habría mejorado el resultado alguien que, teniendo esta misma señal y esta misma gestión, la hubiera filtrado según su criterio?

Los perfiles no compitieron en la rejilla del Portfolio Study, y la razón es que no son variables de cartera: un perfil reordena la señal, de modo que opera en el plano predictivo. Meterlos en la rejilla habría equivalido a elegir el estilo de inversor por su rentabilidad conocida. Lo que sí se hace es reevaluar los ocho con la cartera ya ganadora, como diagnóstico; **ningún perfil se selecciona por su Information Ratio.**

Qué es exactamente un perfil

Un perfil no es un modelo distinto ni una cartera distinta: es otra forma de repartir el peso entre los cinco agentes. Y la diferencia decisiva con el sistema del resto del trabajo está en de dónde sale ese reparto.

Conviene precisar qué parte del sistema cambia y cuál no, porque es fácil llevarse una impresión equivocada. **Los cinco agentes siguen siendo los mismos modelos entrenados:** cada uno ha aprendido de la historia disponible cómo ordenar las acciones dentro de su especialidad, y los rangos que produce un perfil salen exactamente de esos modelos. Lo que un perfil cambia no es el aprendizaje de los especialistas, sino **quién decide cuánto pesa cada uno.**

Ahí está la diferencia. El meta-agente **aprende** ese reparto: mira qué especialista viene acertando en las cohortes ya cerradas y lo ajusta fecha a fecha, sin que nadie decida por él. Un perfil lo fija de antemano y no lo revisa nunca: son constantes declaradas antes de ver un solo dato, idénticas durante los diez años.

Lo que los perfiles simulan, por tanto, es a un inversor con criterio propio que emplea las mismas herramientas: alguien que confía en los cinco modelos, pero que decide por convicción hacer más caso al de valor, o al de crecimiento, en lugar de dejar que la evidencia acumulada reparta esa atención. El perfil equilibrado es el único que no impone ese criterio, de modo que **es el único de los ocho que emplea el consenso aprendido;** los otros siete conservan los modelos y sustituyen sólo la regla que los combina.

El mecanismo opera en dos pasos. Primero acota el universo: sólo son elegibles las acciones que el meta-agente sitúa por encima del percentil 60, de modo que ningún perfil puede comprar algo que el sistema considere malo, y todos eligen dentro del mismo conjunto de candidatas. Después reordena ese conjunto con sus pesos fijos, y el resultado sustituye al orden del meta-agente. Los pesos pueden ser *negativos* cuando el estilo apuesta en contra de un agente, como hace el perfil contrario frente a la tendencia; y conviene recordar que en el agente de riesgo un rango alto significa *menos* riesgo, de modo que un peso positivo prioriza baja volatilidad.

Como la reordenación cambia qué acciones se compren, la calibración de percentil a rentabilidad se recalcula sobre el ranking nuevo: de lo contrario el perfil operaría con expectativas referidas a un orden que ya no usa.

Esa asimetría es la que da sentido a la comparación que sigue. No enfrenta ocho sistemas distintos, sino **los mismos cinco modelos combinados de ocho maneras:** siete según una convicción previa y una según la evidencia acumulada. Si aprender el reparto aporta algo por encima de decidirlo a mano, debería notarse justo aquí.

La Figura 7.8 muestra en qué consiste cada inclinación. El perfil equilibrado conserva el orden del meta-agente sin tocarlo; los demás desplazan peso hacia el especialista que da nombre al estilo, y dos de ellos —el de tendencia y el contrario— llegan a asignar pesos negativos, es decir, a preferir explícitamente lo que ese agente coloca abajo.

Qué le pasó a cada estilo

Los ocho perfiles se evalúan con la cartera ya ganadora dentro y fuera de la ventana de selección, y la Figura 7.9 recoge el resultado. La comparación se resume aquí por su conclusión, porque ordenar ocho variantes con sólo seis cohortes reservadas daría una precisión aparente.





Figura 7.8: Peso que cada perfil da a cada especialista. Un peso negativo indica que el estilo apuesta deliberadamente en contra de ese agente.

Perfiles informativos: sensibilidad de la misma señal, no un ranking de estilos



La reserva contiene seis cohortes; los perfiles no participaron en la selección.

Figura 7.9: Resultados informativos de los perfiles: exceso geométrico agregado en selección y reserva, y exceso anual frente a SPY. La separación de 2025–2026 recuerda que los perfiles no se seleccionaron y que la reserva contiene solo seis cohortes; la figura no constituye un ranking fiable de estilos.

El resultado principal es que **ninguno de los siete estilos mejora a la señal sin reordenar**. El perfil equilibrado —que por construcción no impone ningún sesgo— domina la ventana de selección con un Information Ratio de 0,841 frente al 0,342 del siguiente, y un estilo llega incluso a exceso negativo. La ordenación aprendida ya contiene lo que los perfiles intentan imponer desde fuera, y filtrarla según un gusto previo sólo puede quitarle información.

El orden entre ellos, además, no es arbitrario: como un perfil no añade información sino que cambia el peso relativo de la que ya existe, su resultado depende de hacia qué agente lo desplaza. Los que se apoyan en agentes de Rank-IC próximo a cero se quedan pegados al índice, mientras que los que ponderan agentes algo mejores —el de valor, con un Information Ratio de 0,342, y el de crecimiento, con 0,294— conservan parte del exceso dentro de la ventana de selección. Hay incluso un coste operativo visible: el perfil de tendencia rota 1,64 veces al año, la cifra más alta de los ocho, para terminar con un exceso del 0,43 %.

Hay una segunda dimensión que el Information Ratio agrega y conviene separar: cuánto riesgo asumió cada estilo para llegar a su resultado. El perfil de tendencia es el más ilustrativo, porque acumula las dos peores marcas a la vez: la mayor caída máxima de los ocho, un 38,1 % frente al 22,8 % del equilibrado, y la rotación más alta. Pagó más fricción y soportó más riesgo para terminar con un exceso inferior. El perfil de valor le sigue con un 32,8 % de caída. Inclinar la señal hacia un estilo concreto no sólo cuesta rentabilidad: concentra la cartera y la vuelve más volátil.

La era reservada añade una lectura que conviene no forzar. El equilibrado y el de tendencia son los dos únicos que conservan exceso positivo en 2025–2026, mientras que el defensivo y el contrario se hunden por debajo del –15 %.

Lo llamativo es que el de tendencia, que en la ventana de selección acumulaba las dos peores marcas de riesgo, sea uno de los dos que aguantan fuera de ella. Esa aparente contradicción no admite una explicación de fondo: con seis cohortes, quién queda arriba y quién abajo depende demasiado del tramo concreto que tocó medir. Lo que estos datos sostienen no es qué estilo es mejor, sino que el orden entre ellos no se transfiere de una ventana a otra —y por tanto que elegir perfil por su rentabilidad observada no habría servido de nada.

El orden entre estilos no sobrevive fuera de muestra

Los ocho perfiles permiten además una comprobación que el trabajo aplica a sí mismo. Si se ordenan por su resultado en la ventana de selección y se comparan con el que obtienen en la era reservada, **el orden no se conserva**. Sólo dos de los ocho —el equilibrado y el de tendencia— mantienen un exceso positivo fuera de muestra. Los demás caen, y el que más cae es precisamente uno de los que mejor parecían: el perfil defensivo era el cuarto en selección, con un Information Ratio de 0,251, y termina el último de los ocho, con –2,27.

Es la misma lección que sostiene todo el documento, aplicada aquí a la doctrina de inversión en vez de al modelo: un ranking obtenido en la ventana donde se midió no predice el ranking fuera de ella. Y refuerza la decisión de protocolo de no elegir el perfil por su rentabilidad, porque hacerlo habría seleccionado un estilo que fuera de muestra resultó ser el peor.

La cautela de siempre acota lo que puede leerse aquí: seis cohortes no ordenan ocho estrategias. Lo que estos datos permiten afirmar no es que un estilo concreto sea malo, sino algo más débil y más defendible: que el orden entre ellos no se transfiere.

7.5.2. Años adversos y significado de la era reservada

La ventana de selección no deja ningún año con alfa negativo, de modo que el único año adverso de la serie completa es 2026, ya dentro de la era reservada: la cartera sube un 4,08 % frente al 8,43 % del índice, perdiendo 4,01 puntos. Es un año de mercado alcista en el que la cartera participa menos, no un año de caída en el que se hunda más.

Ese matiz importa porque delimita qué tipo de riesgo tiene el sistema. El comportamiento en 2022 — el único año bajista de toda la serie — fue el contrario: la cartera cayó un 15,11 % frente al 18,38 % del índice, batiéndolo por 4,01 puntos. No hay evidencia, por tanto, de que el sistema falle específicamente en las caídas.

Hay detrás una limitación de diseño que merece enunciarse: el sistema decide *qué* comprar, no *cuánto* estar expuesto. La política de efectivo es lo más parecido a una palanca de exposición que tiene, y la cartera ganadora la deja en cero en la práctica. El resultado es una cartera que participa íntegramente de los movimientos del mercado y aspira a superarlos en términos relativos, no a amortiguarlos.

La era reservada ofrece el contraste decisivo del trabajo, y su lectura depende por completo de qué cartera materialice la señal. Con la optimizada, el CAGR es 19,46 % frente a 19,18 % del índice, el exceso geométrico 0,24 % y el Information Ratio 0,109; con la cartera por defecto, la misma señal daba $-1,795$ sin batir al índice ningún año. El Rank-IC de la era, $+0,0364$, es idéntico en ambos casos porque no depende de la cartera: es la señal, y la señal se sostuvo, aunque más débil que en selección.

Su debilidad estadística es considerable —seis cohortes cerradas y aproximadamente una observación independiente efectiva—, y el trabajo no convierte esa combinación en una demostración. Lo que afirma es más modesto: en la única ventana que no participó en ninguna decisión, la ordenación siguió siendo positiva, y su traducción a rentabilidad dependió de la construcción de cartera hasta el punto de cambiar de signo.

7.5.3. Qué se sigue para el diseño de cartera

Este capítulo empezó preguntando si una cartera real puede expresar la ordenación aprendida sin destruirla por el camino. La respuesta es que depende de la cartera, y que la diferencia no es de grado sino de signo: la rejilla evaluó las seis reglas que gobiernan esa traducción sin reabrir la selección predictiva, y encontró una configuración que multiplica por 2,7 el Information Ratio de la ventana de selección y cambia el signo del resultado en la era reservada.

La implicación excede al caso concreto. En este sistema, la construcción de cartera no era un detalle de implementación sino la variable que decidía si la señal servía para algo, de lo que se sigue una exigencia metodológica: **ninguna conclusión sobre la utilidad práctica de un sistema predictivo es interpretable sin declarar con qué cartera se midió**. Un trabajo que hubiera reportado únicamente el resultado de su cartera por defecto habría concluido que la señal no se traslada fuera de muestra, y se habría equivocado.

Capítulo 8

Limitaciones y amenazas a la validez

Cada limitación se enuncia aquí junto a la cifra que permite dimensionarla: una salvedad que no puede cuantificarse no dice cuánto hay que descontar de las conclusiones. La Tabla 8.1 las reúne ordenadas por severidad.

Tabla 8.1: Limitaciones, evidencia que las cuantifica y severidad asignada.

Limitación	Evidencia que la cuantifica	Severidad
Multiplicidad de configuraciones	Deflated Sharpe 0,573 sobre 46 configuraciones evaluadas, por debajo del umbral 0,95	Alta
Solapamiento de cohortes	117 cohortes mensuales equivalen a ≈ 9 observaciones independientes con horizonte de 12 meses	Alta
Potencia de la era reservada	6 cohortes cerradas y ≈ 1 observación independiente efectiva; 1,41 años de cartera y 1 de 2 años por encima del índice. Con tenencia mínima de doce meses, sólo se cierra una operación en toda la ventana	Alta
Divergencia entre orden predictivo y pago económico	El Rank-IC por era sube (0,0949 $\rightarrow$ 0,0543 $\rightarrow$ 0,1739) mientras el IR de la <i>cartera por defecto</i> cae y se vuelve negativo (1,103 $\rightarrow$ 0,478 $\rightarrow$ -0,204): ordenar bien no basta para cobrar, y cuánto se cobra depende de la cartera	Alta
Cartera elegida sobre la ventana de selección	La ganadora es la mejor de 1.440: su IR de 0,841 en 2015–2024 es una cota superior optimista, no una estimación insesgada	Alta
Concentración del resultado en pocos nombres	De las 42 acciones que pasaron por la cartera, AAPL aporta 27,8 puntos de contribución neta y las cinco primeras la mayor parte de lo acumulado; en la era reservada un solo nombre aporta 21,3	Alta
Dominio de un solo agente	<i>risk</i> aislado 0,1201 frente a 0,1067 del meta, que además acaba asignándole más del 95 % del peso; la neutralización por factores retiene 87,21 %	Media
Mecanismo de la señal sin explicar	El agente dominante se apoya en gap_21d y range_63d , que encabezan el 81,5 % de sus atribuciones locales: microestructura a semanas que ordena retornos a doce meses	Media
Alfa factorial no significativo en selección	Alfa 0,20 % por periodo, $t = 1,02$, $R^2 = 0,015$	Media
Costes constantes	10 pb de comisión y 20 pb de <i>slippage</i> , sin impacto de mercado ni fiscalidad. El equilibrio resimulado está en 295 pb por operación, 9,8 veces el coste adoptado en selección, pero baja a 94 pb en la era reservada	Baja
Cobertura incompleta del universo	El panel resuelve 643 de los 1.206 <i>tickers</i> históricos: 49,0 % de los miembros del índice en 2003 y 99,2 % en 2026. El proveedor retira los símbolos que dejan de cotizar, y solo el 5,5 % de los ausentes son quiebras	Media

Continúa en la página siguiente

Limitación	Evidencia que la cuantifica	Severidad
Salvaguarda <i>a priori</i> en la curva de alfa	Una recta fija entre -10% y $+10\%$ sustituye a la calibración empírica justo donde la cascada no encuentra pendiente creciente, es decir, donde no hay señal que calibrar	Baja
Factores no construibles	Tamaño e inversión declarados no replicables en la regresión factorial	Baja

La severidad es un juicio del autor sobre cuánto condiciona cada limitación las conclusiones, no una medida estadística.

Cuatro de esas filas merecen una precisión que la tabla no puede contener.

La **multiplicidad** se agravó dos veces y a propósito: al encadenar tres Model Studies y al recorrer 1.440 carteras. Sus dos alcances no deben confundirse. La predictiva contamina la métrica que el trabajo reporta como resultado principal; la de la rejilla no puede tocar el Rank-IC y se limita a convertir el Information Ratio de la ventana de selección en una cota superior optimista. Ninguna de las dos anula el contraste de permutación, que no depende del número de configuraciones ensayadas.

El **predominio del agente de riesgo** queda matizado y agravado a la vez por su atribución local. Matizado, porque ese agente no resulta ser una réplica de la prima de baja volatilidad y reasigna atención entre sus variables según el régimen. Agravado, porque desplaza la incógnita sin resolverla: el trabajo no explica *por qué* unas variables de estructura de negociación a semanas ordenan retornos a doce meses, y una señal cuyo mecanismo no se comprende es más frágil ante un cambio de régimen que una respaldada por una hipótesis económica.

La **concentración en pocos nombres** no la delata ninguna métrica agregada: de las 42 acciones que pasaron por la cartera, la primera aporta 27,8 puntos de contribución neta y las cinco primeras suman algo más de la mitad de lo que aportan las quince mayores; en la era reservada una sola posición aporta 21,3 de los puntos de la ventana. El número de apuestas realmente independientes es por tanto bastante menor que los diez años de serie.

Y la que más condiciona las conclusiones: **el orden predictivo y el pago económico no se mueven en la misma dirección**. El Rank-IC es mayor en la era más reciente, mientras que el Information Ratio de la cartera por defecto cae y se vuelve negativo en esa misma era. La cartera adoptada corrige ese deterioro —no deja ningún año negativo en la ventana de selección—, pero que hiciera falta cambiar la cartera para lograrlo es justamente la limitación: la consecuencia para el alcance del trabajo es que la evidencia de que el modelo *ordena* es más sólida que la de que esa ordenación *se cobra*.

8.1. Amenazas a la validez interna

8.1.1. Fechas, restatements y calidad de la fuente

El diseño point-in-time reduce de forma directa el *lookahead bias*, pero depende de la calidad de las fechas de filing y de la correspondencia entre métricas de Finnhub y periodos contables. Los restatements históricos pueden ser invisibles en años tempranos: que una cifra esté hoy disponible con una fecha de filing antigua no garantiza que sea idéntica a la cifra que conoció el mercado ese día. La mitigación consiste en conservar periodo, filing y lag de ejecución, y en no presentar la fuente como una cinta histórica perfecta.

8.1.2. El sesgo de supervivencia por cobertura del proveedor

La pertenencia histórica al índice limita el sesgo de supervivencia de composición, pero no elimina la cobertura desigual de las empresas retiradas. A diferencia de la versión habitual de esta salvedad, aquí no es una posibilidad genérica sino algo medido, y se sabe de ella tres cosas.

La **causa** está medida en el Capítulo 3 y no es la mortalidad empresarial sino la retirada de símbolos por parte del proveedor de precios. El dato que remata el diagnóstico es cómo crece la ausencia con el tiempo transcurrido desde que una empresa salió del índice.




Figura 8.1: Fracción de empresas que no llegan al panel, según cuánto hace que abandonaron el índice. La progresión es la firma de una fuente que poda su histórico, no la de un sector que quiebra.

La Figura 8.1 lo muestra sin ambigüedad: entre las empresas que siguen hoy en el índice falta el 1,2 %, mientras que entre las que salieron hace más de veinte años falta el 94,4 %. Si el problema fuera la mortalidad empresarial, la ausencia no dependería de la antigüedad de esa manera.

La **dirección** es optimista, no conservadora. Las empresas que sí llegan al panel sobreviven hasta hoy con mucha más frecuencia que los miembros reales del índice de su año: en 1998 lo hacen el 77,7 % frente al 35,5 %, un exceso de 42 puntos porcentuales que se reduce a cero en 2026. Como el entrenamiento es una ventana móvil, el exceso que afecta a cada evaluación decae de 26,2 puntos al evaluar 2015 a 8,0 al evaluar 2026.

Podría objetarse que, como muchas de las ausentes fueron adquiridas con prima, el sesgo sería conservador. Ese razonamiento cuenta cabezas en vez de permanencia: una empresa adquirida rinde una vez y desaparece, mientras que una superviviente compone durante todo el periodo, y es esa composición la que infla el resultado.

Queda por declarar el **límite de lo demostrable**. Lo medido es la composición del universo, no el retorno de las empresas ausentes, que carecen precisamente de la serie de precios que permitiría calcularlo: el sesgo *no se cuantifica en puntos de rentabilidad*. Un dato acota su alcance en la dirección contraria —los ausentes sí tienen fundamentales descargados, así que la exclusión no selecciona empresas opacas sino símbolos sin precio—, y la lectura por eras es la comprobación empírica de si mueve o no el resultado predictivo. Una réplica con una fuente comercial *point-in-time* sería la prueba definitiva.

8.2. Amenazas económicas y de generalización

Los costes son constantes, 10 pb de comisión y 20 pb de *slippage*, y no modelan impacto de mercado, *bid-ask* dinámico ni fiscalidad. La sensibilidad medida acota esta limitación mejor de lo que suele acotarse: el exceso de la cartera no se agota hasta unos 295 puntos básicos por operación, 9,8 veces el coste adoptado, de modo que el resultado no depende de haber elegido una comisión benévola. Esa holgura, sin embargo, se calcula sobre la ventana de selección, donde la cartera es la mejor de la rejilla. En la era reservada se reduce a 94 puntos básicos con las

decisiones congeladas y desaparece por completo al resimular la cartera, porque allí el resultado empata con el índice: no hay margen que gastar en fricción.

El universo estadounidense de gran capitalización limita además la extrapolación a pequeñas empresas, otros países o regímenes de liquidez distintos.

Cada limitación acota una afirmación diferente, y conviene no mezclarlas: la multiplicidad limita el Sharpe, el solapamiento limita la precisión, la cobertura limita la generalización y la cartera limita la transferencia de señal. Ninguna permite ignorar los placebos, la permutación o la estabilidad por eras.

8.3. Lo que la cartera dejó de ganar

Las limitaciones anteriores acotan lo que puede afirmarse del resultado medido. Hay otra que no aparece en ninguna métrica agregada, porque no es un error sino el precio de una regla: cada vez que la cartera vende una posición para comprar otra mejor, renuncia a lo que la vendida hiciera después.

El sistema registra esos casos. En la ventana de selección hubo quince ventas seguidas de una subida apreciable en los doce meses posteriores, y la Tabla 8.2 recoge las ocho mayores.

Tabla 8.2: Ventas que el mercado desmintió: exceso no cobrado en los doce meses siguientes.

Acción	Fecha de venta	Subida posterior	Índice	Exceso no cobrado
BA	2017-10-30	37,7 %	6,2 %	29,7 %
ROK	2016-08-29	38,4 %	14,4 %	21,0 %
PH	2016-09-29	43,7 %	19,4 %	20,4 %
AZO	2017-10-30	26,6 %	6,2 %	19,3 %
APH	2023-07-30	42,6 %	20,3 %	18,6 %
APTV	2016-07-30	34,8 %	16,0 %	16,2 %
COST	2018-10-30	32,9 %	15,8 %	14,7 %
VLO	2016-07-30	33,0 %	16,0 %	14,6 %

Todas se vendieron por el mismo motivo: otra candidata ofrecía mayor ventaja neta esperada.

La mayor es Boeing, vendida en octubre de 2017: subió un 37,7 % en el año siguiente frente al 6,2 % del índice, de modo que la cartera dejó sobre la mesa casi treinta puntos de exceso. Las tres siguientes rondan los veinte. En conjunto son quince episodios, no una anécdota, y todos comparten el mismo motivo de venta: apareció una candidata con más ventaja neta esperada.

Hay una asimetría en cómo el trabajo cuenta su propio resultado que este dato ayuda a corregir. El Capítulo 7 dedica una sección a explicar por qué el sistema compró Apple y la mantuvo cuarenta y cuatro meses, y esa es la cara favorable. La desfavorable es que las posiciones que peor salieron —la peor resta 4,2 puntos de contribución neta tras dieciocho meses en cartera— se mantuvieron también durante mucho tiempo, porque la misma permanencia mínima que protege a las buenas protege a las malas.

Dos salvedades acotan lo que puede leerse aquí, y son importantes. La primera es que estos quince casos se identifican *con el resultado ya conocido*: sabemos que subieron porque miramos después. No puede derivarse de ellos ninguna regla nueva, porque añadir un filtro que los hubiera evitado sería ajustar sobre el resultado. La segunda es de selección: la tabla recoge las ventas que el mercado desmintió, no las que acertó, y esas últimas no se listan en ninguna parte. Lo que la tabla mide es el coste de la regla de rotación, no su balance neto.

8.4. Limitaciones heredadas del desarrollo

8.4.1. Tres decisiones que condicionan las cifras

Tres limitaciones no proceden del diseño sino de decisiones tomadas durante el desarrollo. Merecen figurar aquí porque afectan a la interpretación de las cifras y no serían visibles para un lector que sólo viera el resultado final; su origen y la disyuntiva técnica que las motivó se documentan en el Anexo D.

La primera es la salvaguarda de la curva de alfa: una recta fija entre -10% y $+10\%$ que sustituye a la calibración empírica cuando ninguna ventana de la cascada produce una pendiente creciente. Su defecto no es de magnitud sino de dirección: es un supuesto *a priori* que se dispara **precisamente cuando la evidencia indica que no hay señal que calibrar**, de modo que allí donde interviene la expectativa de alfa no procede de los datos sino de la recta declarada. El diseño la prefiere a no tener alfa esperada en absoluto —sin ella la cartera no podría decidir umbrales en esos tramos—, pero hay que declararla como lo que es: una decisión de diseño discutible, no una medición.

La segunda es que la calibración isotónica que precedió a esa salvaguarda se retiró sin conservarla como opción del catálogo, de modo que este trabajo *no puede* ofrecer una comparación empírica entre ambas formulaciones; la afirmación de que la nueva es mejor descansa en un argumento sobre el estimador, no en una medición pareada.

La tercera afectaba a las variables de cartera, que en versiones anteriores de este trabajo tomaban su valor del catálogo recomendado y no de una medición, de modo que las cifras económicas debían leerse como una cota inferior. El Portfolio Study resuelve esa limitación y la sustituye por otra de naturaleza distinta: la cartera ya no es arbitraria, pero es la mejor de 1.440 evaluadas sobre la ventana de selección, y por tanto sus cifras dentro de esa ventana son ahora una cota *superior* optimista en lugar de una inferior conservadora. La comprobación de la era reservada es la única lectura de esas cifras que no está sujeta a ese sesgo, y descansa sobre poco más de un año de datos.

8.4.2. Decisiones con margen escaso

De las dieciocho decisiones de la pasada de referencia, dieciséis conservaron el valor heredado y sólo dos lo cambiaron. Una de esas dos —la variable de régimen de mercado— ganó por no inferioridad, es decir, sin demostrar ser mejor; la otra —la tasa de aprendizaje— sí dominó al valor previo, pero con una ventaja media de tres diezmilésimas de Rank-IC y acertando en el 50,5 % de las cohortes emparejadas. Que la cadena apenas mueva al ganador indica convergencia y no fragilidad, pero ninguno de esos dos valores puede presentarse como un hallazgo empírico: la medición que los respalda no distingue con holgura entre las alternativas.

Capítulo 9

Conclusiones y trabajo futuro

9.1. Objetivo 1: capacidad de ordenación

La evidencia es favorable y robusta. El sistema alcanza Rank-IC medio 0,1067 sobre 117 cohortes, con 76,1 % positivas, IC-IR 0,833 y t de Newey–West 3,33. El test de permutación produce $p = 0,0001$ con 9.999 réplicas; el bootstrap por bloques excluye cero; y la señal conserva el signo al retirar eras completas, cambiar semillas, barajar etiquetas y neutralizar estilos conocidos. En la era reservada el Rank-IC sigue siendo positivo (0,0364).

La formulación defendible es que el sistema aprende una ordenación transversal fuera de muestra dentro del universo, el periodo y el protocolo estudiados. No demuestra, en cambio, que la arquitectura multiagente sea necesaria: el meta aprende a concentrar peso usando cohortes cerradas y supera al promedio equiponderado, pero el agente de riesgo alcanza por sí solo un Rank-IC de 0,1201, ligeramente superior. El resultado describe un meta que selecciona al mejor especialista más que una combinación cuya superioridad haya quedado establecida.

La atribución local añade comprensión, no causalidad. Los huecos de apertura y la amplitud del rango de negociación encabezan juntos 81,5 % de las observaciones de ese agente, y no son simplemente beta ni volatilidad anual. El trabajo identifica así qué variables sostienen el mecanismo, pero no puede distinguir si recogen liquidez, microestructura o una prima estable.

La lectura por eras también exige precisión. Que el Rank-IC sea mayor en el tramo donde el panel histórico está más completo contradice una explicación simple y monótonica basada en la peor cobertura temprana. No descarta que la disponibilidad del proveedor influya por otras vías. Por eso la cobertura sigue siendo una amenaza alta y la réplica con otra fuente es trabajo futuro.

9.2. Objetivo 2: cobrar el orden frente al mercado

El segundo objetivo se juzga contra un listón relativo y de suma cero, no absoluto, y la respuesta llega en dos mitades que conviene no fundir: las reglas de cartera sí alteran materialmente el resultado, y la cartera elegida deja de perder frente al índice en la era reservada sin llegar a superarlo con holgura.

9.2.1. Sensibilidad a la construcción de cartera

Este subobjetivo queda respaldado por la rejilla completa. Manteniendo fijos modelo, señal, datos y ventana, 1.440 combinaciones producen diferencias amplias de Information Ratio. El número de posiciones separa las medianas en 0,208, la tenencia mínima en 0,164 y el tope de efectivo en 0,139; la tolerancia de deriva y el reparto de pesos mueven mucho menos el resultado.

La cartera elegida eleva el Information Ratio de 0,312 a 0,841 y el exceso geométrico de 2,12 % a 5,91 %. Al mismo tiempo, reduce la rotación de 2,42 a 1,35 veces al año y la máxima

caída de 25,21 % a 22,83 %. No mejora por reaccionar más, sino por respetar el horizonte de doce meses: amplía la tenencia mínima de medio horizonte a uno completo y tolera más deriva antes de reequilibrar.

La magnitud de 0,841 no debe aislarse de cómo fue obtenida. Es la mejor cifra de la rejilla y, por tanto, una cota superior optimista. El hallazgo robusto del Objetivo 2a es la dispersión entre políticas y el orden de importancia de las reglas, no el nivel exacto de la ganadora.

9.2.2. Comportamiento en la era reservada

La comparación reservada es alentadora, pero preliminar. Con la cartera original, la señal produce un exceso de -12,23 % e IR -1,795. Con la política optimizada, sin reentrenar ni cambiar el ranking, pasa a exceso 0,24 % e IR 0,109. El cambio de signo demuestra que la conclusión económica depende de la cartera utilizada para medirla.

No demuestra generalización económica. La ventana contiene 6 cohortes cerradas y 1,41 años de cartera; batir al índice en la mitad de los años significa uno de dos. Además, la propia tenencia mínima reduce la rotación observable durante una serie tan corta. El resultado es compatible con dejar de destruir valor y aproximadamente empatar al índice, no con una ventaja sostenida.

La formulación final distingue así dos afirmaciones. Está demostrado que las reglas de cartera alteran materialmente el resultado de selección. Está sugerido, pero no confirmado, que la política elegida traduzca mejor la señal en una ventana nueva.

Sobre el objetivo tal como se enunció —batir al índice— la respuesta defendible es, por tanto, negativa en su versión fuerte y afirmativa sólo en una versión débil: el sistema no demuestra superar al mercado fuera de la ventana en la que se eligieron sus reglas, pero sí demuestra que llegar a esa frontera dependía de la implementación tanto como del modelo. En un juego de suma cero, pasar de destruir valor a empatar con el índice sin reentrenar nada es un resultado sobre dónde estaba el cuello de botella, no una demostración de ventaja competitiva.

9.3. Contribución defendible

La contribución principal es un procedimiento auditable que separa información observable, selección predictiva, pruebas de robustez e implementación económica. Esa disciplina permite localizar una divergencia que una rentabilidad final habría ocultado: el orden transversal puede mejorar mientras el pago de una cartera concreta empeora, y dos carteras pueden producir conclusiones opuestas sobre la misma señal.

De ahí se sigue la tesis del trabajo: **ninguna afirmación práctica sobre un sistema predictivo es interpretable sin declarar con qué cartera se midió**. La frase no convierte a la cartera ganadora en recomendación de inversión. Obliga a tratar tamaño, efectivo, tenencia, rebalanceo y costes como parte de la evaluación científica.

La evidencia económica tiene además una dependencia interna que las métricas agregadas no muestran: la cartera pasó por 42 acciones, pero una sola aporta 27,8 % puntos porcentuales acumulados. Esa concentración reduce el número de experiencias independientes que sostienen el resultado, y es la razón de que la conclusión económica deba ser más prudente que la predictiva.

9.4. Trabajo futuro y respuesta final

1. **Acumular una era reservada con potencia real.** Es la única forma de comprobar si el cambio de signo económico persiste sin volver a utilizar 2015–2024. Más búsqueda sobre la misma ventana aumentaría la multiplicidad, no la evidencia independiente.
2. **Replicar el protocolo con otra fuente y otro universo.** Una base histórica comercial completamente *point-in-time* permitiría medir la sensibilidad a cobertura y comprobar si la ordenación se sostiene fuera de la gran capitalización estadounidense.

3. **Modelar costes dependientes de liquidez y capacidad.** Una cartera de 8 posiciones requiere una función de impacto que complemente comisión y *slippage* constantes y acote con precisión el patrimonio al que el resultado es aplicable.

El TFM encuentra evidencia sólida de capacidad de ordenación y evidencia sólida de que la construcción de cartera importa. No encuentra evidencia suficiente para afirmar que cinco agentes sean necesarios ni que la cartera elegida generalice económicamente. Esa frontera entre lo demostrado, lo sugerido y lo pendiente es el resultado que puede defenderse.

Capítulo 10

Bibliografía

- Amihud, Y. (2002). Illiquidity and Stock Returns: Cross-Section and Time-Series Effects. *Journal of Financial Markets*, 5(1), 31–56. [https://doi.org/10.1016/S1386-4181\(01\)00024-6](https://doi.org/10.1016/S1386-4181(01)00024-6)
- Ang, A., Hodrick, R. J., Xing, Y., y Zhang, X. (2006). The Cross-Section of Volatility and Expected Returns. *The Journal of Finance*, 61(1), 259–299. <https://doi.org/10.1111/j.1540-6261.2006.00836.x>
- Arnott, R. D., Harvey, C. R., y Markowitz, H. (2019). A Backtesting Protocol in the Era of Machine Learning. *The Journal of Financial Data Science*, 1(1), 64–74. <https://doi.org/10.3905/jfds.2019.1.064>
- Asness, C. S., Frazzini, A., y Pedersen, L. H. (2019). Quality Minus Junk. *Review of Accounting Studies*, 24(1), 34–112. <https://doi.org/10.1007/s11142-018-9470-2>
- Bailey, D. H., y López de Prado, M. (2014). The Deflated Sharpe Ratio: Correcting for Selection Bias, Backtest Overfitting, and Non-Normality. *The Journal of Portfolio Management*, 40(5), 94–107. <https://doi.org/10.3905/jpm.2014.40.5.094>
- Bailey, D. H., Borwein, J. M., López de Prado, M., y Zhu, Q. J. (2017). The Probability of Backtest Overfitting. *Journal of Computational Finance*, 20(4), 39–69. <https://doi.org/10.21314/JCF.2017.322>
- Banz, R. W. (1981). The Relationship between Return and Market Value of Common Stocks. *Journal of Financial Economics*, 9(1), 3–18. [https://doi.org/10.1016/0304-405X\(81\)90018-0](https://doi.org/10.1016/0304-405X(81)90018-0)
- Brown, S. J., Goetzmann, W., Ibbotson, R. G., y Ross, S. A. (1992). Survivorship Bias in Performance Studies. *The Review of Financial Studies*, 5(4), 553–580. <https://doi.org/10.1093/rfs/5.4.553>
- Carhart, M. M. (1997). On Persistence in Mutual Fund Performance. *The Journal of Finance*, 52(1), 57–82. <https://doi.org/10.1111/j.1540-6261.1997.tb03808.x>
- Clarke, R., de Silva, H., y Thorley, S. (2002). Portfolio Constraints and the Fundamental Law of Active Management. *Financial Analysts Journal*, 58(5), 48–66.
- Fama, E. F., y French, K. R. (1992). The Cross-Section of Expected Stock Returns. *The Journal of Finance*, 47(2), 427–465. <https://doi.org/10.1111/j.1540-6261.1992.tb04398.x>
- Fama, E. F., y French, K. R. (1993). Common Risk Factors in the Returns on Stocks and Bonds. *Journal of Financial Economics*, 33(1), 3–56. [https://doi.org/10.1016/0304-405X\(93\)90023-5](https://doi.org/10.1016/0304-405X(93)90023-5)
- Fama, E. F., y French, K. R. (2015). A Five-Factor Asset Pricing Model. *Journal of Financial Economics*, 116(1), 1–22. <https://doi.org/10.1016/j.jfineco.2014.10.010>

- Feng, G., Giglio, S., y Xiu, D. (2020). Taming the Factor Zoo: A Test of New Factors. *The Journal of Finance*, 75(3), 1327–1370. <https://doi.org/10.1111/jofi.12883>
- Frazzini, A., y Pedersen, L. H. (2014). Betting Against Beta. *Journal of Financial Economics*, 111(1), 1–25. <https://doi.org/10.1016/j.jfineco.2013.10.005>
- Freyberger, J., Neuhierl, A., y Weber, M. (2020). Dissecting Characteristics Nonparametrically. *The Review of Financial Studies*, 33(5), 2326–2377. <https://doi.org/10.1093/rfs/hhz123>
- Grinold, R. C. (1989). The Fundamental Law of Active Management. *The Journal of Portfolio Management*, 15(3), 30–37. <https://doi.org/10.3905/jpm.1989.409211>
- Gu, S., Kelly, B., y Xiu, D. (2020). Empirical Asset Pricing via Machine Learning. *The Review of Financial Studies*, 33(5), 2223–2273. <https://doi.org/10.1093/rfs/hhaa009>
- Hansen, P. R. (2005). A Test for Superior Predictive Ability. *Journal of Business & Economic Statistics*, 23(4), 365–380. <https://doi.org/10.1198/073500105000000063>
- Harvey, C. R., Liu, Y., y Zhu, H. (2016). ... and the Cross-Section of Expected Returns. *The Review of Financial Studies*, 29(1), 5–68. <https://doi.org/10.1093/rfs/hhv059>
- Hou, K., Xue, C., y Zhang, L. (2015). Digesting Anomalies: An Investment Approach. *The Review of Financial Studies*, 28(3), 650–705. <https://doi.org/10.1093/rfs/hhu068>
- Hou, K., Xue, C., y Zhang, L. (2020). Replicating Anomalies. *The Review of Financial Studies*, 33(5), 2019–2133. <https://doi.org/10.1093/rfs/hhy131>
- Jegadeesh, N., y Titman, S. (1993). Returns to Buying Winners and Selling Losers: Implications for Stock Market Efficiency. *The Journal of Finance*, 48(1), 65–91. <https://doi.org/10.1111/j.1540-6261.1993.tb04702.x>
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., y Liu, T.-Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- Kelly, B. T., Pruitt, S., y Su, Y. (2019). Characteristics Are Covariances: A Unified Model of Risk and Return. *Journal of Financial Economics*, 134(3), 501–524. <https://doi.org/10.1016/j.jfineco.2019.05.001>
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons.
- López de Prado, M., Bailey, D. H., Borwein, J. M., y Zhu, Q. J. (2014). Pseudo-Mathematics and Financial Charlatanism: The Effects of Backtest Overfitting on Out-of-Sample Performance. *Notices of the American Mathematical Society*, 61(5), 458–471. <https://doi.org/10.1090/noti1105>
- McLean, R. D., y Pontiff, J. (2016). Does Academic Research Destroy Stock Return Predictability? *The Journal of Finance*, 71(1), 5–32. <https://doi.org/10.1111/jofi.12365>
- Newey, W. K., y West, K. D. (1987). A Simple, Positive Semi-Definite, Heteroskedasticity and Autocorrelation Consistent Covariance Matrix. *Econometrica*, 55(3), 703–708. <https://doi.org/10.2307/1913610>
- Novy-Marx, R. (2013). The Other Side of Value: The Gross Profitability Premium. *Journal of Financial Economics*, 108(1), 1–28. <https://doi.org/10.1016/j.jfineco.2013.01.003>
- Novy-Marx, R., y Velikov, M. (2016). A Taxonomy of Anomalies and Their Trading Costs. *The Review of Financial Studies*, 29(1), 104–147. <https://doi.org/10.1093/rfs/hhv063>

- S&P Dow Jones Indices (2026). *SPIVA U.S. Scorecard: Year-End 2025*. Tabla 1a; datos a 31 de diciembre de 2025. <https://www.spglobal.com/spdji/en/documents/spiva/spiva-us-year-end-2025.pdf>
- Sharpe, W. F. (1991). The Arithmetic of Active Management. *Financial Analysts Journal*, 47(1), 7–9. <https://doi.org/10.2469/faj.v47.n1.7>
- Shumway, T. (1997). The Delisting Bias in CRSP Data. *The Journal of Finance*, 52(1), 327–340. <https://doi.org/10.1111/j.1540-6261.1997.tb03818.x>
- White, H. (2000). A Reality Check for Data Snooping. *Econometrica*, 68(5), 1097–1126. <https://doi.org/10.1111/1468-0262.00152>

Apéndice A

Reproducibilidad

A.1. Identidad de los estudios

La evidencia empírica de este trabajo procede de cuatro estudios encadenados: tres *Model Studies* en los que el ganador de cada pasada es el *baseline* de la siguiente, y un *Portfolio Study* que optimiza la cartera del último sin reentrenar nada. Sus identificadores permiten localizar cualquier cifra citada en el texto.

Model Study 1	study-20260816-182345-3cc1a5fb · ganador run-803c214fd2ac
Model Study 2	study-20260817-021135-b5926b62 · ganador run-95dcffb1640f
Model Study 3	study-20260817-094411-568bd37e · ganador run-1bb331e23a18
Portfolio Study	study-20260817-212856-f86ca822 · 1.440 carteras evaluadas

El Model Study 3 es el estudio de referencia del documento: de él sale toda la evidencia predictiva. Sus identificadores de datos son los siguientes.

dataset_hash	b5db6211d03fcd56...f182071e5887cd9
evaluation_key	f7152472aeddb96c...ac3933d8eb36167d
catalog_hash	930f1f8c106d3928...9b9c48857e31910152

Las cuatro ejecuciones emplearon el mismo catálogo cerrado y la misma ventana de selección — 117 cohortes mensuales entre 2015 y 2024 —, y reservaron 2025–2026 sin que interviniera en ninguna decisión. La métrica de selección fue **rank_ic_only** en las tres pasadas predictivas y **information_ratio** en el Portfolio Study, cuya rejilla se calculó además sobre una serie recortada en 2024 para que ninguna de las 1.440 combinaciones pudiera observar la era reservada.

A.2. Cómo se persiste y se audita la evidencia

A.2.1. Ciclo de vida de una ejecución

La reproducibilidad no depende sólo de fijar una semilla. Una ejecución puede fallar tras horas de cálculo, cancelarse o reanudarse, y si esos estados no forman parte del diseño, dos resultados nominalmente iguales pueden haber recorrido historias distintas. El sistema separa por eso el *Study*, que contiene la pregunta y el catálogo, de cada *run*, que contiene una evaluación concreta.

El registro existe antes del cálculo: Study y run se crean antes de lanzar el proceso, y desde ahí cada transición relevante —inicio de fase, progreso, finalización, error y cancelación— queda escrita. Reanudar consulta primero el estado persistido, de modo que no se repiten ejecuciones completas ni se duplican decisiones ya tomadas.

Aislar cada evaluación en su propio proceso tiene además una función científica: evita que un estado en memoria —una semilla, una caché, un dataframe mutado— sobreviva de una configuración a la siguiente. El resultado depende así de entradas persistidas y no del orden accidental en que se ejecutaron las cosas.

A.2.2. Cadena de custodia de la evidencia

Cada nivel responde a una pregunta diferente y tiene un consumidor definido, según recoge la Tabla A.1:

Nivel	Contenido	Función en la auditoría
Catálogo	Rejillas, restricciones y fases	Demuestra qué podía elegirse antes de medir.
<code>winner.json</code>	Configuración adoptada y procedencia	Une cada valor final con el run que lo produjo.
<code>decisions.json</code>	Incumbente, candidatos y puerta pareada	Reconstruye por qué cambió o no cada decisión.
Evidencia predictiva	Scores, Rank-IC, atribución y robustez	Sostiene las afirmaciones sobre ordenación.
Evidencia de cartera	Órdenes, posiciones, costes y rejilla	Sostiene las afirmaciones económicas.
Manifiesto LaTeX	Fuente de cada tabla, macro y figura	Impide que el manuscrito mezcle estudios.

Tabla A.1: Niveles de persistencia y propósito de cada uno.

La identidad del panel señala qué datos se usaron, la del catálogo qué espacio de decisiones estaba disponible, y la clave de evaluación une ambas con la configuración concreta. Una caché sólo es reutilizable cuando las tres coinciden y el artefacto está completo, lo que evita dos formas de contaminación difíciles de detectar: atribuir a un catálogo nuevo un resultado antiguo, y dar por terminado un directorio que quedó a medias tras una interrupción.

A.3. Regeneración de figuras y tablas

Las figuras y tablas del manuscrito no se dibujan a mano: se generan desde los artefactos persistidos mediante un único comando, ejecutado desde la raíz del repositorio.

```
python latex/scripts/export_study_assets.py
--study-id study-20260817-094411-568bd37e
--chain-study-id study-20260816-182345-3cc1a5fb
--chain-study-id study-20260817-021135-b5926b62
--chain-study-id study-20260817-094411-568bd37e
--portfolio-study-id study-20260817-212856-f86ca822
```

Los tres identificadores de cadena van en orden de ejecución y el último coincide con el estudio de referencia. La separación entre el estudio predictivo y el de cartera hace explícita la procedencia de cada activo: del primero sale todo lo predictivo —Rank-IC, agentes, meta-agente, decisiones, robustez y atribución— y del segundo todo lo económico —rejilla de carteras, patrimonio, órdenes, métricas anuales y perfiles—.

El script escribe las figuras y los cuerpos de tabla en sus carpetas, genera el fichero de macros numéricas que consumen la memoria y la defensa, y actualiza el manifiesto de activos con la lista de artefactos consumidos, separando las fuentes predictivas de las económicas. Ese manifiesto es la tabla de correspondencia entre cada salida del manuscrito y su origen: ninguna cifra generada por script entra en el documento sin quedar registrada allí, y por eso no se imprime una ruta junto a cada cifra. La única excepción es la Tabla D.1 del Anexo D, que se transcribe de la bitácora del proyecto porque documenta el desarrollo y no una medición.

Una salvedad sobre qué se puede regenerar. El repositorio versiona los artefactos en formato JSON, que sostienen la mayoría de las cifras citadas y permiten verificarlas directamente; los ficheros Parquet quedan excluidos por tamaño, de modo que las tablas y figuras construidas a partir de ellos se conservan ya generadas pero no pueden recalcularse desde un clon del repositorio sin volver a ejecutar el estudio.

Otros dos comandos completan la verificación: uno comprueba que el proyecto sea portable —rutas relativas, recursos existentes, referencias cruzadas con destino, ausencia de *mojibake* y de activos huérfanos— y otro recalcula en memoria las macros decisivas, sin escribir nada, y falla si difieren de los estudios adoptados.

Apéndice B

Catálogo cerrado y protocolo experimental

La afirmación central del diseño experimental — que ningún parámetro se optimizó fuera de un catálogo fijado de antemano — sólo puede comprobarse si el catálogo está publicado. Este anexo lo reproduce íntegro. Cualquier lector puede verificar dos cosas: que el valor ganador de cada variable pertenece a la rejilla declarada para ella, y que la configuración final no contiene ninguna variable ajena al catálogo.

B.1. Regla de selección, en su forma exacta

La Sección 5.2.2 explica en qué consiste desplazar al incumbente; aquí quedan los umbrales concretos, para que la traza sea verificable. Un candidato debe superar tres filtros en este orden:

1. **Elegibilidad.** Observaciones suficientes y ningún Rank-IC por debajo de $-0,02$ en ninguna era disponible.
2. **Puerta pareada.** O *dominancia* —ventaja media positiva y mejor en más de la mitad de las cohortes— o *no inferioridad*, con el límite inferior del *bootstrap* pareado al 90 % por encima de $-0,01$. Las diferencias se emparejan por periodo mensual, de modo que dos configuraciones cuyas rejillas de observación estén desplazadas puedan compararse sin confundir ese desplazamiento con ausencia de evidencia.
3. **Desempate.** Una diferencia inferior a $0,002$ es empate técnico y se resuelve por simplicidad. Si persiste, se recurre en orden al Rank-IC medio, a la fracción de cohortes positivas, a la variabilidad, a la complejidad y, finalmente, a conservar el incumbente.

De las dieciocho decisiones de la pasada de referencia, catorce se resolvieron por comparación robusta y cuatro por empate. Esas dieciocho no cubren las veintiuna variables predictivas: tres —la familia de modelo y los dos parámetros de historia del meta-agente— se ejecutaron con un único valor alcanzable, de modo que no había comparación que hacer. Sus valores finales provienen de una decisión declarada de antemano y no de una medición, igual que los cuatro empates.

B.2. El catálogo completo

La Tabla B.1 reproduce las treinta y tres variables con su etapa, su rejilla de valores admisibles y el valor que adoptó el ganador. La columna de valores es la que hace auditable el catálogo: sin ella no podría comprobarse que una alternativa estaba disponible y no se eligió. El Anexo C explica qué significa cada una.

Tabla B.1: Catálogo cerrado completo: las 33 variables, su rejilla y el valor del ganador.

Variable	Etapas	Predictiva	Valores del catálogo	Ganador
feature_preset	Representación	Sí	core, all	all
meta_method	Meta-agente	Sí	equal, stacked rolling free, stacked rolling bounded	stacked rolling free
model_family	Modelo	Sí	lightgbm, elastic net	lightgbm
snapshot_step_months	Temporal	Sí	1, 3, 6, 12	1
target_size	Cartera	No	5, 8, 12, 16, 25, 50	8
	informativa			
exit_expected_alpha_bps	Cartera	No	0.0, 100.0, 250.0	100.0
	informativa			
fundamental_momentum	Representación	Sí	False, True	True
lgbm_max_depth	Modelo	Sí	3, 4, 6	3
meta_history_quarters	Meta-agente	Sí	8, 16	16
target_horizon_months	Temporal	Sí	3, 6, 12	12
lgbm_n_estimators	Modelo	Sí	100, 200, 400	100
market_regime_feature	Representación	Sí	False, True	False
meta_recency_weighting	Meta-agente	Sí	off, linear, exponential	off
rotation_edge_bps	Cartera	No	25.0, 50.0, 100.0	50.0
	informativa			
train_lookback_years	Temporal	Sí	4, 8, 12	8
max_cash_weight	Cartera	No	0.0, 0.1, 0.25	0.25
	informativa			
minimum_holding_period	Cartera	No	none, quarter horizon, half horizon, full horizon	half horizon
	informativa			
coverage_percentile_floor	Cartera	No	0.0, 60.0, 80.0	60.0
	informativa			
execution_lag_days	Temporal	Sí	30, 45, 60	60
lgbm_learning_rate	Modelo	Sí	0.03, 0.05, 0.1	0.03
neutralize_by_sector	Representación	Sí	False, True	False
rebalance_drift_tolerance	Cartera	No	0.0, 0.1, 0.25, 0.4	0.25
	informativa			
lgbm_min_child_samples	Modelo	Sí	20, 50, 100	20
price_only_strictness_multiplier	Cartera	No	1.0, 1.5, 2.0	1.5
	informativa			
recency_weighting	Temporal	Sí	off, linear, exponential	off
winsorization	Representación	Sí	0.0, 0.01, 0.025	0.0
price_only_sell_only	Cartera	No	False, True	False
	informativa			
max_features_per_agent	Representación	Sí	8, 12, 20	12
objective	Temporal	Sí	rank regression, ranking	rank regression
sizing_mode	Cartera	No	equal, alpha proportional	alpha proportional
	informativa			
commission_bps	Cartera	No	0.0, 5.0, 10.0	10.0
	informativa			
feature_weighting_mode	Representación	Sí	model native, oos stability prune	oos stability prune
slippage_bps	Cartera	No	5.0, 10.0, 20.0	20.0
	informativa			

Las cuatro primeras etapas — temporal, representación, modelo y meta — son predictivas y pueden modificar al ganador. La quinta, cartera, no. El coste declarado de cada variable indica qué debe recalcularse al cambiarla: un ajuste completo, únicamente la recombinación del meta-agente o sólo el *backtest*. Ese coste es lo que hace viable recorrer el catálogo de forma secuencial en lugar de cartesiana.

Qué ganador recoge la última columna. Es el del **Model Study 3**, incluidas sus variables de cartera, que en esa fase conservaban el valor por defecto. No es, por tanto, la cartera que el trabajo adopta: el Portfolio Study reoptimizó después seis de las doce y cambió cuatro —el tope

de efectivo del 25 al 10 %, la permanencia mínima de medio horizonte a uno completo, el suelo de cobertura del percentil 60 a ninguno y la tolerancia a la deriva de 0,25 a 0,40—, mientras que el número de posiciones y el reparto de pesos coincidieron con los de partida. La configuración adoptada se presenta en la Sección 7.2; aquí se tabula el ganador predictivo porque este anexo documenta el catálogo del protocolo, no la gestión de cartera.

La magnitud de ambos recorridos justifica por sí sola la elección de procedimiento. El producto cartesiano de las treinta y tres rejillas asciende a $4,6 \times 10^{14}$ combinaciones, y aun restringido a las veintiuna predictivas son $5,4 \times 10^8$; el recorrido secuencial evaluó 46. Esa reducción no es sólo computacional: cada configuración ensayada incrementa la probabilidad de encontrar una ganadora por azar, que es exactamente lo que el Deflated Sharpe penaliza. En el plano de la cartera, en cambio, las seis variables generan 1.440 combinaciones —cinco órdenes de magnitud menos— sobre una señal que ya no puede cambiar.

B.3. Capacidad de las variables por separado

Antes de cualquier modelo, cada variable ordena muy poco por sí sola. La tabla siguiente recoge los extremos de esa distribución, y es la que sostiene el argumento del Capítulo 3: la capacidad predictiva del sistema no reside en ninguna variable concreta, sino en combinarlas.

Tabla B.2: Variables con mayor y menor Rank-IC univariante.

Feature	Bloque	Agentes	Cobertura	Rank-IC univ.
factor_gap_21d	market liquidity	risk	99,9 %	0,0540
factor_cash_conversion	fundamental stability	growth	82,7 %	0,0370
factor_asset_turnover	quality efficiency	quality	88,8 %	0,0353
factor_rotc	quality core	quality	86,6 %	0,0338
factor_range_63d	price risk	risk	99,9 %	0,0297
factor_roic	quality core	quality	90,9 %	0,0293
factor_roe	quality core	quality	90,9 %	0,0281
factor_range_21d	price risk	risk	99,9 %	0,0278
factor_ev_revenue	value core	value	88,7 %	0,0259
factor_mom_volatility	momentum trend	momentum	99,8 %	0,0241
factor_ps	value core	value	88,8 %	0,0236
factor_roa	quality core	quality	94,4 %	0,0223
factor_roic_trend	fundamental stability	growth	89,4 %	-0,0145
factor_receivables_turnover	quality efficiency	quality	79,3 %	-0,0147
factor_roe_stability	fundamental stability	growth	90,0 %	-0,0147
factor_pb	value core	value	90,8 %	-0,0236
factor_beta_252d	price risk	risk	99,8 %	-0,0375

Doce primeras y cinco últimas de las 73 series con diagnóstico calculado, ordenadas por Rank-IC univariante. Esas 73 no coinciden con las 68 que declara el catálogo: 66 son comunes, siete son componentes derivados que el catálogo no declara por separado y dos variables declaradas no llegan a tener diagnóstico, de modo que la unión de ambas listas —la que audita el exportador— suma 75 filas. Ninguna aparece marcada como podada, así que la tabla describe el catálogo declarado y no qué variables sobrevivieron a la poda por estabilidad.

B.4. Diccionario de variables predictivas

El catálogo de parámetros anterior dice *cómo* puede entrenarse el sistema; no enumera *qué* información recibe. La Tabla B.3 completa esa segunda capa de auditabilidad con las 68 varia-

bles declaradas: nombre persistido, bloque económico, agentes que pueden consumirla, dirección económica orientativa y fuente.

La dirección no es una regla de trading ni una restricción monotonica impuesta al LightGBM. Indica la lectura convencional usada para revisar signos, construir baselines y detectar errores de ingeniería. El modelo puede aprender que una relación cambia por región del espacio de variables o por interacción con otra característica. Del mismo modo, pertenecer a varios agentes no duplica la columna en el panel: cada especialista recibe la misma observación puntual dentro de su propio vocabulario.

Tabla B.3: Diccionario completo de las 68 variables declaradas.

Variable	Agente	Bloque	Dir.	Cobertura	Rank-IC
factor_cash_conversion	growth	fundamental stability	+	82,7 %	0,0370
factor_margin_stability	growth	fundamental stability	+	88,1 %	0,0196
factor_roe_stability	growth	fundamental stability	+	90,0 %	-0,0147
factor_roe_trend	growth	fundamental stability	+	89,4 %	-0,0071
factor_roic_trend	growth	fundamental stability	+	89,4 %	-0,0145
factor_ebitda_growth_acceleration	growth	growth acceleration	+	89,4 %	0,0009
factor_eps_growth_acceleration	growth	growth acceleration	+	89,5 %	0,0024
factor_eps_growth_yoy	growth	growth acceleration	+	90,2 %	-0,0026
factor_fcf_growth_acceleration	growth	growth acceleration	+	93,2 %	0,0001
factor_sales_growth_acceleration	growth	growth acceleration	+	88,3 %	-0,0067
factor_sales_per_share_growth_yoy	growth	growth acceleration	+	88,9 %	0,0129
factor_mom_acceleration	momentum	momentum core	+	99,4 %	0,0046
factor_mom_reversal_1m	momentum	momentum core	+	99,9 %	0,0016
factor_momentum_12_1	momentum	momentum core	+	99,4 %	-0,0116
factor_relative_return_12m	momentum	momentum core	+	99,4 %	-0,0120
factor_relative_return_3m	momentum	momentum core	+	99,8 %	-0,0009
factor_relative_return_6m	momentum	momentum core	+	99,7 %	-0,0028
factor_ma_distance_to_high12	momentum	momentum trend	+	99,9 %	-0,0026
factor_ma_price_vs_sma12	momentum	momentum trend	+	99,9 %	-0,0035
factor_ma_price_vs_sma6	momentum	momentum trend	+	99,9 %	-0,0017
factor_mom_volatility	momentum	momentum trend	+	99,8 %	0,0241
factor_debt_assets	quality	financial strength	-	94,6 %	0,0111
factor_debt_capital	quality	financial strength	-	94,5 %	-0,0046
factor_debt_equity	quality	financial strength	-	91,0 %	0,0014
factor_long_debt_assets	quality	financial strength	-	90,1 %	0,0079
factor_long_debt_capital	quality	financial strength	-	90,1 %	-0,0067
factor_long_debt_equity	quality	financial strength	-	86,6 %	-0,0003
factor_net_debt_capital	quality	financial strength	-	90,1 %	0,0064
factor_net_debt_equity	quality	financial strength	-	86,6 %	0,0066
factor_sga_to_sales	quality	financial strength	-	80,7 %	0,0111
factor_fcf_margin	quality	quality core	+	71,1 %	0,0174
factor_gross_margin	quality	quality core	+	76,8 %	0,0016
factor_net_margin	quality	quality core	+	89,0 %	-0,0054
factor_operating_margin	quality	quality core	+	89,0 %	-0,0020
factor_pretax_margin	quality	quality core	+	89,1 %	-0,0038
factor_roa	quality	quality core	+	94,4 %	0,0223
factor_roe	quality	quality core	+	90,9 %	0,0281
factor_roic	quality	quality core	+	90,9 %	0,0293
factor_rotc	quality	quality core	+	86,6 %	0,0338
factor_asset_turnover	quality	quality efficiency	+	88,8 %	0,0353
factor_cash_ratio	quality	quality efficiency	+	89,7 %	0,0020
factor_current_ratio	quality	quality efficiency	+	86,4 %	-0,0009
factor_inventory_turnover	quality	quality efficiency	+	64,3 %	-0,0023
factor_quick_ratio	quality	quality efficiency	+	86,4 %	0,0102
factor_receivables_turnover	quality	quality efficiency	+	79,3 %	-0,0147
factor_amihud_illiquidity	risk	market liquidity	-	99,8 %	0,0097
factor_gap_21d	risk	market liquidity	-	99,9 %	0,0540
factor_volume_relative	risk	market liquidity	-	99,9 %	0,0110
factor_volume_volatility	risk	market liquidity	-	99,8 %	-0,0009
factor_beta_252d	risk	price risk	-	99,8 %	-0,0375
factor_downside_vol_63d	risk	price risk	-	99,6 %	-0,0116
factor_drawdown_252d	risk	price risk	-	99,9 %	0,0039
factor_max_drawdown_252d	risk	price risk	-	99,9 %	-0,0004
factor_range_21d	risk	price risk	-	99,9 %	0,0278
factor_range_63d	risk	price risk	-	99,9 %	0,0297
factor_realized_vol_126d	risk	price risk	-	99,9 %	-0,0102

Continúa en la página siguiente

Variable	Agente	Bloque	Dir.	Cobertura	Rank-IC
factor_realized_vol_63d	risk	price risk	—	99,9 %	-0,0110
factor_earnings_yield	value	value cashflow	+	87,3 %	0,0093
factor_fcf_yield	value	value cashflow	+	76,1 %	0,0141
factor_ev_ebitda	value	value core	—	86,8 %	0,0140
factor_ev_revenue	value	value core	—	88,7 %	0,0259
factor_pb	value	value core	—	90,8 %	-0,0236
factor_pe	value	value core	—	87,3 %	0,0093
factor_pfcf	value	value core	—	76,1 %	0,0141
factor_ps	value	value core	—	88,8 %	0,0236
factor_ptbv	value	value core	—	64,1 %	-0,0117

La tabla se genera directamente desde el catálogo de variables del sistema, no es una transcripción manual, y cumple dos funciones: hace explícito qué significan los nombres abreviados que aparecen en la atribución, y permite comprobar que ninguna variable citada en el resultado falta del catálogo. Los diagnósticos auxiliares que no entrenan modelos quedan fuera de esta lista para no confundir control de calidad con información predictiva.

Apéndice C

Qué significa cada variable del catálogo

El Anexo B reproduce el catálogo cerrado con su rejilla y el valor del ganador, pero una tabla no dice qué representa cada parámetro ni por qué está ahí. Este anexo lo explica, en el mismo orden en que el protocolo recorre las etapas, y distingue en cada caso si la variable se optimizó, se fijó de antemano o se estresó aparte.

Conviene aclarar antes tres recuentos parecidos que conviven en el trabajo y no son intercambiables. El sistema emplea 68 *variables de entrada* —los datos que los agentes miran para puntuar una acción—. El catálogo contiene 33 *parámetros*, que son los de este anexo: no describen una empresa, sino cómo se entrena y se opera el sistema. Y la auditoría de variables reúne 75 filas porque cruza esas entradas con todas las series a las que el sistema calcula diagnósticos, conservando las de ambos lados.

C.1. Temporal: cuándo se mira y cuánto futuro se predice

Seis parámetros fijan el reloj del sistema. Tres de ellos se optimizaron.

Cadencia de observación

Cada cuántos meses se vuelve a mirar el universo, puntuar todas las acciones y decidir la cartera. Mirar más a menudo produce más cohortes con las que decidir, pero también más oportunidades de operar sobre una señal que aún no ha madurado. El ganador observa cada mes.

Horizonte de la etiqueta

Cuántos meses de retorno futuro aprende a ordenar el modelo. Es la definición de «bueno» que el sistema persigue: con horizonte de doce meses, la mejor acción es la que más rinde en el año siguiente, no la que sube mañana. *Se optimizó*; ganó el horizonte anual frente al semestral.

Años de historia por ajuste

Cuánto pasado entra en cada reentrenamiento. Más historia da más filas pero mezcla regímenes más antiguos, quizá ya irrelevantes. *Se optimizó*; ganaron ocho años.

Retardo de observación

Días entre el fin de un mes y el día en que el sistema mira el mercado. No es lo que impide usar información futura —de eso se encarga el filtro por fecha de publicación, explicado en el Capítulo 3— sino lo que fija cuándo se mira, y con ello cuántos informes del trimestre ya se han publicado. *Se optimizó* entre 45 y 60 días, con la particularidad de que el desempate favorece deliberadamente al retardo mayor, por ser el más conservador. Ganaron 60.

Ponderación por recencia

Si las observaciones recientes pesan más que las antiguas dentro del entrenamiento. *Se optimizó*; ganó no ponderar, es decir, tratar por igual toda la ventana.

Objetivo de aprendizaje

Si el modelo aprende regresando el rango continuo o resolviendo un problema de ranking directo. Se fijó en la regresión del rango.

C.2. Representación: qué ve el modelo

Siete parámetros gobiernan qué información llega a los agentes y en qué forma. Dos se optimizaron.

Conjunto de variables

Cuántos bloques temáticos se activan: un subconjunto reducido de cinco o los once disponibles. *Se optimizó*; ganó el conjunto amplio.

Momentum fundamental

Si además del valor de un ratio se añade su *cambio* desde el informe anterior, calculado siempre con datos ya publicados. *Se optimizó*; ganó incluirlo.

Régimen de mercado

Si cada observación incorpora contexto sobre el estado general del mercado en esa fecha, común a todas las acciones. Ganó no incluirlo, y por no inferioridad: el candidato no demostró ser mejor, sólo que no era peor.

Neutralización sectorial

Si cada empresa se compara con las de su propio sector antes de aprender, en lugar de con todo el universo. Se fijó en no neutralizar; hacerlo habría costado Rank-IC de forma apreciable.

Winsorización

Si los valores extremos de cada variable se recortan a un percentil antes de entrenar, para que un dato anómalo no domine el ajuste. Se fijó en no recortar.

Máximo de variables por agente

Cuántas variables conserva cada especialista tras la poda. Limitarlo reduce varianza y facilita la interpretación, a costa de perder información. El ganador conserva doce.

Regla de ponderación de variables

Si la importancia de cada variable la decide el propio modelo o una poda basada en su estabilidad fuera de muestra. Ganó la poda por estabilidad, aunque por muy poco: la alternativa medía ligeramente mejor pero no superaba la puerta de dominancia.

C.3. Modelo: cómo aprende cada agente

Cinco parámetros describen el estimador. Ninguno se optimizó en la pasada de referencia, y el capítulo de protocolo explica por qué eso importa: el sistema no debe su capacidad predictiva al ajuste fino del modelo.

Familia de modelo

Qué algoritmo usan los cinco agentes. El catálogo ofrece árboles potenciados o una alternativa lineal regularizada; el ganador usa árboles.

Profundidad máxima

Cuántas divisiones encadenadas puede tener cada árbol, es decir, cuán específicas pueden ser las interacciones que aprende. El ganador usa tres, un valor bajo.

Número de árboles

Cuántos árboles se encadenan, cada uno corrigiendo los errores del anterior. El ganador usa cien.

Tasa de aprendizaje

Cuánto corrige cada árbol nuevo. Valores bajos aprenden más despacio pero suelen generalizar mejor.

Mínimo de observaciones por hoja

Cuántas acciones debe haber al menos en cada rama final. Subirlo impide que el modelo construya reglas sobre un puñado de casos.

C.4. Meta-agente: cómo se combinan los cinco

Tres parámetros gobiernan la capa de combinación, y el primero es la decisión más consecuente de todo el catálogo.

Método de combinación

Tres opciones: repartir por igual entre los cinco agentes, o aprender los pesos con una regresión regularizada en su variante *acotada* —donde ningún agente puede pesar menos del 10 % ni más del 50 %— o *libre*, sin tope alguno. *Se optimizó*; ganó la libre, y esa elección explica que el sistema acabe concentrando más del 95 % del peso en un solo especialista.

Cohortes de historia

Cuántas cohortes trimestrales ya cerradas mira el combinador para estimar los pesos. El ganador usa dieciséis.

Ponderación por recencia del combinador

Si las cohortes recientes pesan más que las antiguas al aprender esos pesos. Se fijó en no ponderar.

C.5. Cartera: cómo se convierte el orden en posiciones

Doce parámetros gobiernan la gestión. Ninguno puede modificar la señal, porque se aplican después de congelarla, y se dividen en dos grupos que conviene no mezclar.

C.5.1. Las seis que el Portfolio Study optimiza

Son las decisiones de gestión propiamente dichas: lo que un gestor elegiría.

Número de posiciones

Cuántas acciones se mantienen a la vez. Pocas concentran la señal y hacen el resultado volátil; muchas lo estabilizan a costa de parecerse al índice. El ganador mantiene ocho.

Tope de efectivo

Cuánto patrimonio puede quedar sin invertir cuando ninguna candidata supera el umbral. Con cero, la cartera está siempre invertida al 100 %. El ganador tolera hasta un 10 %, aunque en la práctica nunca lo usa.

Reparto de pesos

Si todas las posiciones pesan lo mismo o el peso sigue al alfa esperado, con un tope de dos a uno entre la mayor y la menor. El ganador reparte en proporción al alfa.

Permanencia mínima

Cuánto debe conservarse una posición antes de poder venderla por cualquier motivo, expresado como fracción del horizonte del modelo. El ganador exige un horizonte completo, es decir, doce meses.

Suelo de cobertura

Percentil por debajo del cual una posición deja de pertenecer a la cartera y se vende entera. El ganador desactiva la regla.

Tolerancia a la deriva

Cuánto pueden desviarse los pesos de su objetivo antes de emitir una orden que los corrija. No cambia qué se tiene, sólo cada cuánto se ajusta. El ganador tolera hasta un 40 %, el valor más laxo disponible.

C.5.2. Las seis que se fijan y se estresan aparte

No describen una decisión del gestor sino el entorno en el que opera, y por eso quedan fuera de la optimización. Optimizar un coste equivaldría a elegir el mundo en el que la estrategia luce mejor.

Comisión

Coste fijo aplicado sobre el notional de cada operación. Se fija en 10 puntos básicos y su efecto se mide en el análisis de sensibilidad a costes.

Slippage

Diferencia adversa estimada entre el precio de referencia y el de ejecución, también sobre el notional. Se fija en 20 puntos básicos.

Alfa mínimo de salida

Alfa esperado anual por debajo del cual una posición pasa a ser candidata a venderse.

Margen de rotación

Ventaja adicional que una candidata externa debe ofrecer por encima del coste de ida y vuelta para justificar una sustitución.

Endurecimiento sin fundamentales nuevos

Multiplicador que sube los umbrales en las observaciones en las que no ha aparecido ningún informe nuevo, cuando la señal se apoya sólo en precios.

Sólo venta sin fundamentales nuevos

Si en esas mismas observaciones se permite deshacer una posición mala pero se prohíbe comprar su reemplazo.

Los cuatro últimos gobiernan la mecánica de rotación, cuyo efecto ya está mediado por las seis variables que sí se recorren. Fijarlos es una decisión declarada de antemano, y acota lo que puede afirmarse: la rejilla responde a qué cartera es mejor *dado* este entorno, no a cuál sería la mejor sin restricciones.

Apéndice D

Auditoría del desarrollo

Este anexo conserva sólo los defectos que pudieron cambiar la validez o la interpretación del estudio. No es una cronología del código ni una lista de incidencias menores. Su propósito es mostrar qué tipos de error eran capaces de producir resultados plausibles, cómo se detectaron y qué contrato quedó después para impedir su regreso. La historia completa permanece en la bitácora del repositorio.

Tabla D.1: Defectos del desarrollo con impacto sobre la validez.

Defecto detectado	Efecto medido de la corrección
La puerta de no inferioridad penalizaba a los candidatos superiores : cuanto mayor la diferencia, más ancho el intervalo	feature_preset pasa de core (Rank-IC 0,0730) a all (0,0958), con ventaja pareada +0,0216. Ningún retador era elegible pese a dominar
market_regime_feature se decidió sobre una ventaja de 0,00112, por debajo del ruido	Pasa de True a False por simplicidad
meta_method se decidió sobre una ventaja de 0,00033	Se mantiene, pero registrado como empate técnico y no como victoria
Emparejamiento por cadena de fecha con rejillas desplazadas por execution_lag_days	Se empareja por periodo mensual; sin bloque completo común el resultado se marca no aplicable en vez de devolver ci_low = 0,0
evaluation_key no incluía el hash del dataset	La misma clave aparecía con CAGR 0,1468 y 0,1692. Ahora la clave separa datasets
Seis factores de precio se inyectaban en el agente <i>momentum</i> fuera de todo condicional	La ablación fundamental deja de recibir información de precio y mide lo que declara
Dos definiciones incompatibles de <i>information ratio</i> bajo el mismo nombre	Una sola, anualizada
CAGR, <i>drawdown</i> y alfa mezclaban la era reservada con la de selección	Métricas segmentadas: selección, confirmación y curva completa
geometric_excess_return era una resta de CAGR	Cociente de acumulados
Una posición sin precio se marcaba plana	Convención de exclusión tipo CRSP (−30 %) y liquidación contra efectivo
subsample=0.8 sin subsample_freq : el <i>bagging</i> nunca se activaba	subsample_freq=1
Nulo de carteras aleatorias con percentil 95 de CAGR del 107 %	Exige cobertura anual completa, aplica la guarda de datos y paga los mismos costes

D.1. Cuatro defectos que producían resultados plausibles

Una regla estadística correcta en apariencia. La puerta de no inferioridad construía su intervalo sobre una transformación que ensanchaba el castigo conforme aumentaba la ventaja del candidato, de modo que ningún retador podía resultar elegible ni siquiera dominando al incumbente. No fallaba nada: los runs terminaban y las métricas parecían razonables. El efecto material se vio en el conjunto de variables, donde la versión defectuosa retenía el reducido con Rank-IC 0,0730 y, corregida la comparación, el amplio alcanzó 0,0958. La corrección fue reescribir la puerta para que el objeto estadístico fuese la serie de diferencias emparejadas por cohorte, y de ahí salieron tres contratos: el signo de una ventaja se conserva al construir su intervalo, un candidato estrictamente mejor no puede volverse menos elegible porque crezca su incertidumbre, y toda decisión registra tamaño de muestra, fracción de victorias y límites del intervalo.

Configuración declarada que no cambia la ciencia. Una opción puede aparecer en el catálogo, viajar por la API y quedar guardada sin alterar los datos que consume el modelo. Ocurrió con una ablación: seis factores de precio llegaban al agente de tendencia fuera del condicional que debía retirarlos, de modo que la interfaz decía haber eliminado una familia de información que el modelo seguía recibiendo. El riesgo no es la etiqueta incorrecta sino que una conclusión del tipo «la información de precio no importa» resultaría irrefutable desde las métricas, porque los dos modelos serían casi el mismo. La misma lógica detectó que un parámetro de submuestreo no activaba el *bagging* por faltarle su frecuencia. La lección: auditar el valor declarado prueba la interfaz; auditar el consumidor prueba el experimento.

Identidades y ventanas que mezclaban evidencias. La primera clave de evaluación no incorporaba la identidad del panel, así que dos conjuntos de datos distintos podían compartirla; el indicio fue encontrar bajo la misma identidad un CAGR de 0,1468 y otro de 0,1692. En paralelo, las métricas económicas se calculaban sobre la curva completa y mezclaban selección con la era reservada, lo que impedía saber qué parte era evidencia disponible durante el desarrollo. La salida se segmentó en selección, reserva y curva completa. También se corrigió el exceso geométrico, que restaba dos CAGR en vez de comparar los factores de riqueza:

$$\alpha_{\text{geom}} = \left(\frac{W_T^{\text{cartera}}}{W_T^{\text{SPY}}} \right)^{1/Y} - 1.$$

Una simulación que termina no es una simulación válida. Los defectos de cartera más peligrosos no lanzaban excepciones: una posición sin precio podía marcarse plana, una venta podía pagar costes sin ejecutarse, una señal ausente podía bloquear una rotación. Cada caso produce una curva suave y aparentemente conservadora que altera el contrafactual. La convención final penaliza una desaparición sin precio con un -30% y liquida contra efectivo, sólo cobra comisión si hubo orden ejecutada, y registra en cada venta la alternativa a la que se reasigna el capital. La prueba de carteras aleatorias mostró lo mismo: el nulo inicial llegaba a un percentil 95 de CAGR del 107% porque aceptaba historias incompletas y no pagaba las mismas fricciones, de modo que no era evidencia contra el modelo sino un contrafactual distinto.

D.2. Matriz de contratos que quedó en el sistema

La Tabla D.2 recoge los contratos que quedaron en el sistema tras esas correcciones. Ninguna de ellas aumenta el Rank-IC ni es evidencia económica. Su valor está en delimitar qué puede creerse del resultado: el modelo recibió las variables que declaraba, las filas pertenecían al tiempo que les correspondía, la búsqueda comparó candidatos bajo una regla coherente y la cartera pagó sólo operaciones que ocurrieron. La conclusión de fondo es que la plausibilidad no sirve como

Frontera	Invariante	Fallo que evita
Catálogo-API	Rechazo de claves y combinaciones desconocidas	Hipótesis no declaradas.
Configuración-datos	Columnas efectivas iguales a las autorizadas	Ablaciones ficticias.
Datos-label	Publicación y cierre anteriores al entrenamiento	Fuga temporal.
Evaluación-caché	Dataset, catálogo y clave coincidentes	Reutilización entre paneles.
Selección-reserva	Ningún artefacto de rejilla contiene 2025-2026	Mirada anticipada.
Orden-contabilidad	Patrimonio reconstruible desde operaciones	Costes o ventas fantasma.
Evidencia-LaTeX	Activo y fuente declarados en el manifiesto	Mezcla de estudios.

Tabla D.2: Contratos de validación derivados de los defectos materiales.

prueba: un número financiero puede parecer razonable y estar midiendo otro universo, otra ventana o una hipótesis que nunca llegó a activarse.