

Aprendizaje automático aplicado a la selección de acciones

Medición honesta del aprendizaje fuera de muestra

Adrián Núñez

Trabajo Fin de Máster · Defensa

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

Aprendizaje automático aplicado a la selección de acciones

Medición honesta del aprendizaje fuera de muestra


Adrián Núñez

Trabajo Fin de Máster · Defensa

[0:20] Buenos días. Mi trabajo se titula «Aprendizaje automático aplicado a la selección de acciones», y el subtítulo es la parte que de verdad importa: medición honesta del aprendizaje fuera de muestra. Voy a hacer dos preguntas que en este campo se confunden constantemente. La primera es si un sistema de aprendizaje automático es capaz de aprender a ordenar acciones. La segunda es si ese orden, una vez existe, puede cobrarse frente al mercado. No son la misma pregunta, y buena parte de la contribución de este trabajo consiste precisamente en separarlas y medirlas por separado. La defensa sigue esa cadena en dos actos. Empiezo por fijar contra qué me estoy midiendo.

Batir al mercado es un juego de suma cero

Aritmética, no opinión



92,89 %

de los fondos *large-cap* pierde contra el S&P 500 a veinte años

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

└ Batir al mercado es un juego de suma cero



[1:00] Antes de formular los objetivos conviene fijar el listón, porque no es un listón cualquiera. El argumento es de Sharpe y es puramente aritmético, no una opinión sobre lo eficientes que sean los mercados. El conjunto de la gestión activa posee, entre todos, la cartera de mercado. Por tanto, antes de costes, su rendimiento medio es exactamente el del índice. De ahí se sigue algo incómodo: para que un gestor lo supere, otro tiene que quedarse por debajo. Es un juego de suma cero. Y en cuanto se introducen las comisiones y los costes de operar, pasa a ser de suma negativa, donde el conjunto pierde por construcción. SPIVA aporta el correlato empírico de esa aritmética. En la figura tenéis, para cada horizonte publicado, el porcentaje de fondos estadounidenses de gran capitalización que no supera al S&P 500. No es una serie monótona, pero sí persistentemente alta, y a veinte años llega al 92,89 por ciento. Es decir: nueve de cada diez profesionales que dedican su vida a esto no lo consiguen. Ese es el contexto en el que hay que juzgar cualquier resultado que presente hoy aquí. [Sources] - <https://www.spglobal.com/spdji/en/documents/spiva/spiva-us-year-end-2025.pdf> — Report 1a, All Large-Cap Funds frente al S&P 500, rentabilidad absoluta; datos a 31-12-2025.

Dos objetivos, dos listones, dos métricas

1 · ¿Aprende?

Listón **absoluto**: existe o no existe.
Se decide con **Rank-IC**.

2 · ¿Se cobra?

Listón **relativo** y de suma cero.
Se decide con **Information Ratio**.

Ordenar bien y ganar dinero son capacidades relacionadas, no equivalentes.

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

└ Dos objetivos, dos listones, dos métricas

[0:50] De ahí salen los dos objetivos del trabajo, y quiero subrayar que tienen listones distintos y métricas distintas. El objetivo uno pregunta si el sistema aprende a ordenar acciones fuera de muestra, y se decide exclusivamente por el Rank-IC, que mide si el orden que predigo coincide con el orden de los retornos que efectivamente ocurrieron después. Su listón es absoluto: la capacidad de ordenar existe o no existe, y no depende de contra quién compita. El objetivo dos pregunta si con ese orden se supera al índice, y se decide por el Information Ratio, que es exceso sobre el índice dividido por su volatilidad. Su listón es relativo y, como acabamos de ver, de suma cero. Los separo por una razón metodológica concreta: si midiera las dos cosas a la vez correría el riesgo de elegir el modelo por una cartera afortunada en lugar de por su capacidad predictiva, y también el riesgo contrario, presentar una señal estadísticamente buena como si ya fuera dinero. La frase de abajo resume la tesis metodológica del trabajo: ordenar bien y ganar dinero están relacionados, pero no son lo mismo.

Dos objetivos, dos listones, dos métricas

1 · ¿Aprende?	2 · ¿Se cobra?
¿Ordena acciones fuera de muestra?	¿Supera al índice con ese orden?
Listón absoluto: existe o no existe. Se decide con Rank-IC.	Listón relativo y de suma cero. Se decide con Information Ratio.

Ordenar bien y ganar dinero son capacidades relacionadas, no equivalentes.

Tres preguntas que esta defensa deja resueltas

1

?

se resuelve en el Acto I

2

?

se resuelve en el Acto II

3

?

se resuelve al final del Acto II

Ninguna de las tres se responde con la intuición que uno esperaría.

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

└ Tres preguntas que esta defensa deja resueltas

[1:05] Estas son las tres preguntas concretas que voy a dejar resueltas, y las dejo aquí planteadas para que sepáis en todo momento en qué punto del argumento estamos. La primera: ¿el sistema aprende de verdad a ordenar acciones fuera de muestra? La segunda: ¿cuánto pesan las reglas de gestión de la cartera frente al modelo predictivo, es decir, cuánto del resultado final decide el modelo y cuánto decide lo que hago después con él? Y la tercera: ¿sobrevive todo eso en una ventana de tiempo que ninguna decisión del trabajo llegó a consultar? Cada una lleva un interrogante, y cada interrogante se sustituye por una cifra en la diapositiva donde queda demostrado: la primera en el acto uno, la segunda en el acto dos, la tercera al final del acto dos. Al terminar volveré a esta misma pantalla con las tres respuestas puestas. Adelanto solo una cosa, que es la de abajo: ninguna de las tres se responde con la intuición que uno esperaría antes de empezar, y en los tres casos la sorpresa está en un sitio distinto del que yo suponía cuando diseñé el experimento.

Tres preguntas que esta defensa deja resueltas

- 1 ¿El sistema **aprende** a ordenar acciones fuera de muestra? ?
se resuelve en el Acto I
- 2 ¿Cuánto pesan las **reglas de cartera** frente al modelo? ?
se resuelve en el Acto II
- 3 ¿Sobrevive todo eso en una ventana **nunca consultada**? ?
se resuelve al final del Acto II

Ninguna de las tres se responde con la intuición que uno esperaría.

Acto I

¿Aprende el sistema a ordenar acciones?

2026-08-24


Aprendizaje automático aplicado a la selección de acciones

Acto I

¿Aprende el sistema a ordenar acciones?

[0:12] Primer acto: la señal, y solo la señal. Quiero insistir en que nada de lo que viene a continuación depende de cuántas acciones se compren, de cuánto cuesta rotarlas ni de ninguna decisión de cartera. Todo eso llega después, y llega con la señal ya congelada.

Cinco especialistas y un meta-agente que aprende a ponderarlos



Información disjunta

Pesos aprendidos

68 predictores · 33 parámetros de catálogo · un único ranking transversal de salida

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

— Cinco especialistas y un meta-agente que aprende a ponderarlos



[0:55] La arquitectura son cinco agentes especialistas y un meta-agente. Cada especialista mira una familia distinta de información —calidad, valor, crecimiento, momento y riesgo— y produce su propio ranking de todas las acciones del universo. El meta-agente recibe esos cinco rankings y aprende cómo ponderarlos para producir uno solo, que es la salida del sistema. Hay dos detalles de diseño que importan mucho para interpretar lo que viene después. El primero: los bloques de información son disjuntos, no se solapan. Ninguna variable aparece en dos agentes. Eso significa que si dos agentes acaban coincidiendo en su ranking, no es un artefacto de estar mirando los mismos datos. El segundo: los pesos del meta-agente no están fijados a mano por mí, se estiman a partir de las cohortes que ya han cerrado. Esa es literalmente la parte que aprende, y dentro de dos diapositivas veréis cómo aprende. En total son 68 predictores y 33 parámetros de catálogo.

Cuatro condiciones que hacen honesta la evaluación

Universo *point-in-time*

Etiquetas solo cuando cierran

Fundamentales por fecha de publicación

Retardo de ejecución

Las cuatro restan resultado. Están porque sin ellas el resultado no significa nada.

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

└ Cuatro condiciones que hacen honesta la evaluación

Cuatro condiciones que hacen honesta la evaluación

Universo *point-in-time*
Composición del S&P 500 **en cada fecha**, no la de hoy. Sin ella, el sistema solo vería empresas que sobrevivieron.

Etiquetas solo cuando cierran
Una observación entrena únicamente si su horizonte de doce meses **ya terminó**. Nunca se aprende de un futuro a medio ocurrir.


Fundamentales por fecha de publicación
El periodo fiscal **no** es cuando el mercado supo la cifra: se usa la fecha de *filing* de EDGAR más un margen.

Retardo de ejecución
Entre observar y poder operar pasa un tiempo, y ese tiempo está en el modelo, no supuesto igual a cero.

Las cuatro restan resultado. Están porque sin ellas el resultado no significa nada.

[1:10] Esta diapositiva es la que sostiene la credibilidad de todo lo demás, así que me detengo. Son cuatro condiciones que impuse para que la evaluación no se engañe a sí misma. La primera es el universo point-in-time: uso la composición que tenía el S&P 500 en cada fecha histórica, no la de hoy. Si usara la de hoy, el sistema solo vería empresas que sobrevivieron hasta 2026, que es el sesgo de supervivencia clásico y regala rentabilidad gratis. La segunda es la más importante y la más fácil de hacer mal: los datos fundamentales se fechan por su publicación, no por su periodo fiscal. El cierre del tercer trimestre no es la fecha en que el mercado conocía esa cifra; el mercado la conoce cuando la empresa la presenta. Por eso uso la fecha de filing de EDGAR más un margen adicional. La tercera: una etiqueta solo entrena cuando su horizonte de doce meses ya ha cerrado del todo, de modo que nunca aprendo de un futuro que aún está ocurriendo. Y la cuarta: un retardo de ejecución entre el momento en que observo y el momento en que puedo operar, porque suponerlo cero es suponer que se opera al precio que uno acaba de ver. Las cuatro condiciones restan resultado, todas ellas. Están precisamente por eso: sin ellas el número final sería más bonito y no significaría nada.

Las decisiones terminan antes de abrir la era reservada



2015–2024

selección: 117 cohortes, todas las decisiones

2025–2026

reservada: ninguna decisión la utilizó

Aprendizaje automático aplicado a la selección de acciones


2026-08-24

Las decisiones terminan antes de abrir la era reservada



[1:00] Este es el protocolo experimental, y es lo que me permite responder a la tercera pregunta. Tres estudios encadenados recorren de forma secuencial las cuatro fases predictivas —temporal, representación, modelo y meta—, cambiando una variable cada vez y comparando el Rank-IC de forma pareada, es decir, sobre exactamente las mismas cohortes. Cuando ese proceso termina, la señal se congela. Solo entonces se abre el estudio de cartera, que es la rejilla de la derecha. Y ahora la parte que importa: todo eso ocurre sobre datos de 2015 a 2024, que son 117 cohortes. El periodo 2025-2026 se aparta desde el principio. Y quiero ser preciso en cómo se aparta, porque no es que yo mirara para otro lado por disciplina: la serie sobre la que se calcula la rejilla está truncada en 2024, de modo que la era reservada no es que se ignore, es que literalmente no llega a calcularse. Se consulta una sola vez, al final de todo, y lo que salga es lo que hay.


El meta se equivoca, se corrige y acaba concentrándose



2026-08-24

Aprendizaje automático aplicado a la selección de acciones

El meta se equivoca, se corrige y acaba concentrándose



[1:15] Esta figura es la evidencia más directa de aprendizaje que tiene el trabajo, y quiero que la leamos por tramos, de izquierda a derecha, porque la historia está en el recorrido y no en el punto final. En 2015 el reparto entre los cinco agentes es uniforme, y lo es por construcción: no hay todavía ninguna cohorte cerrada de la que aprender, así que el sistema no tiene información para preferir a nadie. En 2016 ocurre lo primero interesante: el meta se concentra en momentum. Y momentum acabará siendo el peor especialista de todo el periodo. O sea, se equivoca, y se equivoca con datos, no por casualidad. En 2017 empieza a corregir hacia risk, y a partir de 2020 el peso de risk ya no baja de 0,79 en ningún año. Insisto en el punto: equivocarse con la información disponible y luego corregirse cuando llega información nueva, sin que nadie intervenga en el proceso, es exactamente lo que significa aprender. Si el sistema hubiera acertado desde el primer año yo desconfiaría, porque en 2015 no había nada con lo que acertar.

El matiz incómodo: el mejor especialista, solo, bate al meta

0,0690

promedio ingenuo
de los cinco

0,1067

meta-agente
(pesos aprendidos)

0,1201

risk por separado

El meta bate con holgura al promedio ingenuo: **aprender pesos sirve**.
Pero risk solo lo supera, porque el meta **tarda años en descubrirlo**.

Límite. Elegir risk en 2015 no era una opción disponible: en esa fecha nadie sabía cuál de los cinco iba a ganar. El coste del aprendizaje es el trayecto.

2026-08-24


Aprendizaje automático aplicado a la selección de acciones

El matiz incómodo: el mejor especialista, solo, bate al meta



[1:05] Y aquí viene el matiz incómodo, que este trabajo reporta en lugar de esconder. Tenemos tres números que comparar. El promedio ingenuo de los cinco agentes, es decir, ponderarlos a partes iguales sin aprender nada, da un Rank-IC de 0,0690. El meta-agente con pesos aprendidos da 0,1067, que es batir al promedio ingenuo con holgura: aprender los pesos sirve, y esa es la primera lectura. Pero el agente risk por separado da 0,1201, o sea, más que el meta. La pregunta obvia del tribunal es por qué, y la respuesta está en la figura anterior: el meta tarda años en descubrir a risk, y durante todo ese trayecto arrastra el peso de agentes que ordenan peor. El promedio de todo el periodo incorpora esos años malos. Ahora bien, quiero que quede clara la asimetría: yo puedo decir hoy que risk era el mejor porque he visto los diez años. En 2015, elegir risk no era una opción disponible; nadie sabía cuál de los cinco iba a ganar. El coste del aprendizaje es precisamente ese trayecto, y creo que reportarlo es más honesto que presentar el 0,1201 como si hubiera sido alcanzable de antemano.

Pregunta 1, resuelta: el orden existe y es de microestructura



Límite. Microestructura de precio a semanas, no la prima de baja volatilidad: la atribución describe el mecanismo, no lo explica.

PREGUNTA 1 · ¿APRENDE?

0,1067

Dentro de risk, dos variables explican el 81,5 % del liderazgo:

47,8 % 33,7 %
gap_21d range_63d

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

Pregunta 1, resuelta: el orden existe y es de microestructura



[1:05] Con esto puedo dar por resuelta la primera pregunta: sí, el sistema aprende a ordenar, con un Rank-IC medio de 0,1067 en la ventana de selección. Ese es el primer interrogante que se sustituye por una cifra. Pero quiero enseñaros además qué hay dentro, porque la respuesta natural resulta ser falsa. El agente que domina el sistema se llama risk, y la lectura que cualquiera haría es que está reproduciendo la prima de baja volatilidad, que es un factor conocido desde hace décadas. Los datos no la respaldan. Quienes mandan dentro de risk son el hueco de apertura a veintiún días, que encabeza el 47,8 por ciento de sus observaciones, y el rango de negociación a sesenta y tres días, con un 33,7. Entre las dos suman el 81,5 por ciento. La beta a un año, que sería la variable de la prima de baja volatilidad, ni siquiera está entre las tres primeras. Esto es microestructura de precio a escala de semanas, no una prima de riesgo clásica. Y la figura añade un matiz: aunque el reparto entre agentes esté ya estabilizado, la variable que manda dentro del agente cambia con el régimen de mercado. Lo presento como descriptivo, no causal: la atribución me dice por dónde pasa el mecanismo, no por qué funciona.

La señal es positiva, pero no es homogénea entre eras



Límite. La era reservada aporta solo 6 cohortes cerradas y aproximadamente una observación independiente efectiva.

76,1 %
cohortes positivas de 117

0,833
IC-IR

0,0364
era reservada

2026-08-24


Aprendizaje automático aplicado a la selección de acciones

La señal es positiva, pero no es homogénea entre eras



[0:55] Una media puede esconder cualquier cosa, así que enseñé la serie completa en lugar de quedarme en el número. En la ventana de selección hay 117 cohortes, el 76,1 por ciento de ellas son positivas y el IC-IR, que es la media dividida por su desviación, sale 0,833. La media de la era reservada sigue siendo positiva, 0,0364, aunque mucho más baja. Y lo que la figura enseña y la media no es que la señal no es homogénea: se debilita hasta aproximadamente la mitad en el régimen intermedio y vuelve a ser más fuerte en el más reciente. Por eso reporto la serie. El límite del recuadro es importante y lo voy a repetir varias veces: la era reservada aporta solo seis cohortes cerradas, y como se solapan en el tiempo equivalen aproximadamente a una única observación independiente. Cualquier cosa que diga sobre esa ventana hay que leerla con ese tamaño muestral delante.

Siete contrastes adversariales respaldan la señal



- ✓ t de Newey-West = 3,33
- ✓ permutación: $p = 0,0001$
- ✓ cinco placebos de etiqueta
- ✓ *bootstrap* por bloques excluye el cero
- ✓ ninguna era sostiene sola el resultado
- ✓ estable ante el cambio de semilla
- ✓ estable ante el corte de eras

Aprendizaje automático aplicado a la selección de acciones

2026-08-24

└ Siete contrastes adversariales respaldan la señal



[1:00] Una señal positiva puede ser ruido con suerte, así que la sometí a ocho contrastes diseñados para tumbarla. Siete la respaldan y los repaso. El t de Newey-West, que corrige por la autocorrelación que introduce el solapamiento de las cohortes, sale 3,33. El contraste de permutación baraja las etiquetas 9.999 veces y ninguna de esas 9.999 permutaciones alcanza la señal observada, de ahí el p -valor de 0,0001, que es el mínimo alcanzable con ese número de repeticiones. Los cinco placebos de etiqueta, que consisten en pedirle al sistema que prediga cosas que no debería poder predecir, quedan un orden de magnitud por debajo. El *bootstrap* por bloques de doce cohortes, que es la figura de la izquierda, excluye el cero de su intervalo. Y ninguna era por separado sostiene el resultado ella sola, ni cambia nada al cambiar la semilla aleatoria o el punto de corte entre eras. Es decir: el ranking no es ruido. Pero hay un octavo contraste, y ese sí falla.

El contraste que falla: Deflated Sharpe

Por qué no se contradice con lo anterior

0,573

Deflated Sharpe obtenido

0,95

umbral exigido

Encadenar tres estudios multiplica las configuraciones evaluadas y por tanto **encarece** este listón, en lugar de aliviarlo. Lo asumo.

Límite. La evidencia de *ordenación* es más fuerte que la de *rentabilidad ajustada por selección*; no reclamo la segunda.

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

El contraste que falla: Deflated Sharpe

El contraste que falla: Deflated Sharpe

Por qué no se contradice con lo anterior
Los siete contrastes apoyan que el **ranking no es ruido**.
El Deflated Sharpe limita algo distinto: una afirmación de **rentabilidad ajustada por cuántas configuraciones ensayé**. Penaliza por las 46 probadas.
Encadenar tres estudios multiplica las configuraciones evaluadas y por tanto **encarece** este listón, en lugar de aliviarlo. Lo asumo.

Límite. La evidencia de ordenación es más fuerte que la de rentabilidad ajustada por selección; no reclamo la segunda.

0,573


Deflated Sharpe obtenido

0,95

umbral exigido

[1:05] El contraste que falla es el Deflated Sharpe, que sale 0,573 frente a un umbral exigido de 0,95. Lo pongo en su propia diapositiva porque no quiero que pase desapercibido y porque me parece que la explicación de por qué no contradice a los siete anteriores es una parte sustantiva del trabajo. Los siete contrastes anteriores apoyan una afirmación concreta: que el ranking que produce el sistema no es ruido. El Deflated Sharpe mide otra cosa: penaliza el resultado por el número de configuraciones que probé antes de quedarme con esta, que fueron 46. Es un corrector de multiplicidad. Y aquí está lo incómodo, que declaro abiertamente: encadenar tres estudios secuenciales, que es mi diseño, multiplica el número de configuraciones evaluadas y por tanto encarece este listón en lugar de aliviarlo. Mi propio método hace más difícil pasar este contraste. Podría haberlo omitido del trabajo y nadie lo habría echado en falta. Lo reporto porque la consecuencia es concreta y quiero que se me juzgue con ella delante: la evidencia de ordenación es más fuerte que la evidencia de rentabilidad ajustada por selección, y por eso no reclamo la segunda en ningún momento de esta defensa.

El sesgo de cobertura: medido, no supuesto



Causa

Dirección

Decaimiento

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

El sesgo de cobertura: medido, no supuesto



[1:05] Queda una objeción seria que quiero adelantarme a responder, porque si no la hago yo la hará el tribunal. Mi universo point-in-time no es perfecto: el proveedor de datos no cubre todos los símbolos históricos, y esa cobertura incompleta podría estar fabricando parte de la señal. En lugar de suponer que no pasa nada, lo medí, y os doy las tres cosas que hay que saber. La causa: el principal motivo de ausencia es que el proveedor retira los símbolos que dejan de cotizar, un 36,8 por ciento de los ausentes, y no la mortalidad empresarial, que es solo un 5,5 por ciento. La dirección: el sesgo es optimista, es decir, sobrestima mi resultado en lugar de infravalorarlo. Declararlo va en mi contra y por eso lo declaro. Y el decaimiento: el sesgo cae de 26,2 a 8,0 puntos según se evalúa 2015 o 2026, o sea, es máximo en la era antigua y mínimo en la reciente. Esa última cifra tiene una consecuencia que quiero dejar sembrada aquí porque la recojo en el segundo acto: si el sesgo de cobertura estuviera fabricando la capacidad predictiva, el Rank-IC debería ser mayor en la era antigua, donde el sesgo es máximo. Y ocurre exactamente lo contrario.

Acto II

¿Puede cobrarse ese orden frente al mercado?

2026-08-24


Aprendizaje automático aplicado a la selección de acciones

Acto II

¿Puede cobrarse ese orden frente al mercado?

[0:12] Segundo acto. La señal queda congelada exactamente aquí y no vuelve a tocarse en toda la defensa: no se reentrena, no se cambia una sola variable predictiva. Todo lo que sigue modifica únicamente las reglas con las que ese orden se convierte en posiciones reales.

El orden mejora mientras el pago empeora



Límite. Identifica la implementación como palanca observable; no prueba que toda la debilidad económica sea ajena a la señal.

Rank-IC

Information Ratio

Mismo modelo. Misma señal.
Distinta pregunta.

Aprendizaje automático aplicado a la selección de acciones


2026-08-24

El orden mejora mientras el pago empeora



[1:15] Esta es la tensión central del trabajo y la bisagra entre los dos actos, así que es probablemente la diapositiva más importante de la defensa. Lo que veis es que el orden transversal mejora hacia la era más reciente mientras el pago económico de la cartera original cae hasta volverse negativo. Mismo modelo, misma señal, y sin embargo las dos curvas van en direcciones opuestas. No es una contradicción, y la explicación es la razón por la que separé los dos objetivos al principio. El Rank-IC evalúa toda la sección transversal, incluidas las acciones de la mitad inferior del ranking, que una cartera que solo compra nunca puede monetizar: acertar que algo va a caer no da dinero si no puedes ponerte corto. La cartera, en cambio, tiene ocho nombres y paga costes de operar. Son dos preguntas distintas sobre el mismo objeto. Y aquí recupero lo que sembré en la diapositiva del sesgo de cobertura: el sesgo es máximo en la era antigua, así que si estuviera fabricando la capacidad predictiva el Rank-IC debería ser mayor allí, y ocurre lo contrario. Eso descarta la explicación simple para la señal. Lo que no puedo hacer es extender ese argumento al resultado económico: identifico la implementación como una palanca observable, no pruebo que toda la debilidad económica sea ajena a la señal.

Pregunta 2, resuelta: 1.440 carteras sobre la misma señal



Límite. La cifra de la ganadora es una cota superior optimista: el hallazgo robusto es la dispersión de la nube.

PREGUNTA 2 · ¿CUÁNTO
PESA?

× **2,7**

Con la misma señal congelada:

Information Ratio
0,312 → 0,841

Exceso geométrico
2,12 % → 5,91 %

Aprendizaje automático aplicado a la selección de acciones


2026-08-24

— Pregunta 2, resuelta: 1.440 carteras sobre la misma señal



[1:10] Segunda pregunta resuelta, y la respuesta es un factor de dos coma siete. Explico qué es cada punto de esa nube: una cartera completa, simulada de principio a fin, que cambia únicamente las seis reglas de gestión. Mismo modelo, misma señal congelada, mismo panel de datos, mismas fechas. Es un experimento controlado en el sentido estricto del término, porque lo único que varía entre dos puntos son las reglas. Y la dispersión vertical de la nube es el resultado: con la misma capacidad predictiva, el Information Ratio va desde 0,312 hasta 0,841, multiplicándose por dos coma siete, y el exceso geométrico pasa del 2,12 al 5,91 por ciento. Una aclaración metodológica sobre por qué la rejilla es cartesiana, es decir, por qué pruebo todas las combinaciones en lugar de optimizar variable a variable: las seis reglas interactúan entre sí. El suelo de cobertura significa cosas opuestas según cuál sea el tope de efectivo, de modo que elegir cada eje por separado no habría encontrado la combinación final. Y el límite, que es importante: la cifra de la ganadora es una cota superior optimista, porque es el máximo de 1.440 intentos. El hallazgo robusto, el que defiende, no es esa cifra concreta sino la dispersión de toda la nube.

Tres reglas concentran casi toda la sensibilidad



Mueven más

Casi inertes

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

Tres reglas concentran casi toda la sensibilidad



[0:55] Si la cartera decide el resultado, la pregunta siguiente es qué parte de la cartera lo decide. La figura compara, para cada regla, la mejor y la peor mediana de Information Ratio dejando variar las otras cinco. El patrón es nítido: lo que gobierna la exposición al mercado es lo que manda. El número de posiciones mueve 0,208, la tenencia mínima 0,164 y el tope de efectivo 0,139. En cambio la tolerancia a la deriva mueve 0,017 y el reparto de pesos dentro de la cartera 0,005, es decir, son prácticamente indiferentes. Y hay un detalle en esta figura que justifica por sí solo la decisión de usar una rejilla cartesiana: si uno eligiera cada variable por su mejor valor marginal, adoptaría un suelo de cobertura de 60. La cartera ganadora usa 0. Optimizar variable a variable no habría encontrado esta cartera, y eso es evidencia directa de que las reglas interactúan.

La ganadora opera menos, y por eso gana

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

La ganadora opera menos, y por eso gana

La ganadora opera menos, y por eso gana

Métrica	Cartera del modelo	Ganadora	Era reservada
Information Ratio	0,312	0,841	0,109
Exceso geométrico	2,12 %	5,91 %	0,24 %
Rotación anual	2,42	1,35	0,35
Máxima caída	25,21 %	22,83 %	16,08 %


Qué cambio: 8 posiciones - efectivo 25 % → 10 % - tenencia mínima medio horizonte → horizonte completo - deriva 0,25 → 0,40.

Rota la mitad, cae menos y casi triplica el Information Ratio.
Para una señal a doce meses, reaccionar cada mes costaba más que no reaccionar.

Rota la mitad, cae menos y casi triplica el Information Ratio.
Para una señal a doce meses, reaccionar cada mes costaba más que no reaccionar.

[1:15] Vamos a la cartera ganadora concreta. La columna de la izquierda es la configuración real del estudio de modelo, que ya llevaba media ventana de tenencia mínima, así que la comparación es justa y no contra un hombre de paja. Qué cambia la ganadora: no toca el número de posiciones, que siguen siendo ocho, ni el reparto proporcional al alfa. Lo que hace es bajar el efectivo del 25 al 10 por ciento, alargar la tenencia mínima de medio horizonte a un horizonte completo, quitar el filtro de cobertura y tolerar más deriva antes de rebalancear, de 0,25 a 0,40. Las cuatro decisiones apuntan en la misma dirección, y es una dirección contraintuitiva: operar menos. Los resultados. El Information Ratio pasa de 0,312 a 0,841, casi el triple. La rotación anual cae del 242 al 135 por ciento, es decir, se opera aproximadamente la mitad. Y la caída máxima baja 2,4 puntos, del 25,21 al 22,83 por ciento, pese a haber reducido el colchón de efectivo, que es lo contrario de lo que uno esperaría. La lectura de todo esto dice algo concreto sobre la señal: es una señal a doce meses, y la maquinaria anterior la deshacía antes de que madurase. Reaccionar cada mes a una señal anual costaba más de lo que aportaba.

Pregunta 3, resuelta: la cartera cambia el signo del resultado



-12,23 %

cartera original

0,24 %

cartera optimizada

0,0364

la señal es idéntica en ambos casos

Límite. 6 cohortes y 1,41 años: empatar no es batir, y un solo periodo de confirmación no demuestra generalización.

2026-08-24

Aprendizaje automático aplicado a la selección de acciones




Pregunta 3, resuelta: la cartera cambia el signo del resultado



[1:25] Tercera pregunta, y es el momento de abrir la ventana que no se había consultado nunca. Empiezo por lo que habría pasado sin el segundo acto. Con la cartera por defecto del catálogo, las tres pasadas de la cadena mejoran dentro de la ventana de selección y fracasan fuera: Information Ratio negativo en las tres, sin batir al índice ni un solo año, y un exceso de menos 12,23 por ciento. Leído así, este trabajo parecería el retrato de un sobreajuste de manual, y así lo habría tenido que presentar. Con la cartera optimizada, sobre la misma señal, sin reentrenar nada y sin tocar una sola variable predictiva, deja de perder: el exceso pasa a más 0,24 por ciento y el Information Ratio a 0,109. Fijaos en el número de abajo a la derecha, que es el que cierra el argumento: el Rank-IC de la era reservada es 0,0364 en los dos casos, exactamente el mismo, porque se calcula antes de construir la cartera. La señal no ha cambiado en absoluto; lo único que ha cambiado son las reglas. Y ahora quiero medir la afirmación por lo que es, sin inflarla. Se pasa de destruir valor a empatar con el índice, no a superarlo. Son seis cohortes y un año y medio. Empatar no es batir, y un solo periodo de confirmación no demuestra generalización. Lo que sí demuestra, y esto sí lo definiendo es dónde estaba el cuello de botella.

El resultado se concentra en muy pocos nombres

Qué compró la cartera y dónde se concentró el resultado



42 acciones · 15 meses de mediana · AAPL aporta 27,8 %

Límite. Es una limitación, no un mérito: hay menos apuestas independientes que años de serie. El sector es una foto actual, no *point-in-time*.


Aprendizaje automático aplicado a la selección de acciones

El resultado se concentra en muy pocos nombres



[1:00] Antes de cerrar quiero abrir la cartera y enseñar de qué está hecha, porque contiene la limitación más seria del trabajo. La cartera mantuvo ocho posiciones en los 117 snapshots, sin quedarse en efectivo en ninguno. Por ella pasaron 42 nombres distintos en 49 episodios, con una mediana de quince meses por episodio. Un detalle que me gusta: ningún episodio duró un solo snapshot, de modo que la tenencia mínima que eligió la rejilla se puede leer directamente en la vida de las posiciones. Y ahora la parte incómoda. Apple aporta 27,8 puntos de contribución, casi el doble que la segunda posición, y en la era reservada una sola posición aporta 21,3. Eso significa que el número de apuestas efectivamente independientes es bastante menor de lo que los diez años de serie sugieren a primera vista. Es una limitación, no un mérito, y la recojo como tal. Añado además que la clasificación sectorial de la figura es una foto actual y no point-in-time, así que el reparto por sectores hay que leerlo como indicativo.

Cuánto margen hay antes de que los costes se lo coman



Límite. El margen es amplio en selección y estrecho en la reserva: es ahí donde el resultado es frágil, no en el supuesto de coste.

30 pb

coste adoptado por operación

295 pb

coste al que el exceso se anula

Margen de 9,8 veces en la ventana de selección.

En la era reservada baja a 3,1 veces.

Aprendizaje automático aplicado a la selección de acciones

2026-08-24

Cuánto margen hay antes de que los costes se lo coman



[1:00] Una objeción previsible es que todo esto se sostenga sobre un supuesto de costes demasiado generoso, así que la respondo con la escalera de la izquierda. Yo adopto 30 puntos básicos por operación. La pregunta relevante no es si ese número es exacto, sino a qué coste se anularía el exceso, y la respuesta es 295 puntos básicos, casi diez veces más. Es decir, tendría que estar equivocándome en un orden de magnitud para que el resultado de la ventana de selección se desvaneciera. Ese margen es amplio y el resultado es robusto al supuesto. Pero doy también el dato que me incomoda: en la era reservada ese margen baja a 3,1 veces. Sigue habiendo margen, pero es mucho más estrecho. Quiero que la conclusión se lea con precisión: la fragilidad del resultado no está en el supuesto de costes, que aguanta bien, sino en el tamaño de la ventana reservada, que es donde he insistido toda la defensa.

Las tres preguntas, resueltas

1 0,1067 de Rank-IC

Sí: siete contrastes a favor, uno en contra

2 ×2,7 en IR

Deciden el resultado, con la señal congelada

3 0,24 % de exceso

Deja de perder y empata: **empatar no es batir**

Ninguna afirmación práctica sobre una señal es interpretable
sin declarar con qué cartera se midió.

2026-08-24

Aprendizaje automático aplicado a la selección de acciones

Las tres preguntas, resueltas

[1:20] Vuelvo a las tres preguntas del principio, ahora con las respuestas puestas. Sí aprende, las reglas de cartera deciden el resultado, y en la ventana nunca consultada la cartera optimizada deja de perder. De la segunda es de la que estoy más seguro: está demostrada sobre 1.440 carteras con la señal congelada. Sobre el objetivo tal como lo enuncié al principio, batir al mercado, la respuesta honesta es que no está demostrado: empatar no es batir, y seis cohortes no son una generalización. Lo que sí queda demostrado es dónde estaba el cuello de botella, y esa es la contribución que definiendo. Una buena señal puede parecer inútil con una cartera inadecuada, y una buena cartera puede maquillar una señal débil; este trabajo separa selección, robustez e implementación precisamente para poder distinguir esos dos casos. De ahí la frase final, que es la tesis metodológica en una línea: ninguna afirmación práctica sobre una señal es interpretable sin declarar con qué cartera se midió. En el juego de suma cero de la segunda diapositiva, pasar de destruir valor a empatar sin reentrenar nada es un resultado sobre el cuello de botella, no una ventaja competitiva. Presentarlo como lo segundo sería el tipo de afirmación que este trabajo intenta desmontar.

Las tres preguntas, resueltas

- 1 ¿El sistema **aprende** a ordenar acciones fuera de muestra? **0,1067 de Rank-IC**
Sí: siete contrastes a favor, uno en contra
- 2 ¿Cuánto pesan las **reglas de cartera** frente al modelo? **×2,7 en IR**
Deciden el resultado, con la señal congelada
- 3 ¿Sobrevive todo eso en una ventana **nunca consultada**? **0,24 % de exceso**
Deja de perder y empata: empatar no es batir

Ninguna afirmación práctica sobre una señal es interpretable
sin declarar con qué cartera se midió.

Gracias

Preguntas

2026-08-24


Aprendizaje automático aplicado a la selección de acciones

Gracias

Adrián Núñez
Preguntas

[0:20] Muchas gracias por vuestra atención. Quedo a vuestra disposición para preguntas.

Reserva · Cómo se construyen los perfiles



2026-08-24

Aprendizaje automático aplicado a la selección de acciones


Reserva · Cómo se construyen los perfiles

Reserva · Cómo se construyen los perfiles



Reserva · Ningún estilo mejora a no imponer estilo

Perfiles informativos: sensibilidad de la misma señal, no un ranking de estilos




2026-08-24

Aprendizaje automático aplicado a la selección de acciones

Reserva · Ningún estilo mejora a no imponer estilo




Reserva · Capacidad: hasta qué tamaño aguanta



Con un límite de participación del 5 % del volumen diario, el percentil 95 de capacidad se sitúa en 20,3 millones de dólares. Es una estrategia de tamaño reducido: la restricción no la impone la señal, la impone la liquidez de las ocho posiciones.

Aprendizaje automático aplicado a la selección de acciones

Reserva · Capacidad: hasta qué tamaño aguanta



Pasada	Variables cambiadas	Rank-IC	IR reservado
Model Study 1	0	0.1051	-2.346
Model Study 2	2	0.1050	-1.010
Model Study 3	2	0.1067	-1.795

La selección secuencial depende del punto de partida: el ganador de cada pasada es el baseline de la siguiente, y el procedimiento se detiene cuando deja de haber cambios que hacer.

El coste está declarado: encadenar multiplica las configuraciones evaluadas y encarece el Drawnet Sharpe. Lo que protege al resultado no es la búsqueda, es la ventana reservada.